

Verossimilhança

Disciplina BIE5781 – IB – USP

PI (Paulo Inácio Prado)

02 de outubro de 2026

Recapitulando

- Modelos estatísticos descrevem a distribuição de probabilidades de variáveis aleatórias.
- No modelo de regressão linear simples, uma resposta Y é descrita como uma variável aleatória Gaussiana, com um parâmetro de posição μ que é uma função linear de uma variável X :

$$y_i \sim \mathcal{N}(\mu_i, \sigma)$$
$$\mu_i = \beta_0 + \beta_1 x_i$$

- O método dos mínimos quadrados (MQ, ou *OLS*) é uma forma de ajustar o modelo de regressão linear, minimizando a soma dos quadrados dos resíduos.

Hoje veremos ...

- que a soma dos quadrados dos erros é proporcional à probabilidade que o modelo de regressão simples atribui aos dados ($p(y \mid \theta)$).
- que MQ é uma ótima ideia para ajustar modelos Gaussianos, pois é um caso particular do **Método da Máxima Verossimilhança** (MV, ou *ML*)
- que a MV fornece um critério geral para encontrar os valores dos parâmetros que são mais apoiados pelos dados, para qualquer modelo estatístico.
- como as estimativas de MV (*MLE*) podem ser calculadas (ou como podemos ajustar modelos aos dados pelo método de MV, o que é a mesma coisa).

3 / 36

Nossa velha amiga, a regressão linear

$$\begin{aligned}y_i &\sim \mathcal{N}(\mu_i, \sigma) \\ \mu_i &= \beta_0 + \beta_1 x_i \\ \sigma &= C\end{aligned}$$

de forma mais compacta:


$$y_i \sim \mathcal{N}(\mu_i = \beta_0 + \beta_1 x_i, \sigma)$$

O que implica que:

$$p(y_i \mid \theta) = \mathcal{N}(y_i \mid \mu_i = \beta_0 + \beta_1 x_i, \sigma)$$

onde:

$$\theta = \{\beta_0, \beta_1, \sigma\}$$




4 / 36

Modelos atribuem probabilidades às observações

$$p(y_i | \theta), \theta : \{\beta_0 = 110.03, \beta_1 = 2.11, \sigma = 0.0278\}$$

Exemplo:

Qual é a probabilidade atribuída pelo modelo às medidas observadas no trecho de Paris a Evaux ($x = 0.5438, y = 111.22Km$)?



5 / 36


Modelos atribuem probabilidades às observações

$$p(y_i | \theta), \theta : \{\beta_0 = 110.03, \beta_1 = 2.11, \sigma = 0.0278\}$$

Exemplo:

Qual é a probabilidade atribuída pelo modelo às medidas observadas no trecho de Paris a Evaux ($x = 0.5438, y = 111.22Km$)?

1- Calcule o valor de μ da distribuição normal. Ou seja, o valor previsto de y pela reta de regressão para $x_i = 0.5438$ ($\mu = \beta_0 + \beta_1 x_i$):



```
> (mu <- 110.03 + 2.11*0.5438)
```

```
[1] 111.1768
```

6 / 36

Modelos atribuem probabilidades às observações

Probabilidade atribuída pelo modelo para $\{x = 0.5438, y = 111.22 \text{ Km}\}$

1 - Valor de μ :

```
> (mu <- 110.03 + 2.11*0.5438)
```

```
[1] 111.1768
```

2 - Probabilidade atribuída à observação $y = 111.22 \text{ Km}$ por $\mathcal{N}(\mu_i = \beta_0 + \beta_1 x_i, \sigma)$, supondo que y foi medido com precisão de 10 m.

```
> pnorm(111.22 + 0.01, mean = mu, sd = 0.0278) -  
+ pnorm(111.22 - 0.01, mean = mu, sd = 0.0278)
```

```
[1] 0.079
```

7 / 36

Verossimilhança

$$p(y|\theta) = p(y_1|\theta) \times p(y_2|\theta) \dots \times p(y_n|\theta)$$



$$= \prod p(y_i|\theta)$$

$$= \mathcal{L}_y(\theta)$$

Seção	y	Probabilidade
Dunkirk a Pantheon	111.24	0.195
Pantheon a Evaux	111.22	0.079
Evaux a Carcassonne	111.05	0.212
Carcassonne a Barcelona	110.99	0.281
Produto		0.000919

8 / 36

Verossimilhança como medida de apoio dos dados ao modelo



9 / 36

Verossimilhança: uma medida de apoio

A lei da verossimilhança (enunciado informal)

SE

- Há várias hipóteses ou modelos para descrever um conjunto de dados,
- e cada modelo atribui probabilidades diferentes aos dados

ENTÃO

O modelo que atribui a maior probabilidade aos dados é o mais apoiado pelos dados, ou seja, o modelo mais plausível.

10 / 36

Observações importantes

A verossimilhança é uma função dos parâmetros do modelo: verossimilhanças são condicionais a um conjunto de dados. Ou seja, os dados são tomados como invariantes, enquanto os parâmetros do modelo podem variar.

Funções de verossimilhança não são funções de distribuição de probabilidade, embora seja preciso usar distribuições de probabilidade para calcular verossimilhanças.

Notação

Usaremos a notação $\mathcal{L}_y(\theta)$ para expressar:

- uma função de verossimilhança condicional a um conjunto de dados $y = y_1, \dots, y_n$,
- para um modelo que tem um conjunto de parâmetros $\theta = \theta_1, \dots, \theta_i$.

11 / 36

O método da máxima verossimilhança

- Quando escolhemos um modelo estatístico para descrever dados, não sabemos os valores dos parâmetros dos modelos.
- Cada combinação de parâmetros resulta em um modelo diferente.
- Assim, podemos usar a função de verossimilhança para encontrar a combinação de parâmetros mais bem apoiada pelos dados, isto é, as estimativas de máxima verossimilhança (**MLEs**):

Ajuste pelo método de MV:

Encontrar os valores dos parâmetros que são mais apoiados pelos dados, ou seja, os valores dos parâmetros que maximizam a função de verossimilhança:

$$\hat{\theta} = \underset{\theta}{\operatorname{argmax}}[\mathcal{L}_y(\theta)]$$

12 / 36

Propriedades dos MLEs

quando $n \rightarrow \infty$:

- **Consistência**: converge em probabilidade para o valor do parâmetro a ser estimado.
- **Eficiência**: tem o menor erro quadrático médio possível entre os estimadores consistentes.
- **Normalidade**: a distribuição amostral dos MLEs tende assintoticamente à normal.²


Em geral:

- **Invariância funcional**: uma função monotônica de um MLE também é um MLE.

[2] Uma generalização do Teorema Central do Limite; decorre da propriedade de eficiência

13 / 36

Mais de um parâmetro: superfície de verossimilhança




• trace 1

14 / 36



Encontrando MLEs numericamente

- Na maioria dos casos, não há soluções analíticas para os MLEs.
- Em parte porque mesmo modelos relativamente simples têm mais de 3 parâmetros e, portanto, **superfícies de verossimilhança complexas e multidimensionais**.
- Precisamos recorrer a métodos numéricos, geralmente com computadores (rotinas de otimização).



15 / 36

Otimização pode ser traiçoeira



16 / 36

Procure ajuste por MV em boas bibliotecas

- Há bibliotecas para ajuste por MV de uma enorme variedade de modelos.
- Para começar a usar uma classe de modelos estatísticos, procure com cuidado programas estáveis e acessíveis. O conselho de usuários mais experientes é o caminho mais seguro.
- Boas bibliotecas incorporam a experiência de estatísticos, cientistas da computação e usuários que colaboram entre si, e.g.:
 - Regressão linear por MQ: `stats::lm()`
 - MQ não linear: `stats::nls`
 - Modelos lineares generalizados: `stats::glm()`
 - Modelos Gaussianos de efeitos mistos: `lme4::lmer`
 - GLMs de efeitos mistos: `lme4::glmer`
 - ...

17 / 36

Mensagens para levar para casa

- Todo modelo estatístico é uma hipótese sobre como os dados foram gerados por uma distribuição de probabilidade. Assim, essas hipóteses atribuem probabilidades aos dados.
- Como qualquer outro tipo de modelo, modelos estatísticos são aproximações de um processo muito complexo que gera seus dados.
- Lei da verossimilhança: fique com o modelo que atribui a maior probabilidade aos seus dados.
- A (log-)verossimilhança expressa o apoio dos dados a um modelo, **em comparação** com outros modelos ajustados ao mesmo conjunto de dados.
- Podemos ajustar modelos estatísticos encontrando os valores dos parâmetros que maximizam a verossimilhança do modelo.
- Estimativas de máxima verossimilhança têm muitas propriedades estatísticas desejáveis.

18 / 36


Leituras recomendadas

- Likelihood and all that. capítulo 6 *in* Bolker, B.M. 2008 Ecological Models and Data in R. Princeton: Princeton University Press.
- Hobbs, N.T. & Hilborn, R. 2006. Alternatives to statistical hypothesis testing in ecology: A guide to self-teaching. Ecological Applications: 16(1): 5-19.
- The Concept of Likelihood , capítulo 2 *in*: Edwards, A.W.F., 1992 Likelihood. Baltimore: John Hopkins University Press.

Slides extras

Probabilidades e densidades atribuídas a cada observação

Seção	y	Probabilidade	Densidade
Dunkirk a Pantheon	111.24	0.195	9.812
Pantheon a Evaux	111.22	0.079	3.812
Evaux a Carcassonne	111.05	0.212	10.708
Carcassonne a Barcelona	110.99	0.281	14.355



21 / 36

Função de verossimilhança da regressão linear simples

A função de densidade de probabilidade da Gaussiana para uma observação y_i é

$$\mathcal{N}(y_i) = (2\pi\sigma^2)^{-\frac{1}{2}} e^{-\frac{1}{2\sigma^2}(y_i - \mu_i)^2}$$

Na regressão linear, $\mu_i = \beta_0 + \beta_1 x_i$. Substituindo, temos:

$$\mathcal{N}(y_i) = (2\pi\sigma^2)^{-\frac{1}{2}} e^{-\frac{1}{2\sigma^2}(y_i - (\beta_0 + \beta_1 x_i))^2}$$

Assim, o conjunto de parâmetros da regressão linear simples é $\theta = \{\beta_0, \beta_1, \sigma\}$ e a função de verossimilhança é o produto da função de densidade definida acima para todos os valores de y_i :

$$\mathcal{L}_y(\theta) = \prod_{i=1}^n (2\pi\sigma^2)^{-\frac{1}{2}} e^{-\frac{1}{2\sigma^2}(y_i - (\beta_0 + \beta_1 x_i))^2}$$

22 / 36

Regressão linear simples: dedução dos MLEs

Função de log-verossimilhança do modelo:

$$\begin{aligned} -\mathbf{L}_y(\beta_0, \beta_1, \sigma^2) &= \\ -\ln[\mathcal{L}_y(\beta_0, \beta_1, \sigma^2)] &= \\ -\ln\left[\prod_{i=1}^n (2\pi\sigma^2)^{-\frac{1}{2}} e^{-\frac{1}{2\sigma^2}(y_i - (\beta_0 + \beta_1 x_i))^2}\right] &= \\ \frac{n}{2}\ln(2\pi) + \frac{n}{2}\ln(\sigma^2) + \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \end{aligned}$$

23 / 36

Regressão linear simples: dedução dos MLEs

Derivamos e igualamos a zero

$$\begin{aligned} \frac{\partial [-\mathbf{L}_y(\beta_0, \beta_1, \sigma^2)]}{\partial \beta_0} = 0 &\implies \sum y_i = n\beta_0 + \beta_1 \sum x_i \\ \frac{\partial [-\mathbf{L}_y(\beta_0, \beta_1, \sigma^2)]}{\partial \beta_1} = 0 &\implies \sum y_i x_i = \beta_0 \sum x_i + \beta_1 \sum x_i^2 \\ \frac{\partial [-\mathbf{L}_y(\beta_0, \beta_1, \sigma^2)]}{\partial \sigma^2} = 0 &\implies n - \frac{1}{\sigma^2} \sum (y_i - \beta_0 - \beta_1 x_i)^2 = 0 \end{aligned}$$

24 / 36

O método de MQ é a solução de máxima verossimilhança para modelos Gaussianos!

Resolvendo o sistema com as duas primeiras equações:

$$\begin{cases} \sum y_i = n\beta_0 + \beta_1 \sum x_i \\ \sum y_i x_i = \beta_0 \sum x_i + \beta_1 \sum x_i^2 \end{cases}$$

Obtemos:

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} , \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

25 / 36

A função de verossimilhança

Qualquer função proporcional ao produto das probabilidades atribuídas por um modelo estatístico a cada observação dos dados:

$$\mathcal{L} \propto P(y_1 | H) \times P(y_2 | H) \times \dots \times P(y_i | H)$$

26 / 36

A função de verossimilhança

Qualquer função proporcional ao produto das probabilidades atribuídas por um modelo estatístico a cada observação dos dados:

$$\mathcal{L} \propto \prod^N P(y_i | H)$$

27 / 36

A função de log-verossimilhança

O logaritmo da função de verossimilhança, ou seja, qualquer função proporcional à **soma dos logaritmos das probabilidades** atribuídas por um modelo a cada observação dos dados:

$$\mathbf{L} \propto \sum^N \ln P(y_i | H)$$

28 / 36

Alguns outros MLEs analíticos

Para ajustar distribuições aos dados (modelos muito simples, sem preditores):

- Poisson: $\hat{\lambda} = \frac{\sum y_i}{n}$
- Normal: $\hat{\mu} = \frac{\sum y_i}{n}$, $\hat{\sigma} = \sqrt{\sum \frac{(y_i - \bar{y})^2}{n}}$
- Binomial: $\hat{p} = \frac{y}{N}$
- Exponencial: $\hat{\lambda} = \frac{n}{\sum y_i}$
- Geométrica: $\hat{p} = \frac{n}{n + \sum y_i}$


29 / 36

Exemplo: ajuste de Poisson por MV




- 568 parcelas na Mata Atlântica
- Um total de 4.242 palmeiras registradas.
- Para ajustar uma Poisson, basta a média amostral:

$$\hat{\lambda} = \frac{4242 \text{ palmeiras}}{568 \text{ parcelas}} = 7,468/\text{parcela}$$



30 / 36

Exemplo: ajuste de Poisson por MV



31 / 36


Poisson x Binomial Negativa

Qual modelo é mais apoiado por esses dados?

- Diferença entre as log-verossimilhanças:

$$L_{NB} - L_{Poisson} = 1924$$

- Ou seja, uma razão de verossimilhança de e^{1924}
- O ajuste da binomial negativa é muitíssimo mais apoiado pelos dados, **em comparação** com o ajuste da Poisson.




32 / 36

Inferência sobre parâmetros



Perfis de log-verossimilhança

- Um gráfico do valor mínimo da **log-verossimilhança negativa** em função de um único parâmetro;
- O eixo y é padronizado para que seu mínimo seja zero.
- Regra canônica**: todos os valores do parâmetro a até 2 unidades da log-verossimilhança negativa relativa são igualmente plausíveis.



33 / 36


Perigo, Will Robinson!



34 / 36

Exemplo: escalonamento da carga de parasitas



- A biomassa de ectoparasitas de aves é proporcional à potência $2/3$ da massa corporal do hospedeiro.
- Dados: biomassa corporal média e massa média de ectoparasitas por ave para 42 espécies de aves.
- Regressão linear simples, com o log da biomassa média de parasitas como resposta e o log da massa corporal média como variável preditora.



Hechinger et al. Proc. R. Soc, 2019

35 / 36

Intervalos de plausibilidade



36 / 36

