

Fundamentos para modelagem estatística

Disciplina BIE5781 – IB – USP


PI (Paulo Inácio Prado)

30 de setembro de 2026

Conceitos

- Variáveis aleatórias
- Funções de densidade de probabilidade
- Distribuições de probabilidade como modelos estatísticos ($p(y | \theta)$)
- A distribuição normal de probabilidade
- Teorema central do limite
- Método dos mínimos quadrados

Métodos dos mínimos quadrados – um pouco de história




Joseph Stigler, 1999

3 / 41

O problema: combinação de observações

- A partir do séc XVII: ciência europeia acumula medidas astronômicas e geodésicas
- Sécs XVII-XVIII:
 - medidas repetidas nunca são iguais, mas a sua combinação reduz o erro
 - medidas sob diferentes condições também podem ser combinadas
 - diferentes maneiras de combinar (p.ex, média, minimizar erros absolutos)




Wikipedia: história do metro

4 / 41

Um exemplo: definição do metro

- **1791**: Assembleia Nacional Francesa define o metro como um décimo de milionésimo da distância do equador ao polo norte
- **1792-1798**: missão Delambre & Méchain mede quatro subseções de arco ao longo do meridiano de Paris, entre Durkink e Barcelona.
- Medidas de cada subseção necessárias para os cálculos: comprimento em unidades lineares (*Module*) e em graus, e coordenadas do ponto médio.



Stigler, 1986, 1999

Cálculos

Dados das medidas das subseções do arco:

- razão entre comprimento em *Modules* e em graus : $y = S/d$
- o quadrado do seno das coordenadas centrais : $x = \sin^2 L$

Usamos os coeficientes da aproximação linear $y = a + bx$ para calcular distância do equador ao polo norte com:

$$Q = 90(a + b/2)$$

Problema: combinar as medidas para obter a melhor estimativa de a e b .

Table 17.1 French arc measurements. The number 76545.74 is a misprint; the correct number is 76145.74. The table gives the length of four consecutive segments of the meridian arc through Paris, both in modules S (one module $\cong 12.78$ feet) and degrees d of latitude (determined by astronomical observation). The latitude L of the midpoint of each arc segment is also given.

	Modules S	Degrees d	Midpoint L
Dunkirk to Pantheon	62472.59	2.18910	49° 56' 30"
Pantheon to Evaux	76545.74	2.66868	47° 30' 46"
Evaux to Carcassonne	84424.55	2.96336	44° 41' 48"
Carcassonne to Barcelona	52749.48	1.85266	42° 17' 20"
Total	275792.36	9.67380	

Source: *Allgemeine Geographische Ephemeriden* (1799) 4: xxxv.

Stigler, 1999

Erros

a = 28220.94 , b = 541.26

Subseção	x	y	Previsto	Erro
Dunkirk a Pantheon	0.58582	28538.02	28538.02	0.00
Pantheon a Evaux	0.54380	28533.11	28515.28	17.83
Evaux a Carcassonne	0.49471	28489.47	28488.71	0.76
Carcassonne a Barcelona	0.45275	28472.29	28466.00	6.29

Erros

a = 28227.16 , b = 562.61

Subseção	x	y	Previsto	Erro
Dunkirk a Pantheon	0.58582	28538.02	28556.75	-18.73
Pantheon a Evaux	0.54380	28533.11	28533.11	0.00
Evaux a Carcassonne	0.49471	28489.47	28505.49	-16.02
Carcassonne a Barcelona	0.45275	28472.29	28481.89	-9.59

Soma dos quadrados dos erros

$a = 28227.16$, $b = 562.61$

Subseção	x	y	Previsto	Erro	Erro²
Dunkirk a Pantheon	0.5858	28538.02	28556.75	-18.73	350.70
Pantheon a Evaux	0.5438	28533.11	28533.11	0	0.00
Evaux a Carcassonne	0.4947	28489.47	28505.49	-16.02	256.67
Carcassonne a Barcelona	0.4528	28472.29	28481.89	-9.59	92.00
Total					699.37

Soma dos quadrados dos erros


$a = 28227.16$, $b = 541.26$

Subseção	x	y	Previsto	Erro	Erro²
Dunkirk a Pantheon	0.5858	28538.02	28544.25	-6.22	38.70
Pantheon a Evaux	0.5438	28533.11	28521.5	11.61	134.76
Evaux a Carcassonne	0.4947	28489.47	28494.93	-5.46	29.82
Carcassonne a Barcelona	0.4528	28472.29	28472.22	0.07	0.01
Total					203.29

Método dos mínimos quadrados (1805)



Adrien-Marie Legendre (1752-1833),
único retrato conhecido, [Wikipedia](#)




11 / 41

... que levou à distribuição Normal (1809)



Carl Friedrich Gauss (1777-1855),
[Wikipedia](#)



12 / 41

... que levou ao teorema do limite central (1812)



Pierre Simon Laplace (1749-1827) ([Wikipedia](#))




Tabuleiro de Galton (1873) ([Wikipedia](#))

13 / 41

Somos todos ogros

1. Se você não está entendendo tudo, é porque está prestando atenção.
2. "Síndrome do impostor" muitas vezes é reconhecimento da complexidade de um tema, o que não é pouco.
3. O aprendizado é gradual: cada etapa de entendimento é valiosa em si e porque é necessária para as seguintes.



14 / 41

Conceitos e definições


DEFINITION	# OF PLANETS	SOLAR SYSTEM
TRADITIONALIST: PLUTO IS A PLANET	9	
MODERN: PLUTO IS NOT A PLANET	8	
EXPANSIVE: DWARF PLANETS ARE PLANETS	17+	
ULTRATRADITIONALIST: ONLY THE CLASSICAL PLANETS ARE PLANETS	5	
CONDESCENDING: ONLY GIANT PLANETS ARE PLANETS; THE REST ARE BIG ASTEROIDS.	4	
SIMPLISTIC: ANYTHING GRAVITATIONALLY ROUND IS A PLANET	37+	
GROUNDING: ONLY OBJECTS A SPACESHIP HAS LANDED ON ARE PLANETS	10	
REGOLITHIC: ANYTHING COVERED IN DIRT AND ICE AND STUFF IS A PLANET	∞	

"Planet definitions", xkcd

15 / 41

Um conjunto de dados experimentais

- Coleta de populações de *Drosophila melanogaster* em 18 locais na Austrália.
- Linhagens isofêmeas: progênie separadas de cada fêmea coletada, obtida de 10 gerações em laboratório.
- 50 larvas das linhagens de cada população mantidas a 18°C, 25°C e 29°C durante o desenvolvimento (3 réplicas por tratamento).
- Condições controladas de laboratório: frascos, meio de cultura, fotoperíodo, temperatura, densidade de moscas, etc.
- Medição das moscas adultas nascidas sob cada tratamento.




Van Heerwaarden & Sgrò, *Evolution* (2011).

16 / 41



Um conjunto de dados experimentais

- 30 adultos sorteados entre as moscas criadas em cada temperatura.
- Os histogramas mostram as frequências de moscas em classes de comprimento do tórax para cada população, apenas para fêmeas criadas a 25°C.
- As linhas azuis são as médias do comprimento do tórax de cada amostra.



17 / 41


Distribuição das médias amostrais



18 / 41

Variáveis aleatórias


- Muitos valores são possíveis, mesmo para médias de medidas tomadas exatamente da mesma forma e sob condições fortemente controladas.
- Medidas científicas são **variáveis aleatórias**: quantidades que são inevitavelmente afetadas por eventos aleatórios.
- Como lidar com isso? Com modelos que nos dizem qual é a chance de observar cada valor possível da medida.
- Em outras palavras, construindo **distribuições de probabilidade**.



19 / 41

1º passo: a escala de densidade


- Vamos reescalonar o eixo y deste histograma para que a área total do histograma seja igual a um.
- Ou seja, expressamos as frequências (ou contagens) originais em uma nova escala, de modo que a soma das áreas das barras seja igual a um. Chamamos essa escala de **densidade**.
- Este é um reescalonamento linear (ou seja, proporcional), então a forma do histograma não muda.



20 / 41

2º passo: a função de densidade


- Agora vamos imaginar como "suavizar" a distribuição de densidades, usando uma função contínua.
- Pense nessa função como a representação contínua (ou um limite contínuo) do histograma. Essa é a **função de densidade**.
- A área sob a curva de uma função de densidade é igual a um.



21 / 41

Função de densidade: algumas definições


- A função de densidade é uma função matemática contínua $f(x)$ que retorna um valor de densidade para qualquer valor da medida x .
- Chamamos de **espaço amostral** (Ω) o conjunto de todos os valores que uma variável aleatória pode assumir.



22 / 41

Função de densidade e probabilidades

- A integral de $f(x)$ sobre o espaço amostral é igual a um.
- Essa é uma forma matemática de dizer que a área sob $f(x)$ é igual a um.




23 / 41

Função de densidade e probabilidades

- A área sob $f(x)$ para qualquer intervalo $L \leq x \leq U$ é uma fração da área total sob $f(x)$.
- Essa área é uma expressão matemática da **probabilidade atribuída a um intervalo de medidas**. Ela também é uma integral definida da função de densidade:

$$P(L \leq x \leq U) = \int_L^U f(x) dx$$




24 / 41

Distribuições de probabilidade como modelos

- A função de densidade que definimos é usada para expressar probabilidades de variáveis aleatórias, ou seja, uma **distribuição de probabilidade**.
- É um modelo que atribui probabilidades aos dados, isto é, aos valores de uma variável aleatória.
- No nosso exemplo, a variável aleatória é o comprimento médio do tórax que obtivemos a partir de amostras de 30 moscas.
- Com esse tipo de modelo, podemos fazer muitas perguntas interessantes sobre essas médias amostrais, como:


25 / 41

Qual é a probabilidade de um comprimento médio do tórax de até 1,04 mm?



26 / 41

Qual é o intervalo de confiança para o comprimento médio do tórax?



27 / 41


Qual distribuição de probabilidade?

- Agora sabemos que distribuições de probabilidade são uma boa escolha para modelar variáveis aleatórias. Mas como construir um modelo desses?
- Há receitas para isso, mas muitas distribuições de probabilidade já foram propostas, para uma enorme variedade de tipos de dados.
- No nosso exemplo, nossa variável aleatória são médias amostrais. O **Teorema Central do Limite** afirma que as médias amostrais seguem uma distribuição Normal à medida que o tamanho das amostras aumenta.
- Esse é um dos resultados mais importantes da teoria da probabilidade. Temos ótimas razões para escolher a distribuição Normal como nosso modelo estatístico.

28 / 41

A distribuição Normal


- Criada para descrever a distribuição de erros de medida aditivos.
- O TCL nos diz que este é um bom modelo para qualquer variável aleatória que seja a soma de muitas outras variáveis aleatórias (como médias amostrais).
- É uma distribuição simétrica, sempre em forma de sino.
- Tem dois parâmetros, que correspondem à média e ao desvio-padrão da distribuição.
- Sua média e seu desvio-padrão são independentes.



29 / 41

Parâmetro de posição da distribuição Normal


- A Normal tem um **parâmetro de posição**, que chamaremos de μ .
- Esse parâmetro corresponde à média da distribuição Normal.
- Ao mudar μ , mudamos a posição da distribuição Normal ao longo do eixo x, sem alterar o desvio-padrão.



30 / 41

Parâmetro de escala da distribuição Normal


- A Normal tem um **parâmetro de escala**, que chamaremos de σ .
- Esse parâmetro corresponde ao desvio-padrão da distribuição Normal.
- Ao mudar σ , mudamos a dispersão da distribuição Normal em torno da média, sem alterar a média.



31 / 41

O modelo de regressão linear


- Agora vamos examinar a distribuição das médias nas três temperaturas
- Para cada temperatura, temos 18 médias, das medidas de 30 indivíduos de cada população de origem
- Queremos um modelo que combine essas medidas repetidas para cada tratamento para estimar o melhor possível qual o tamanho médio sob cada temperatura.



32 / 41

O modelo de regressão linear


- Temos boas razões para assumir que o comprimento médio do tórax em cada tratamento tende a uma distribuição normal.
- Vamos começar com um modelo simples: o comprimento médio do tórax das populações é uma função linear da temperatura: $\mu = a + bX$
- O que buscamos, então, são valores de a e b que resultem na previsão com menor erro possível do comprimento do tórax para cada temperatura.



33 / 41

Ajuste do modelo


- Assim, podemos usar o método dos mínimos quadrados para combinar todas as medidas que temos e encontrar os valores de a e b que minimizam o erro de previsão.
- Ajustar um modelo estatístico nada mais é que encontrar valores de seus parâmetros adequados para descrever os dados.
- No método de mínimos quadrados, esta adequabilidade é expressa pela soma dos quadrados dos resíduos.



34 / 41

Ajuste do modelo


- Assim, podemos usar o método dos mínimos quadrados para combinar todas as medidas que temos e encontrar os valores de a e b que minimizam o erro de previsão.
- Ajustar um modelo estatístico nada mais é que encontrar valores de seus parâmetros adequados para descrever os dados.
- No método de mínimos quadrados, esta adequabilidade é expressa pela soma dos quadrados dos resíduos.



35 / 41

Ajuste no R

```
> m1 <- lm(th.mean ~ Temperature,  
+         data = dthor.mt)  
> plot(th.mean ~ Temperature,  
+      data = dthor.mt,  
+      xlab = "Temperatura",  
+      ylab = "Comprimento tórax (mm)")  
> abline(m1, col = "blue")
```



36 / 41

Um pouco de notação

- Nosso modelo: o comprimento médio do tórax y segue uma distribuição normal:

$$y \sim \text{Normal}(\mu, \sigma)$$

- Sendo que a média desta distribuição é uma função linear da temperatura x

$$\mu = a + bx$$

- E o desvio-padrão desta distribuição é constante

Um pouco de notação

- A notação $y \sim \text{Normal}(\mu, \sigma)$ nos lembra que nosso modelo é uma distribuição de probabilidades.
- Desta maneira, nosso modelo atribui probabilidades a cada valor de y
- Isto vale para qualquer modelo estatístico. Todos eles utilizam alguma distribuição de probabilidades para atribuir probabilidades a observações.
- Podemos expressar isto como $p(y_i \mid \theta)$ (a probabilidade p que o modelo atribui a cada observação y_i , considerando os valores de seus parâmetros θ).

Um pouco de notação

Como na distribuição normal a média é independente do desvio padrão, uma notação alternativa do nosso modelo é a seguinte:

- O comprimento do tórax é uma função linear da temperatura, mais um erro de distribuição normal com média zero e desvio-padrão constante:

$$y = a + bx + \epsilon,$$

$$\epsilon \sim \text{Normal}(\mu = 0, \sigma)$$

39 / 41

Mensagens para levar para casa

1. Distribuições de probabilidade atribuem probabilidades a cada valor possível de uma medida.
2. Assim, distribuições de probabilidade podem ser concebidas como modelos do processo que gera os dados em questão.
3. Ajustamos um modelo estatístico encontrando valores razoáveis para os parâmetros das distribuições de probabilidade.
4. O método dos mínimos quadrados é uma maneira de encontrar estes valores razoáveis, se supomos que as observações têm uma distribuição normal
5. Esta premissa de normalidade é razoável quando as observações resultam de soma de muitas variáveis aleatórias.

40 / 41

Referências

- Bolker, B.M. 2008 Ecological Models and Data in R. Princeton: Princeton University Press.
- Gotelli, N.J., Ellison, A.M., Ellison, S.E., 2004. A Primer of Ecological Statistics. Sinauer Associates Publishers.
- McElreath, R., 2018. Statistical Rethinking: A Bayesian Course with Examples in R and Stan, 2nd ed. CRC Press.