

Modelos Estatísticos Lineares

Disciplina BIE5781 – IB – USP

PI (Paulo Inácio Prado)

07 de outubro de 2026

Conceitos-chave

- Preditor linear:
 - Aditivos
 - Com interação
- Variáveis categóricas e contrastes lineares
- Uso do preditor para ... fazer previsões :)

O preditor linear

Uma expressão geral para modelos estatísticos

$$Y \sim f(Y \mid \theta = g_i(X))$$

Em palavras

Y é uma variável aleatória, cujos valores têm probabilidades definidas pela função de densidade $f(Y)$, cujos parâmetros θ são funções g_i de outras medidas (preditoras) X .

Exemplo: regressão linear simples

$$Y \sim \text{Normal}(Y \mid \mu = \beta_0 + \beta_1 X_1, \sigma)$$

Preditores lineares

Todos que podem ser escritos na forma

$$g(X_i) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_n X_n = \sum \beta_i X_i$$

Exemplos

- $\beta_0 + \beta_1 X_1$, pois $\beta_0 = \beta_0 X_0$, sendo $X_0 = 1$
- $\beta_0 + \beta_1 X_1 + \beta_2 X_1^2$, pois podemos chamar X_1^2 de X_2
- $\beta_0 + \beta_1 X_1 + \beta_2 \ln(X_1)$, pois podemos chamar $\ln X_1$ de X_2
- $\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2$, pois podemos chamar $X_1 X_2$ de X_3

Preditores lineares

Todos que podem ser escritos na forma

$$g(X_i) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_n X_n = \sum \beta_i X_i$$

Ou seja, a derivada parcial em relação a cada parâmetro não depende de nenhum parâmetro:

$$\frac{\partial g(X_i)}{\partial \beta_i} = X_i$$

5 / 66

E o que são preditores **não** lineares?

Todos que **não podem** ser reduzidos à forma $g(X_i) = \sum \beta_i X_i$.

Exemplos

- $\beta_0 X_1^{\beta_1}$
- $\beta_0 e^{\beta_1 X_1}$
- $\frac{\beta_1 X_1}{1 + \beta_1 \beta_2 X_1}$
- E muitas, muitas mais.

Em todos os casos, as derivadas parciais dependem dos parâmetros.

6 / 66

E o que são preditores **não** lineares?

Todos que **não podem** ser reduzidos à forma $g(X_i) = \sum \beta_i X_i$.

Exemplos

- $g(X_i) = \beta_0 X_1^{\beta_1} : \quad \frac{\partial g}{\partial \beta_0} = X_1^{\beta_1}, \quad \frac{\partial g}{\partial \beta_1} = \beta_0 X_1^{\beta_1} \ln X_1$
- $g(X_i) = \beta_0 e^{\beta_1 X_1} : \quad \frac{\partial g}{\partial \beta_0} = e^{\beta_1 X_1}, \quad \frac{\partial g}{\partial \beta_1} = \beta_0 X_1 e^{\beta_1 X_1}$
- $g(X_i) = \frac{\beta_1 X_1}{1 + \beta_1 \beta_2 X_1} : \quad \frac{\partial g}{\partial \beta_1} = \frac{X_1}{(1 + \beta_1 \beta_2 X_1)^2}, \quad \frac{\partial g}{\partial \beta_2} = -\frac{\beta_1^2 X_1^2}{(1 + \beta_1 \beta_2 X_1)^2}$
- E muitas, muitas mais.

Em todos os casos, as derivadas parciais dependem dos parâmetros.

7 / 66

Preditores lineares múltiplos aditivos

8 / 66


Modelos lineares múltiplos aditivos

- O preditor é a soma de variáveis independentes isoladas, cada uma multiplicada por seu coeficiente.
- A soma **não** inclui variáveis independentes que são produtos de outras presentes no modelo:

$$\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$$

- Se uma variável independente X_i aumenta em uma unidade, o preditor aumenta β_i , não importando o valor das outras variáveis.
- Ou seja, diferenças da resposta associadas a cada preditora são **aditivas**. Não são afetadas pelo valor das demais variáveis.

Interpretação dos coeficientes



Relação entre altura do primeiro filho e altura do pai e da mãe (Galton, 1885)

Interpretação dos coeficientes

Especifica o modelo

```
> m.pais.f <- alist( H ~ dnorm( mu, exp(lsigma) ),  
+                   mu <- b0 + b1 * pai + b2 * mae)
```

Ajuste

```
> ## Valores iniciais  
> inicio.a <- mean(dat$H)  
> inicio.ls <- sd(dat$H) |> log()  
> ## Ajuste  
> m.pais <- quap( m.pais.f, data = dat,  
+               start = list(b0 = inicio.a, b1 = 0, b2 = 0, lsigma = inicio.ls))  
> ## Coeficientes  
> precis(m.pais)
```

	mean	sd	5.5%	94.5%
b0	70.4358382	0.16058759	70.1791882	70.6924881
b1	0.4767470	0.06376877	0.3748322	0.5786618
b2	0.2840529	0.06811670	0.1751892	0.3929165
lsigma	0.7477301	0.05376032	0.6618107	0.8336494

Interpretação dos coeficientes

```
> ## Especifica o modelo  
> lm.pais <- lm(H ~ pai + mae, data = dat)  
> ## Resumo  
> summary(lm.pais)
```


```
Call:  
lm(formula = H ~ pai + mae, data = dat)
```

```
Residuals:  
    Min       1Q   Median       3Q      Max  
-6.0629 -1.2474  0.1647  1.4512  7.8374
```


```
Coefficients:  
            Estimate Std. Error t value Pr(>|t|)  
(Intercept) 70.43584    0.16200  434.794 < 2e-16 ***  
pai          0.47675    0.06433   7.411 5.62e-12 ***  
mae          0.28405    0.06872   4.134 5.59e-05 ***  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 2.131 on 170 degrees of freedom  
Multiple R-squared:  0.3206,    Adjusted R-squared:  0.3126
```

Interpretação dos coeficientes



Coeficientes expressam diferenças condicionais



13 / 66

In do volume de árvores de *Prunus serotina* em função dos logaritmos de sua altura e DAP (Meyer, 1953)

14 / 66


Coeficientes expressam diferenças condicionais

```
> ## Especifica o modelo
> m.arv.f <- alist( LV ~ dnorm( mu, exp(lsigma) ),
+                 mu <- b0 + b1 * LD + b2 * LH)

> ## Valores iniciais
> inicio.a2 <- mean(dat2$LV)
> inicio.ls2 <- sd(dat2$LV) |> log()
> ## Ajuste no rethinking
> m.arv <- quap( m.arv.f, data = dat2,
+               start = list(b0 = inicio.a2, b1 = 0, b2 = 0, lsigma = inicio.ls2))
> ## Coeficientes
> precis(m.arv)
```

	mean	sd	5.5%	94.5%
b0	-8.122428e-09	0.01389209	-0.02220225	0.02220223
b1	1.982650e+00	0.07128876	1.86871668	2.09658308
b2	1.117123e+00	0.19429336	0.80660492	1.42764154
lsigma	-2.559442e+00	0.12700009	-2.76241285	-2.35647152


Coeficientes expressam diferenças condicionais




15 / 66

16 / 66

Coeficientes expressam diferenças condicionais



Coeficientes expressam diferenças condicionais



1: o que sobra da altura depois de descontar o diâmetro. 2: o volume (também descontado o diâmetro) em função desse resto. A inclinação é o coeficiente da altura na regressão múltipla.

Teorema de Frisch–Waugh–Lovell

Em um modelo ajustado pelo método dos mínimos quadrados com preditor linear

$$\mu = \beta_0 + \beta_1 X_1 + \sum_{i=2}^n \beta_i X_i$$

Os seguintes estimadores de β_1 são equivalentes:

1. A estimativa obtida de uma regressão múltipla com todas as variáveis preditoras
2. O coeficiente da regressão da resposta Y em função do **resíduo de X_1** em relação às demais preditoras ($X_2, \dots, X_n$)
3. O coeficiente da regressão do **resíduo da resposta Y** em função do **resíduo de X_1** , ambos em relação às demais preditoras



Ragnar Frisch (1895-1973)

Veja [Wikipedia](#) e [Lovell 2018](#)


Preditoras categóricas

Altura de filhas e filhos

Temos que converter o gênero em um número, para incluir no preditor linear.

Solução: nova variável com valor 1 se menina e valor 0 se menino.

	Altura mãe	Gênero	menina	Altura
22	4.02	F	1	69.5
29	2.52	F	1	70.5
32	2.02	F	1	66.0
886	2.02	M	0	64.0
889	-0.98	M	0	66.5
891	1.02	M	0	72.0



21 / 66

Altura de filhas e filhos

Especifica o modelo

```
> m.gal.f <- alist(
+   Height ~ dnorm(mu, exp(lsigma) ),
+   mu <- b0 + b1 * mae + b2 * menina
+ )
```

Ajuste do modelo

```
> m.gal <- quap(m.gal.f, data = gal,
+   start = list(b0 = mean(gal$Height), b1 = 0, b2 = 0,
+   lsigma = log(sd(gal$Height))))
> precis(m.gal)
```


	mean	sd	5.5%	94.5%
b0	70.4409495	0.18397288	70.1469253	70.7349737
b1	0.3486614	0.07338628	0.2313759	0.4659468
b2	-5.1500658	0.52716955	-5.9925845	-4.3075470
lsigma	0.8836568	0.05038493	0.8031319	0.9641816

22 / 66

Altura de filhas e filhos

$$\mu = \beta_0 + \beta_1 mae + \beta_2 menina$$

- Meninos (menina = 0):
$$\mu = \beta_0 + \beta_1 mae$$
- Meninas (menina = 1):
$$\mu = [\beta_0 + \beta_2] + \beta_1 mae$$
- β_2 : diferença entre meninas e meninos com mães de mesma altura.
- Diferenças **aditivas**: retas paralelas.




23 / 66

E com três níveis?

Objeto datasets::PlantGrowth :

Peso seco de plantas em três grupos experimentais (controle, tratamento 1 e 2) com 10 plantas por grupo:


	weight	group
1	4.17	ctrl
2	5.58	ctrl
11	4.81	trt1
12	4.17	trt1
21	6.31	trt2
22	5.12	trt2



Que números atribuir a cada grupo?

24 / 66

Uma nova variável com valores 0, 1, 2 ?



Codificar em uma única variável impõe: (i) uma **ordem** e **distâncias iguais** entre os grupos, (ii) relação linear com as categorias. O modelo muda com os rótulos e ignora diferenças não monotônicas entre grupos.

25 / 66

Ajuste do modelo

Cria as variáveis indicadoras

```
> pg$x1 <- ifelse(pg$group == "ctrl", 1, 0)
> pg$x2 <- ifelse(pg$group == "trt1", 1, 0)
> pg$x3 <- ifelse(pg$group == "trt2", 1, 0)
```

Especifica o modelo

```
> m.ind.f <- alist(
+   weight ~ dnorm(mu, exp(lsigma)),
+   mu <- b1 * x1 + b2 * x2 + b3 * x3
+ )
```

Ajuste

```
> m.ind <- quap(m.ind.f, data = pg, start = list(b1 = 5, b2 = 5, b3 = 5, lsigma = 0))
```

27 / 66

Solução: uma variável para cada nível

Três variáveis binárias (0 , 1), indicando cada nível do fator

grupo	x ₁	x ₂	x ₃
Controle	1	0	0
Tratamento 1	0	1	0
Tratamento 2	0	0	1

Como fica o preditor $\mu = \beta_1x_1 + \beta_2x_2 + \beta_3x_3$

- Controle : $\mu = \beta_1 \times 1 + \beta_2 \times 0 + \beta_3 \times 0 = \beta_1$
- Tratamento 1 : $\mu = \beta_1 \times 0 + \beta_2 \times 1 + \beta_3 \times 0 = \beta_2$
- Tratamento 2 : $\mu = \beta_1 \times 0 + \beta_2 \times 0 + \beta_3 \times 1 = \beta_3$

Cada coeficiente é a média de um grupo.

26 / 66

Ajuste do modelo: estimativas

```
> precis(m.ind)

              mean      sd      5.5%      94.5%
b1      5.0319607 0.1870121  4.7330792  5.3308421
b2      4.6610357 0.1870121  4.3621542  4.9599171
b3      5.5260304 0.1870121  5.2271490  5.8249119
lsigma -0.5252895 0.1290991 -0.7316149 -0.3189641
```

Médias dos grupos

```
> tapply(pg$weight, pg$group, mean)

ctrl trt1 trt2
5.032 4.661 5.526
```

28 / 66

O mesmo modelo, com uma variável índice

No *rethinking* podemos usar uma variável que atribui um índice numérico a cada nível do fator. Cada nível tem seu próprio coeficiente, como no modelo com variáveis indicadoras:

```
> pg$g <- factor(pg$group)|> as.integer() # ctrl = 1, trt1 = 2, trt2 = 3
> head(pg[, c("group", "g", "weight")])
```

	group	g	weight
1	ctrl	1	4.17
2	ctrl	1	5.58
3	ctrl	1	5.18
4	ctrl	1	6.11
5	ctrl	1	4.50
6	ctrl	1	4.61

Fórmula do modelo com a notação `b[índice]`:

```
> m.ind.f2 <- alist(
+   weight ~ dnorm(mu, exp(lsigma)),
+   mu <- b[g]
+ )
```

E se incluirmos um intercepto?

- Intercepto: constante numérica no preditor linear (β_0)
- Útil como valor de referência em comparações
- Com mais de uma preditora categórica, apenas uma pode ter uma variável para cada nível

$$\mu = \beta_0 + \beta_1x_1 + \beta_2x_2 + \beta_3x_3$$

Se apenas adicionamos um intercepto, temos um coeficiente a mais que o número de grupos (quatro coeficientes para três médias). Há infinitas maneiras de descrever as médias dos grupos:

Solução	β_0	β_1	β_2	β_3
A	0	5.03	4.66	5.53
B	5	0.03	-0.34	0.53
C	10	-4.97	-5.34	-4.47

Portanto, com intercepto, bastam $k - 1$ variáveis. Mas que valores colocar nelas?

O mesmo modelo, com uma variável índice

Ajuste:

```
> m.idx <- quap(m.ind.f2, data = pg,
+   start = list(b = rep(5, 3), lsigma = 0))
> precis(m.idx, depth = 2)
```

	mean	sd	5.5%	94.5%
b[1]	5.0319607	0.1870121	4.7330792	5.3308421
b[2]	4.6610357	0.1870121	4.3621542	4.9599171
b[3]	5.5260304	0.1870121	5.2271490	5.8249119
lsigma	-0.5252895	0.1290991	-0.7316149	-0.3189641

Contrastes

Contraste: regra para reescrever as k médias como um intercepto e $k - 1$ coeficientes, associados a $k - 1$ variáveis numéricas, que chamaremos de c_i .

$$\mu = \beta_0 + \beta_1c_1 + \beta_2c_2$$

grupo	c_1	c_2
ctrl	0	0
trt1	1	0
trt2	0	1

- O contraste é expresso por uma **matriz** com os níveis da variável categórica nas linhas, e as variáveis c_i nas colunas. Esta matriz tem sempre uma coluna a menos que o número de linhas.
- Contrastes diferentes dão as **mesmas médias** e a **mesma verossimilhança**.
- O que muda é o **significado dos coeficientes**.
- O que permite usar os coeficientes para responder a diferentes **perguntas**.

Contraste de controle

$$\mu = \beta_0 + \beta_1 c_1 + \beta_2 c_2$$

grupo	c ₁	c ₂	μ
ctrl	0	0	β ₀
trt1	1	0	β ₀ + β ₁
trt2	0	1	β ₀ + β ₂

- β₀ = μ_{ctrl}
- β₁ = μ_{trt1} - μ_{ctrl}
- β₂ = μ_{trt2} - μ_{ctrl}

Cada coeficiente é a diferença de um grupo em relação ao grupo de **referência**.
A média do grupo de referência equivale ao intercepto β₀
A coluna **menina** do exemplo do Galton era um contraste de controle, com os meninos como referência.

Exemplo de ajuste com contraste de controle

Ajusta o modelo

```
> ## Valores iniciais
> inicio <- list(b0 = 5, b1 = 0, b2 = 0, lsigma = 0)
> ## Ajuste
> m.trat <- quap(f.contr, data = pg, start = inicio)
> ## Estimativas
> precis(m.trat)
```

	mean	sd	5.5%	94.5%
b0	5.0319936	0.1870100	4.73311549	5.33087161
b1	-0.3709760	0.2644720	-0.79365342	0.05170139
b2	0.4939948	0.2644720	0.07131739	0.91667220
lsigma	-0.5253008	0.1290977	-0.73162382	-0.31897773

Exemplo de ajuste com contraste de controle

Adicionamos as variáveis c₁ e c₂ aos dados

```
> pg <- mutate(pg,
+               c1 = case_match(group, "ctrl" ~ 0, "trt1" ~ 1, "trt2" ~ 0),
+               c2 = case_match(group, "ctrl" ~ 0, "trt1" ~ 0, "trt2" ~ 1))
```

Especifica o modelo

```
> f.contr <- alist(weight ~ dnorm(mu, exp(lsigma)),
+                  mu <- b0 + b1 * c1 + b2 * c2)
```

Contraste de soma

$$\mu = \beta_0 + \beta_1 c_1 + \beta_2 c_2$$

grupo	c ₁	c ₂	μ
ctrl	1	0	β ₀ + β ₁
trt1	0	1	β ₀ + β ₂
trt2	-1	-1	β ₀ - β ₁ - β ₂

- β₀ = $\frac{\mu_{ctrl} + \mu_{trt1} + \mu_{trt2}}{3}$
- β₁ = μ_{ctrl} - β₀
- β₂ = μ_{trt1} - β₀

Cada coeficiente é o desvio de um grupo em relação à **média das médias**.
O desvio do último grupo não tem coeficiente próprio: é -(β₁ + β₂).

Contraste de soma

Ajuste do modelo

```
> pg <- mutate(pg,
+               c1 = case_match(group, "ctrl" ~ 1, "trt1" ~ 0, "trt2" ~ -1),
+               c2 = case_match(group, "ctrl" ~ 0, "trt1" ~ 1, "trt2" ~ -1))
> m.soma <- quap(f.contr, pg, start = inicio)
> precis(m.soma)
```

	mean	sd	5.5%	94.5%
b0	5.07300094	0.1079720	4.9004408	5.2455610
b1	-0.04099719	0.1526955	-0.2850340	0.2030396
b2	-0.41199771	0.1526955	-0.6560345	-0.1679609
lsigma	-0.52528473	0.1290998	-0.7316111	-0.3189584

Média das médias:

```
> mean(tapply(pg$weight, pg$group, mean))
```

[1] 5.073

Contraste de Helmert

Ajuste do modelo

```
> pg <- mutate(pg,
+               c1 = case_match(group, "trt1" ~ -1/2, "trt2" ~ 1/2, "ctrl" ~ 0),
+               c2 = case_match(group, "trt1" ~ -1/3, "trt2" ~ -1/3, "ctrl" ~ 2/3))
> m.helm <- quap(f.contr, data = pg, start = inicio)
> precis(m.helm)
```

	mean	sd	5.5%	94.5%
b0	5.07297974	0.1079743	4.9004160	5.2455435
b1	0.86508587	0.2644818	0.4423928	1.2877789
b2	-0.06150705	0.2290480	-0.4275700	0.3045559
lsigma	-0.52526376	0.1291025	-0.7315944	-0.3189331

Contraste de Helmert

Cada grupo comparado com a média dos grupos anteriores. Com a ordem trt1, trt2, ctrl:

$$\mu = \beta_0 + \beta_1 c_1 + \beta_2 c_2$$

grupo	c ₁	c ₂	μ
trt1	-1/2	-1/3	β ₀ - 1/2 β ₁ - 1/3 β ₂
trt2	1/2	-1/3	β ₀ + 1/2 β ₁ - 1/3 β ₂
ctrl	0	2/3	β ₀ + 2/3 β ₂

- β₀ = média das médias
- β₁ = μ_{trt2} - μ_{trt1}
- β₂ = μ_{ctrl} - (μ_{trt1} + μ_{trt2}) / 2

β₁: os tratamentos diferem entre si? β₂: o controle difere da média dos tratamentos?

O mesmo modelo, colunas diferentes

	β ₀	β ₁	β ₂	μ _{ctrl}	μ _{trt1}	μ _{trt2}	log-verossim.
Controle	5.03	-0.37	0.49	5.03	4.66	5.53	-26.81
Soma	5.07	-0.04	-0.41	5.03	4.66	5.53	-26.81
Helmert	5.07	0.87	-0.06	5.03	4.66	5.53	-26.81

Mesma fórmula no quap(), mesmas médias, mesma verossimilhança. Só mudam os números nas colunas e, com eles, o significado dos coeficientes.

Contrastes na sintaxe de modelos do R

```
> gal$Gender <- relevel(factor(gal$Gender), ref = "M")
> lm(Height ~ mae + Gender, data = gal) |> coef()
```

```
(Intercept)      mae  GenderF
70.4416397    0.3487784 -5.1542925
```

Agora **GenderF** é o mesmo β_2 do **quap()**: o R construiu a mesma coluna que fizemos à mão.

Fatores no **lm()**

```
> lm(Height ~ mae + Gender, data = gal) |> coef()
```

```
(Intercept)      mae  GenderM
65.2873472    0.3487784   5.1542925
```

- O coeficiente se chama **GenderM** e tem o sinal trocado em relação ao β_2 que usamos para ajustar o modelo com a função **rethinking::quap()**.
- O R fez a codificação sozinho, com o **contraste de controle**.
- A referência é o primeiro nível do fator, em ordem alfabética: "F".

Mudando a referência: **relevel()**

As matrizes de contraste no R

```
> contrasts(pg$group)
```

```
      trt1 trt2
ctrl    0    0
trt1    1    0
trt2    0    1
```

```
> contr.sum(3)
```

```
  [,1] [,2]
1     1     0
2     0     1
3    -1    -1
```

```
> contr.helmert(3)
```

```
  [,1] [,2]
1    -1    -1
2     1    -1
3     0     2
```

Controle e soma: os mesmos valores de c_1 e c_2 que usamos com o **quap()**.

Helmert: os mesmos sinais, mas valores inteiros ($-1, 1, 0$ e $-1, -1, 2$). Com **contr.helmert()** os coeficientes ficam divididos por 2 e por 3: $\beta_1/2$ e $\beta_2/3$.

Ajuste de modelos com os diferentes contrastes

```
> lm(weight ~ group, data = pg) |> coef()

(Intercept)  grouptrt1  grouptrt2
      5.032      -0.371       0.494

> lm(weight ~ group, data = pg,
+   contrasts = list(group = "contr.sum")) |> coef()

(Intercept)    group1    group2
      5.073     -0.041     -0.412

> pg$group.h <- factor(pg$group, levels = c("trt1", "trt2", "ctrl"))
> lm(weight ~ group.h, data = pg,
+   contrasts = list(group.h = "contr.helmert")) |> coef()

(Intercept)  group.h1  group.h2
      5.0730      0.4325     -0.0205
```

Síntese

Contraste	No R	Intercepto	Coefficientes
Controle	<code>contr.treatment</code> (padrão)	média do grupo de referência	diferença de cada grupo para a referência
Soma	<code>contr.sum</code>	média das médias	desvio de cada grupo (menos o último) para a média das médias
Helmert	<code>contr.helmert</code>	média das médias	cada grupo contra a média dos anteriores (em escala)

O contraste não é uma propriedade dos dados: é uma escolha, guiada pelas perguntas que queremos que os coeficientes respondam. Muito usado em análise de dados experimentais.

O que o R faz nos bastidores: `model.matrix()`

As colunas que o R gera a partir da definição de contrastes, para uma planta de cada grupo:

```
> model.matrix(~ group, data = pg,
+   contrasts.arg = list(group = "contr.sum"))[c(1, 11, 21), ]

(Intercept) group1 group2
1           1      1      0
11          1      0      1
21          1     -1     -1
```

As mesmas colunas c_1 e c_2 que passamos ao `quap()`.

Interações

Modelos lineares múltiplos com interações

- O preditor inclui variáveis que são produtos de pelo menos outras duas presentes no modelo, por exemplo:

$$\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2$$

- Se a variável independente X_1 aumenta em uma unidade, o preditor aumenta em $\beta_1 + \beta_3 X_2$.
- Ou seja, diferenças da resposta associadas a uma preditora dependem do valor de outra(s). Há uma **interação** estatística.

Exemplo de preditor linear com uma interação


Duas predictoras:

- X_1 : altura da mãe (mae), contínua
- X_2 : gênero binário atribuído (**menina**: menino = 0, menina = 1)

Preditor:

- expressão:** $\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2$
- meninos:** $\beta_0 + \beta_1 X_1 + \beta_2 \times 0 + \beta_3 X_1 \times 0 = \beta_0 + \beta_1 X_1$
- meninas:** $\beta_0 + \beta_1 X_1 + \beta_2 \times 1 + \beta_3 X_1 \times 1 = [\beta_0 + \beta_2] + [\beta_1 + \beta_3] X_1$

Gráfico do exemplo com interação



Cálculo de previstos e interpretação de coeficientes

Valores previstos: um caso

Filha de mãe com 1 polegada acima da média :

$$\begin{aligned}\mu &= \beta_0 + \beta_1 \text{ mae} + \beta_2 \text{ menina} \\ \mu &= 70.44 + 0.35 \times 1 + (-5.15) \times 1 \\ \mu &= 65.64 \text{ polegadas}\end{aligned}$$

No R:

```
> (cf <- coef(m.gal))

      b0      b1      b2    lsigma
70.4409495  0.3486614 -5.1500658  0.8836568

> cf["b0"] + cf["b1"] * 1 + cf["b2"] * 1

      b0
65.63955
```

Valores previstos: multiplicação de matrizes

Matriz do modelo $\mathbf{X}$: uma linha para cada caso e uma coluna para cada coeficiente. A primeira coluna é sempre 1 (o intercepto); as demais têm os valores das preditoras (**mae** e **menina**).

$$\underbrace{\begin{bmatrix} 1.0 & 1.0 & 0.0 \\ 1.0 & 1.5 & 0.0 \\ 1.0 & 1.0 & 1.0 \\ 1.0 & 1.5 & 1.0 \end{bmatrix}}_{\mathbf{X}}$$

Valores previstos para vários casos

Gênero	Altura da mãe (in)	mae (centrada)	menina	Altura prevista (in)
Menino	64.98	1.0	0	70.79
Menino	65.48	1.5	0	70.96
Menina	64.98	1.0	1	65.64
Menina	65.48	1.5	1	65.81

Cada linha: $\mu = \beta_0 + \beta_1 \text{ mae} + \beta_2 \text{ menina}$, com os valores de **mae** e **menina** daquela linha.

Valores previstos: multiplicação de matrizes

A multiplicação da matriz do modelo pelo vetor-coluna de coeficientes da regressão resulta em um vetor-coluna com os valores previstos.

$$\mathbf{X} \boldsymbol{\beta} = \boldsymbol{\mu}$$
$$\underbrace{\begin{bmatrix} 1.0 & 1.0 & 0.0 \\ 1.0 & 1.5 & 0.0 \\ 1.0 & 1.0 & 1.0 \\ 1.0 & 1.5 & 1.0 \end{bmatrix}}_{\mathbf{X}} \cdot \underbrace{\begin{bmatrix} 70.44 \\ 0.35 \\ -5.15 \end{bmatrix}}_{\boldsymbol{\beta}} = \underbrace{\begin{bmatrix} 70.79 \\ 70.96 \\ 65.64 \\ 65.81 \end{bmatrix}}_{\boldsymbol{\mu}}$$

Cálculo de valores previstos com o *rethinking*

1. Crie uma tabela com os valores de X_i

```
> ## Grade de valores das preditoras
> grade <- expand.grid(
+   mae = seq(min(gal$mae),
+             max(gal$mae),
+             length.out = 50),
+   menina = c(0, 1)
+ )
```

	mae	menina
1	-5.984264	0
2	-5.729162	0
3	-5.474060	0
4	-5.218958	0
5	-4.963856	0
96	5.495328	1
97	5.750430	1
98	6.005532	1
99	6.260634	1
100	6.515736	1

Funções que facilitam criar grades de previsão: `base::expand.grid()`, `tidyr::expand_grid()`, `tidyr::crossing()`, `tidyr::expand()`, `modelr::data_grid()`, `marginaleffects::datagrid()`, `emmeans::ref_grid()`

57 / 66

Valores previstos com `predict()`

O mesmo modelo ajustado com `lm()`:

```
> lm.gal <- lm(Height ~ mae + menina, data = gal)
```

Calcula previstos

```
> lm.gal.p <- predict(lm.gal, newdata = grade, interval = "confidence")
> ## Preditoras e previsão
> cbind(grade[,1:2], lm.gal.p)|> head()
```

	mae	menina	fit	lwr	upr
1	-5.984264	0	68.35446	67.41049	69.29842
2	-5.729162	0	68.44343	67.53365	69.35321
3	-5.474060	0	68.53241	67.65657	69.40824
4	-5.218958	0	68.62138	67.77921	69.46355
5	-4.963856	0	68.71035	67.90153	69.51918
6	-4.708754	0	68.79933	68.02351	69.57515

Com `interval = "prediction"`, o intervalo inclui também a variação gaussiana entre indivíduos na população (equivalente ao `sim()` do *rethinking*).

Valores previstos com o *rethinking*


2. Passe para a função `link()`

`link()` retorna `n` previstos para cada valor de X_i , usando `n` valores de β_i com variação devido à incerteza da estimativa.

```
> ## Amostras de mu para cada caso
> mu <- link(m.gal, data = grade, n=1000)
> ## 1000 amostras (linhas) para cada caso
> dim(mu)
```

```
[1] 1000 100
```

```
> ## Média e intervalo de 95%
> grade$media <- colMeans(mu)
> IC <- apply(mu, 2, PI, prob = 0.95)
> grade$inf <- IC[1, ]
> grade$sup <- IC[2, ]
```



58 / 66

Um modelo com muitos coeficientes

Especifica o modelo

```
> mgal2.f <- alist(
+   Height ~ dnorm(mu, exp(lsigma)),
+   mu <- b0 + b1 * mae + b2 * pai + b3 * menina +
+     b4 * mae * pai + b5 * mae * menina + b6 * pai * menina +
+     b7 * mae * pai * menina)
>
```

Ajusta o modelo

```
> m.gal2 <- quap(mgal2.f, data = gal,
+   start = list(b0 = mean(gal$Height),
+     b1 = 0, b2 = 0, b3 = 0, b4 = 0, b5 = 0, b6 = 0, b7 = 0,
+     lsigma = log(sd(gal$Height))))
```

59 / 66

60 / 66

Coeficientes podem ser difíceis de interpretar

```
> precis(m.gal2)
```

	mean	sd	5.5%	94.5%
b0	70.58447533	0.16138522	70.32655057	70.84240008
b1	0.28461479	0.06755261	0.17665267	0.39257691
b2	0.48410405	0.06365678	0.38236823	0.58583987
b3	-5.94251639	0.60744853	-6.91333646	-4.97169631
b4	-0.02666409	0.02641725	-0.06888397	0.01555578
b5	-0.04243042	0.27180493	-0.47682720	0.39196636
b6	-0.13094881	0.21741601	-0.47842158	0.21652397
b7	0.11678184	0.09261535	-0.03123539	0.26479906
lsigma	0.73938128	0.05037883	0.65886618	0.81989637

“The safest interpretation of a regression is as a comparison”

Gelman et al. 2020 - Regression and other stories

Previstos condicionais


Calculamos os previstos para cada combinação com `link()`

Mil amostras de μ para cada combinação de valores da grade:

```
> mu2 <- link(m.gal2, data = grade2)
```

Média e IC das amostras para cada combinação

```
> grade2$media <- colMeans(mu2)
> IC2 <- apply(mu2, 2, PI, prob = 0.95)
> grade2$inf <- IC2[1, ]
> grade2$sup <- IC2[2, ]
```



Uma solução: previstos condicionais

Começamos criando uma grade com `expand.grid` combinando:

- 50 valores de altura centrada do pai, entre **-7** e **9** polegadas
- Os dois valores de gênero atribuído ao nascer
- Dois valores de altura centrada da mãe: **-6** e **6**

```
> grade2 <- expand.grid(pai = seq(-7, 9, length.out = 50),
+                       menina = c(0, 1),
+                       mae = c(-6, 6))
```

Primeiras e últimas linhas da grade:

```
> rbind( head(grade2,2), tail(grade2,2))
```

	pai	menina	mae
1	-7.000000	0	-6
2	-6.673469	0	-6
199	8.673469	1	6
200	9.000000	1	6

Mensagens para levar para casa

- O preditor linear de modelos estatísticos: algum parâmetro da distribuição é a soma de variáveis predictoras, ponderadas por coeficientes.
- Em preditores aditivos, as diferenças na resposta devido a cada variável preditora independem dos valores das demais: a diferença é apenas de interceptos.
- Em preditores com interação, as diferenças na resposta devido a uma variável preditora dependem do valor de outra(s): há diferenças de inclinações.
- Os coeficientes de preditores lineares são condicionais: expressam as diferenças na resposta associada a diferenças nas predictoras, descontadas as diferenças devidas às outras variáveis.

Mensagens para levar para casa

- Variáveis categóricas são incluídas nos preditores como **contrastes**: $k - 1$ variáveis numéricas, em que k é o número de categorias da variável.
- Há muitas maneiras de definir contrastes, o que pode ser útil para interpretar coeficientes e/ou responder diferentes perguntas com os coeficientes.
- Uma vez ajustado o modelo, podemos usar o preditor linear para calcular valores previstos para qualquer combinação de variáveis preditoras (independentes).
- Para modelos com muitos coeficientes, os previstos em função de algumas variáveis, condicionados a outras, são um recurso importante para interpretar o modelo.

Para saber mais

- Arel-Bundock, V. (2026) Model to Meaning: How to interpret statistical models in R and Python. CRC Press. Versão online: <https://marginaleffects.com/>
- Fox, J. & Weisberg, S. (2019). An R Companion to Applied Regression. Sage.
- Fox, J., & Weisberg, S. (2018). Visualizing fit and lack of fit in complex regression models with predictor effect plots and partial residuals. Journal of statistical software, 87, 1-27.
- Gelman, A., Hill, J., & Vehtari, A. (2020). Regression and other stories. Cambridge University Press.
- McElreath, R. (2016). Statistical rethinking: A Bayesian course with examples in R and Stan (Vol. 122). Boca Raton, FL: CRC press.
- Schad, D. J., Vasishth, S., Hohenstein, S., & Kliegl, R. (2020). How to capitalize on a priori contrasts in linear (mixed) models: A tutorial. Journal of memory and language, 110, 104038.