Inferência Bayesiana I

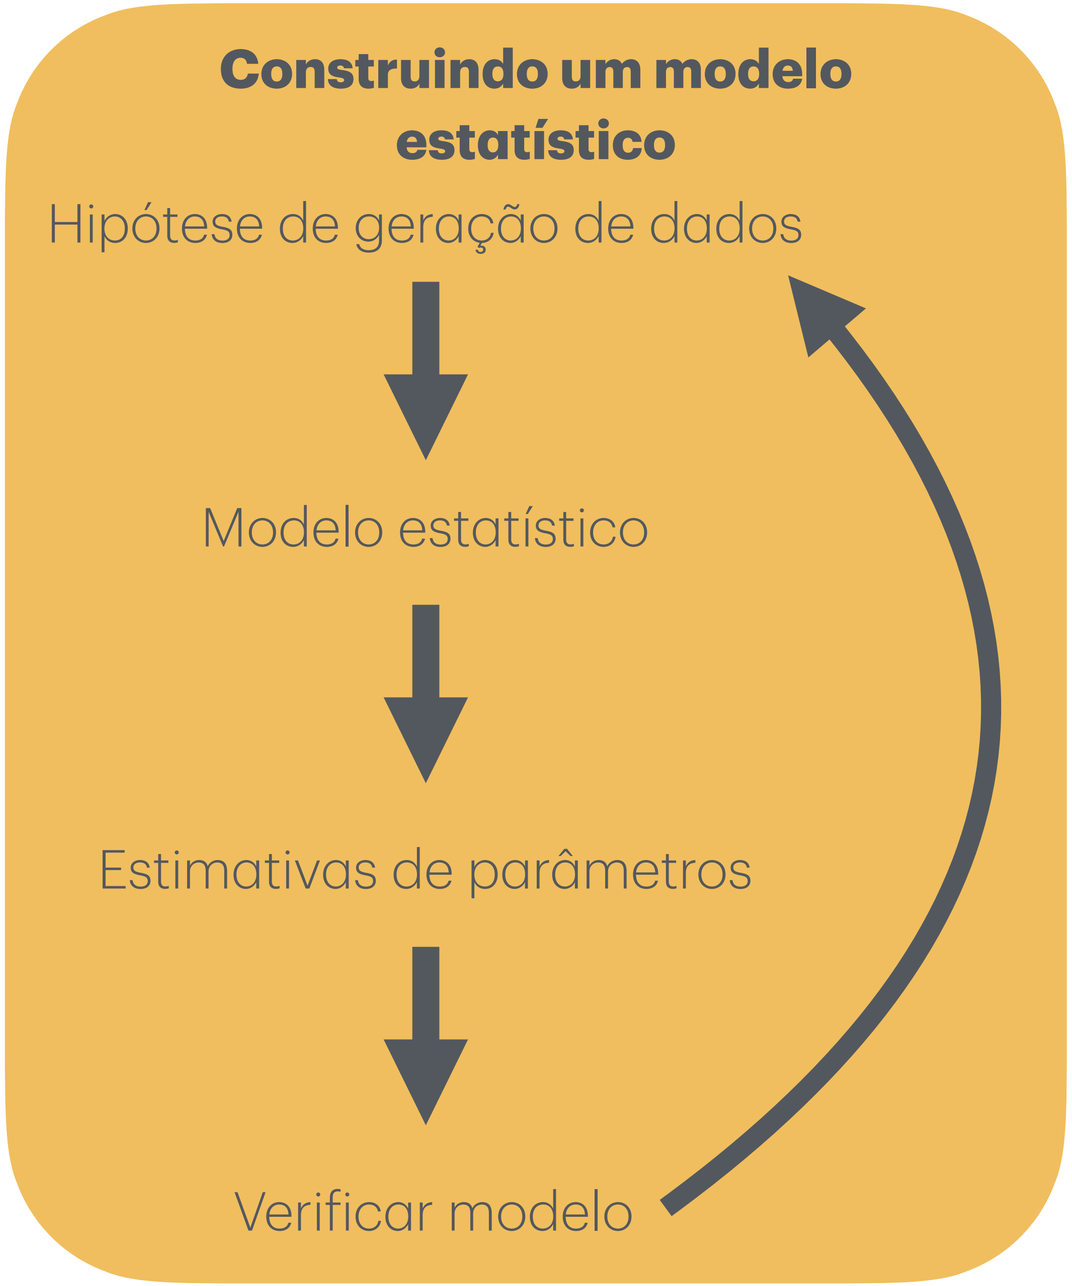
Conceitos e fundamentos

Diogo Melo - 09/10/2026

Principios de Modelagem

Nosso martelo

- Nosso modelo deve:
  - Estabelecer uma relação entre parâmetros e observações
  - Criar uma descrição probabilística do modelo de estudo
  - Essa descrição deve capturar aspectos dos dados os quais estamos interessados!



O que significa probabilidade?

As muitas faces da probabilidade

Probabilidades frequentistas.

- A probabilidade de um evento é o limite da frequência relativa num conjunto grande de experimentos.
- Probabilidade descrevem propriedades objetivas do mundo.
- A probabilidade só se aplica a eventos repetidos.

Probabilidades Cox

- Probabilidade é uma extensão da lógica formal e nos permite discutir eventos sobre os quais temos informação incompleta.
- Probabilidades descrevem nosso estado de conhecimento, não propriedades do mundo real.
- Probabilidades se aplicam para qualquer afirmação ou evento sobre o qual não temos informação completa.

Probabilidade como extensão da lógica

A implica B

A: Está chovendo

B: Há nuvens

A é verdade, então B é verdade.



O que B diz sobre A?

Se B for verdade, como a minha avaliação sobre a plausibilidade de A deveria mudar?

Quanto ela deveria mudar?

Probabilidade como extensão da lógica

A implica B

A: Está chovendo

B: Há nuvens

A é verdade, então B é verdade.



O que B diz sobre A?

Se B for verdade, como a minha avaliação sobre a plausibilidade de A deveria mudar?

Quanto ela deveria mudar?

Cox, mostrou que a função que tem as propriedades corretas pra esse tipo de operação é a probabilidade.

Jaynes, E. T. (2012). *Probability theory* (G. L. Bretthorst, Ed.). Cambridge University Press.

Cox, R. T. (1946). Probability, frequency and reasonable expectation. *American Journal of Physics*, *14*(1), 1–13.

Verossimilhança de uma observação.

- A verossimilhança nos pede para imaginar um mundo possível. E naquele mundo, atribuir probabilidades para eventos.

- Pense na verossimilhança como em uma história de ficção. Ela não diz respeito ao mundo real, mas quão consistente os eventos são com uma história.

$$P(\text{Eventos} \mid \text{Mundo presumido})$$

- Matematicamente, a verossimilhança é só uma contagem de quantas maneiras o que aconteceu poderia ter acontecido sob uma dada hipótese sobre o mundo.

- Quanto mais maneiras de produzir um determinado conjunto de dados sob uma hipótese, maior a verossimilhança atribuída àqueles dados, dada aquela hipótese.

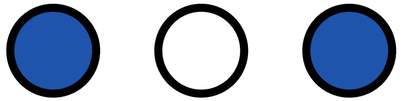
$$P(y \mid \theta)$$

Verossimilhança como contagem

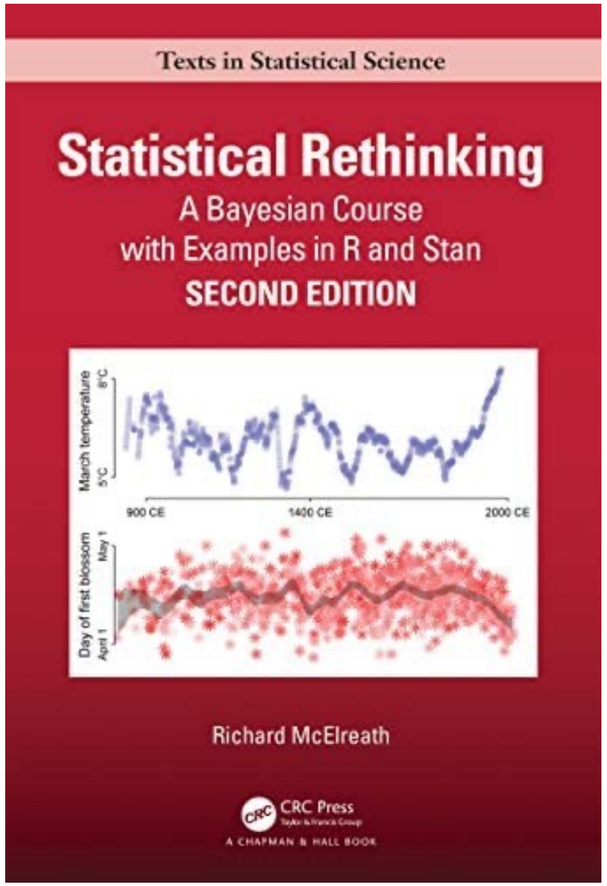
- Um estatístico criou uma urna que contém quatro bolas, azuis ou brancas.
- Cinco configurações possíveis:

(1) [○○○○], (2) [●○○○], (3) [●●○○], (4) [●●●○], (5) [●●●●]

- Nós observamos 3 amostras com reposição:



Exemplo de:

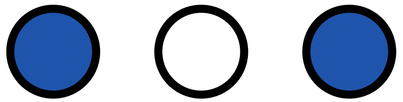


Verossimilhança como contagem

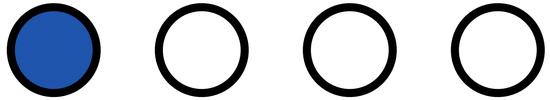
- Um estatístico criou uma urna que contém quatro bolas, azuis ou brancas.
- Cinco configurações possíveis:

(1) [○○○○], (2) [●○○○], (3) [●●○○], (4) [●●●○], (5) [●●●●]

- Nós observamos 3 amostras com reposição:



Vamos assumir a seguinte composição:

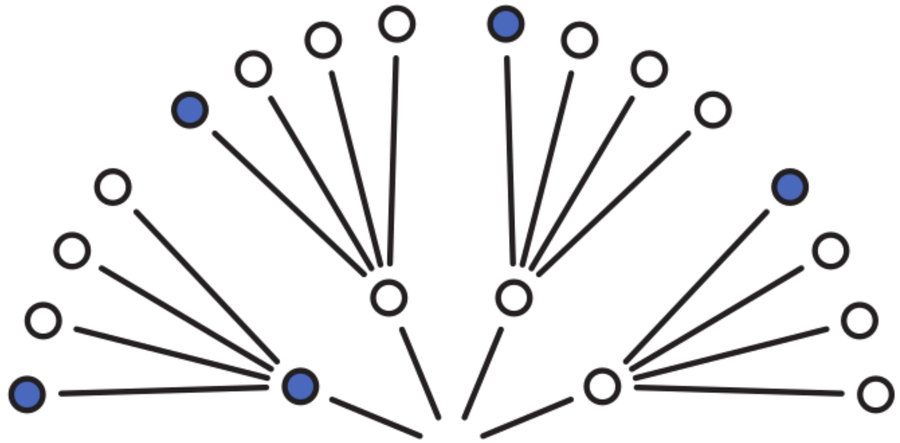


Existem 4 resultados possíveis de um sorteio:



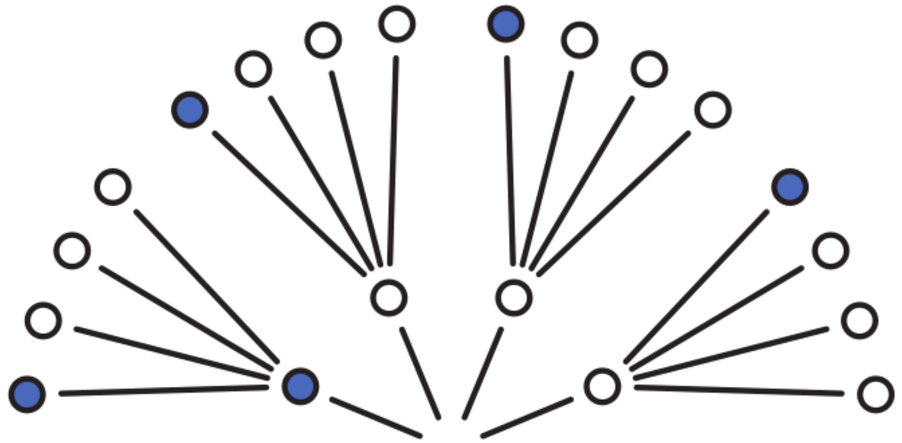
Verossimilhança como contagem

2 sorteios:

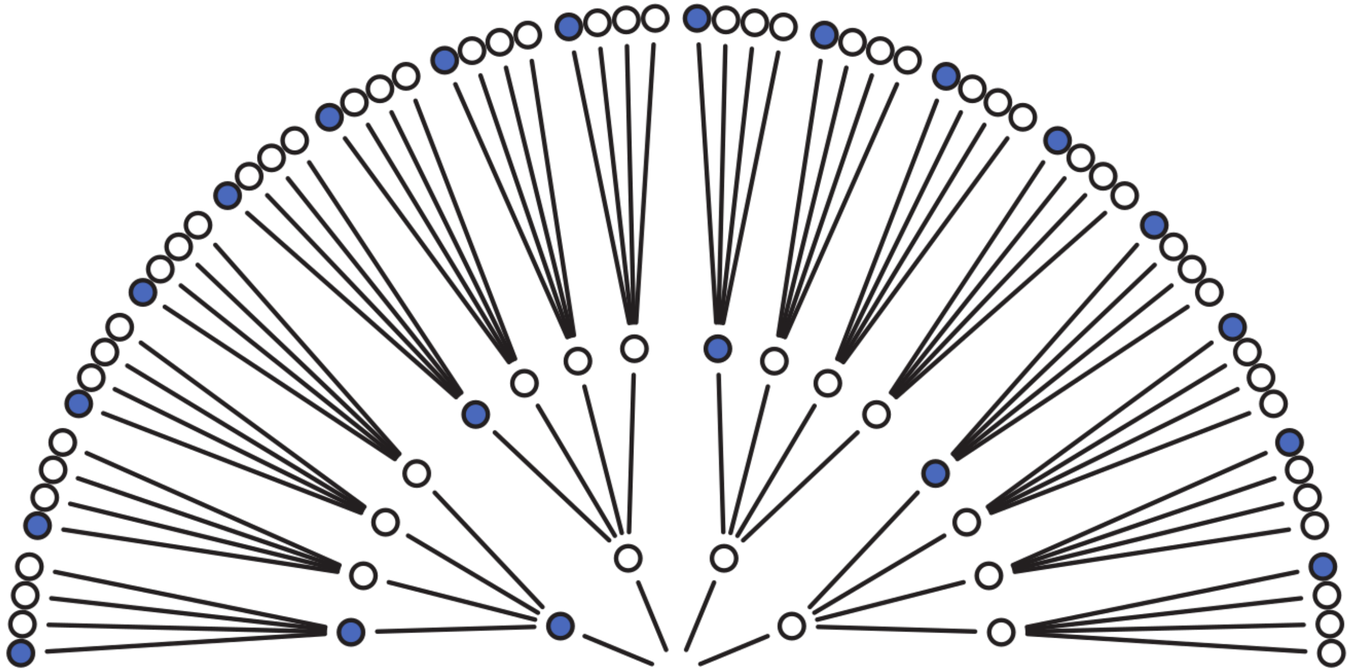


Verossimilhança como contagem

2 sorteios:

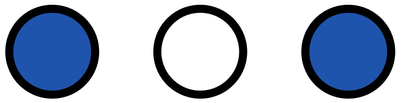


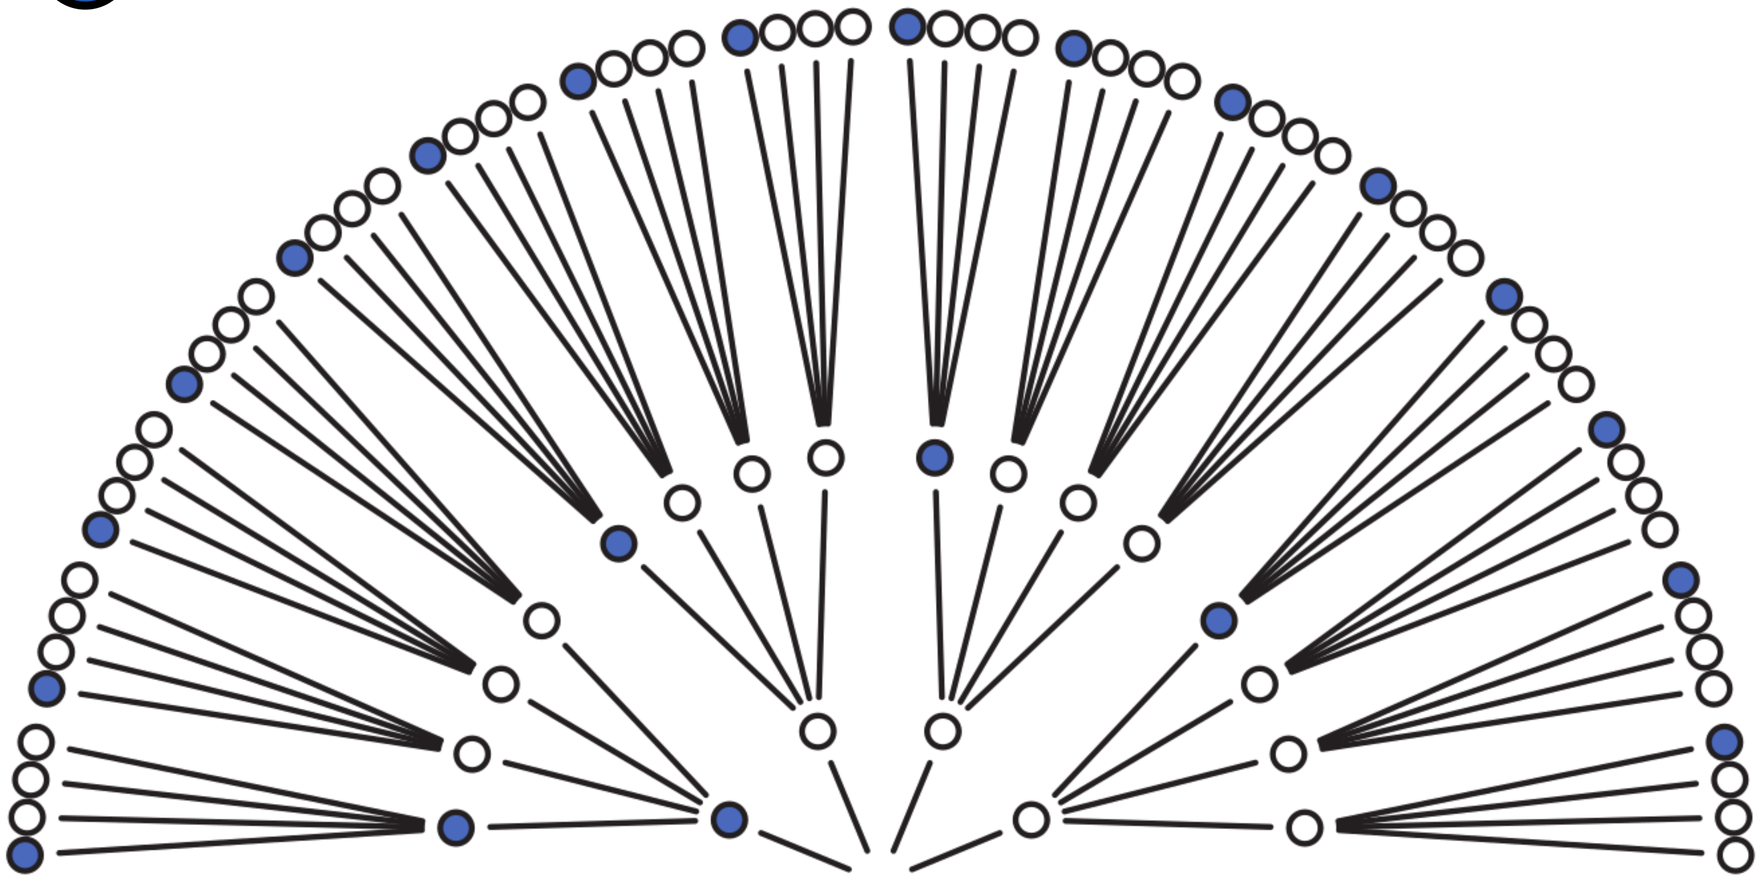
3 sorteios:



Verossimilhança como contagem

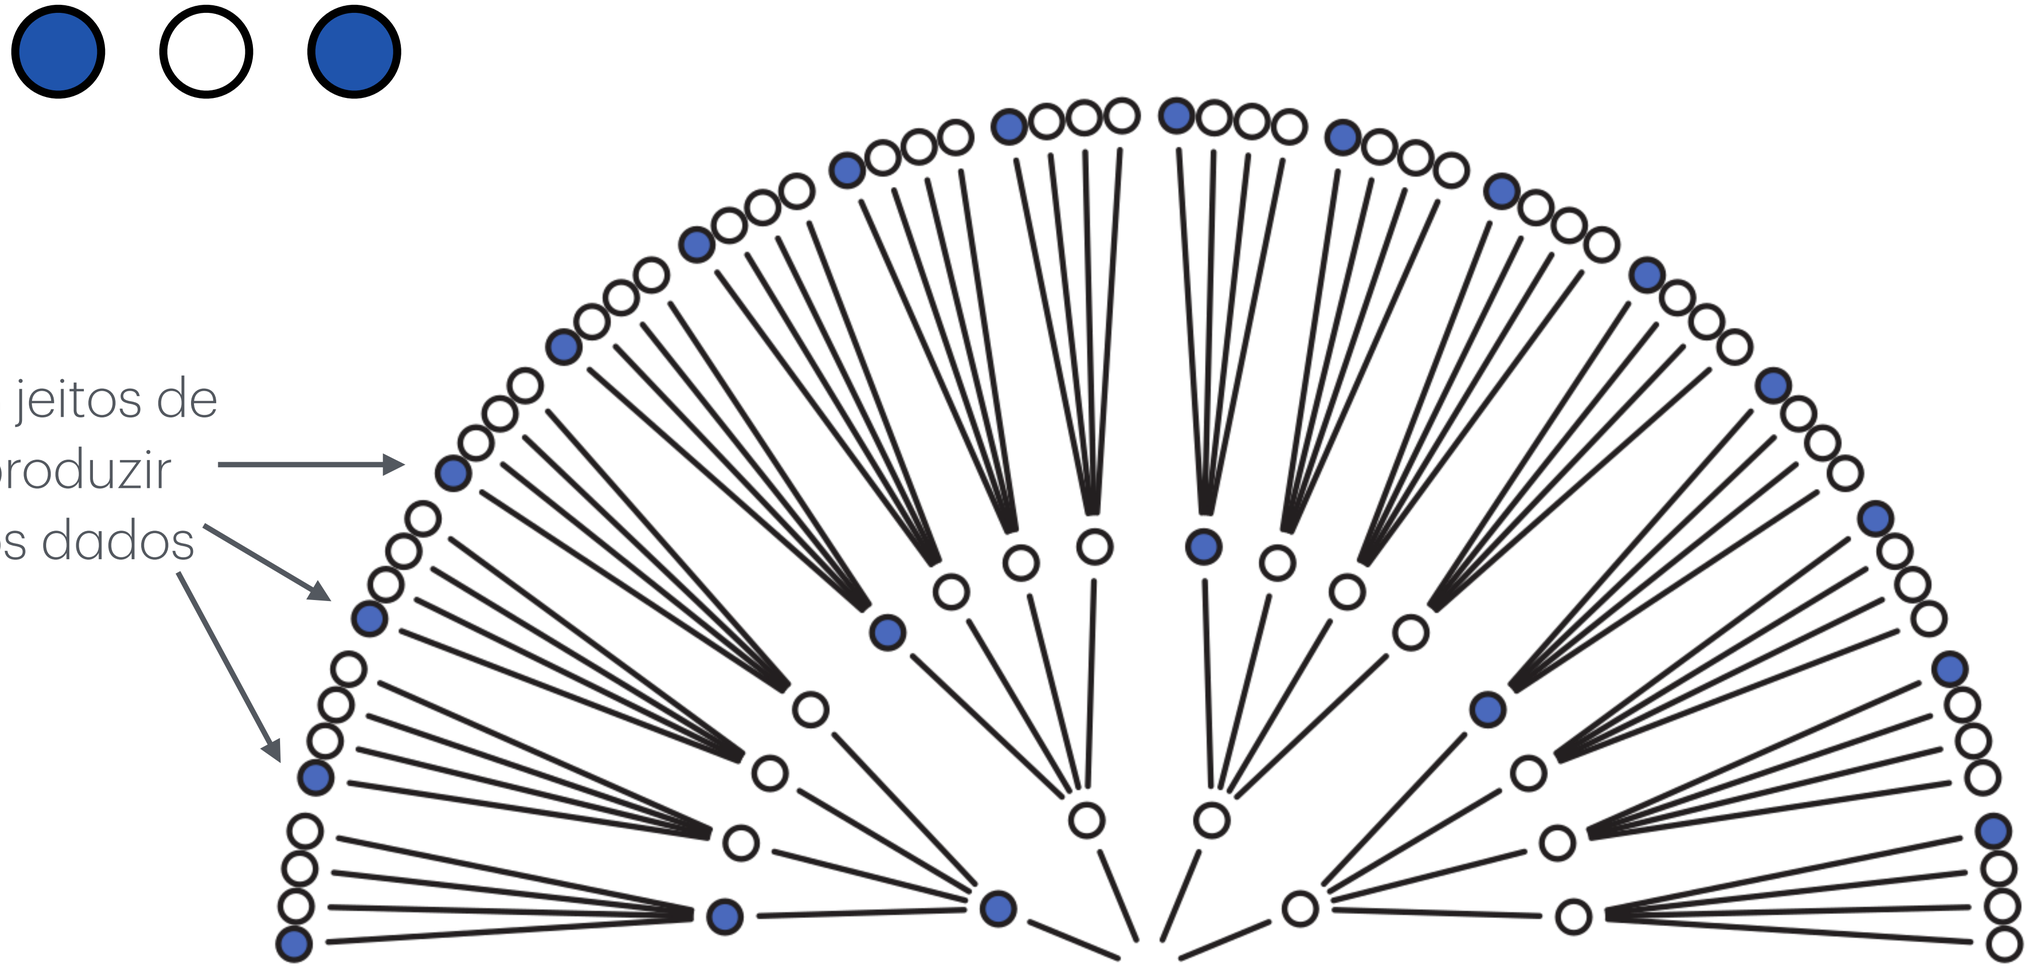
Quantos desses sorteios possíveis são compatíveis com os dados?





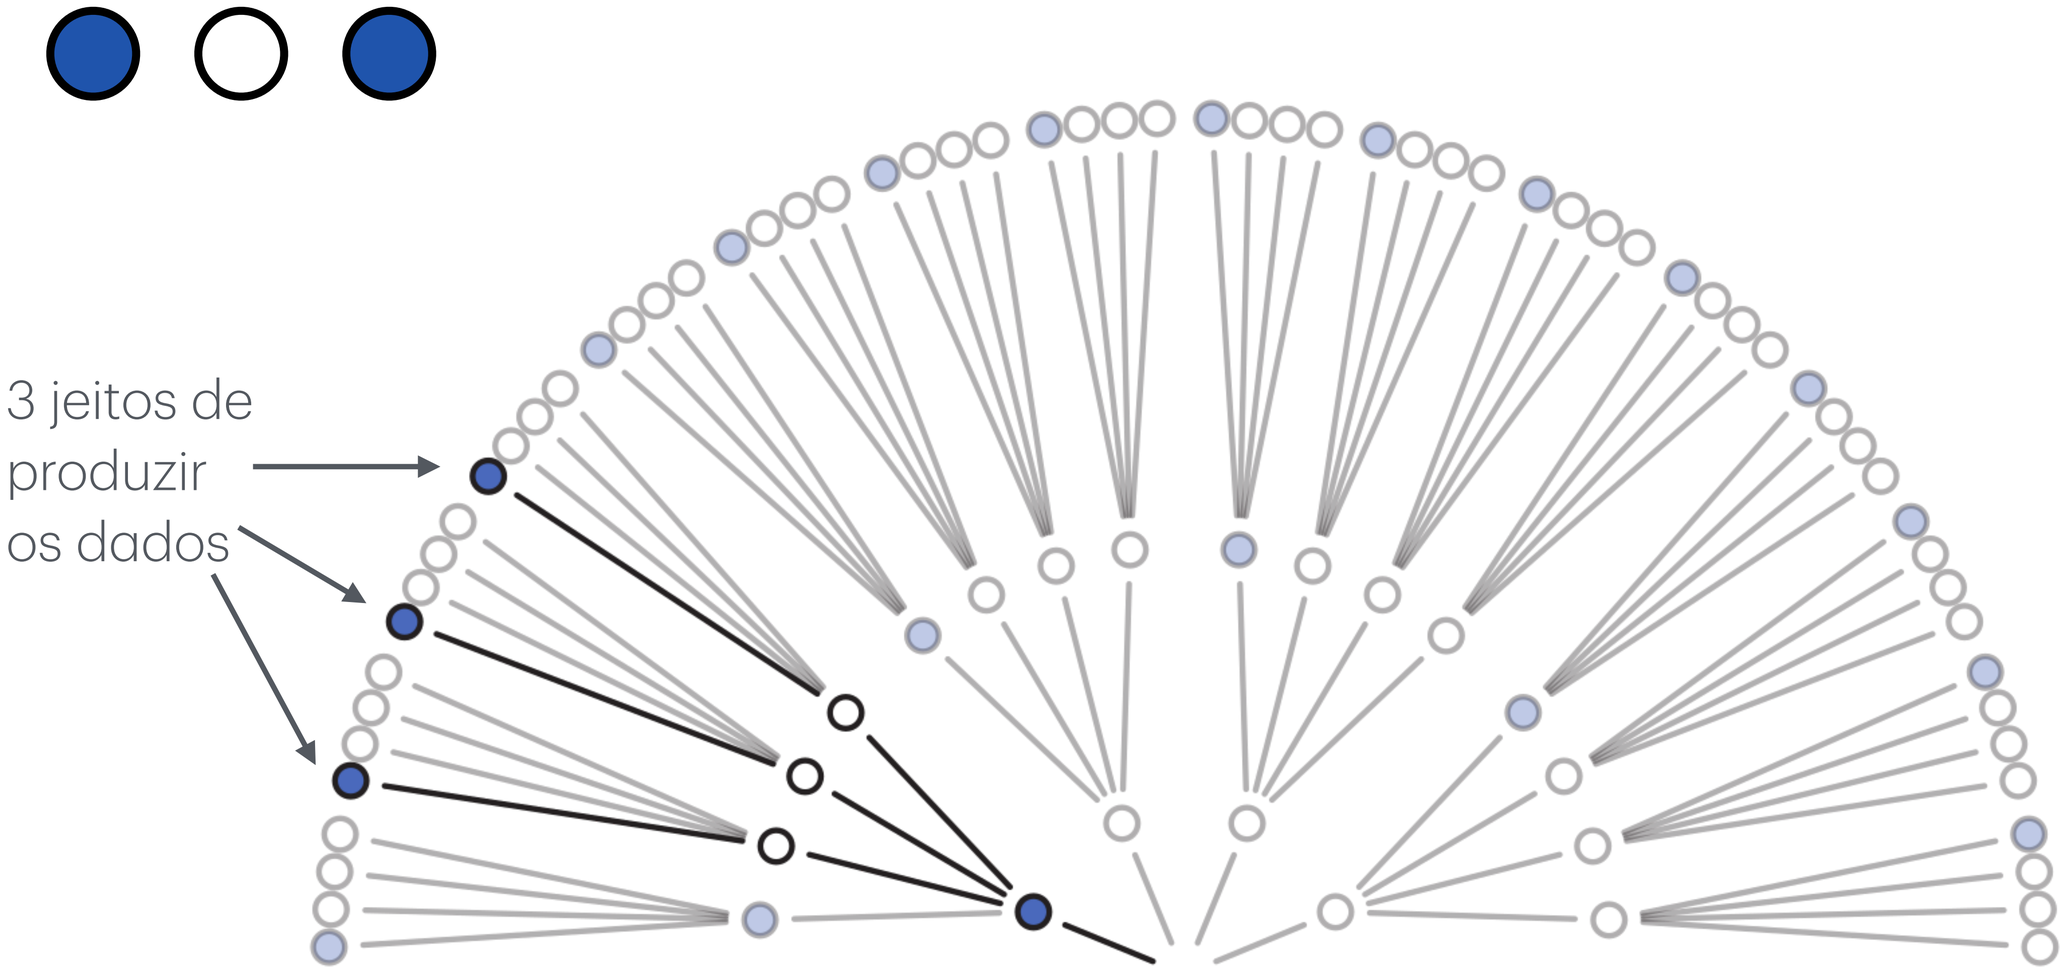
Verossimilhança como contagem

Quantos desses sorteios possíveis são compatíveis com os dados?



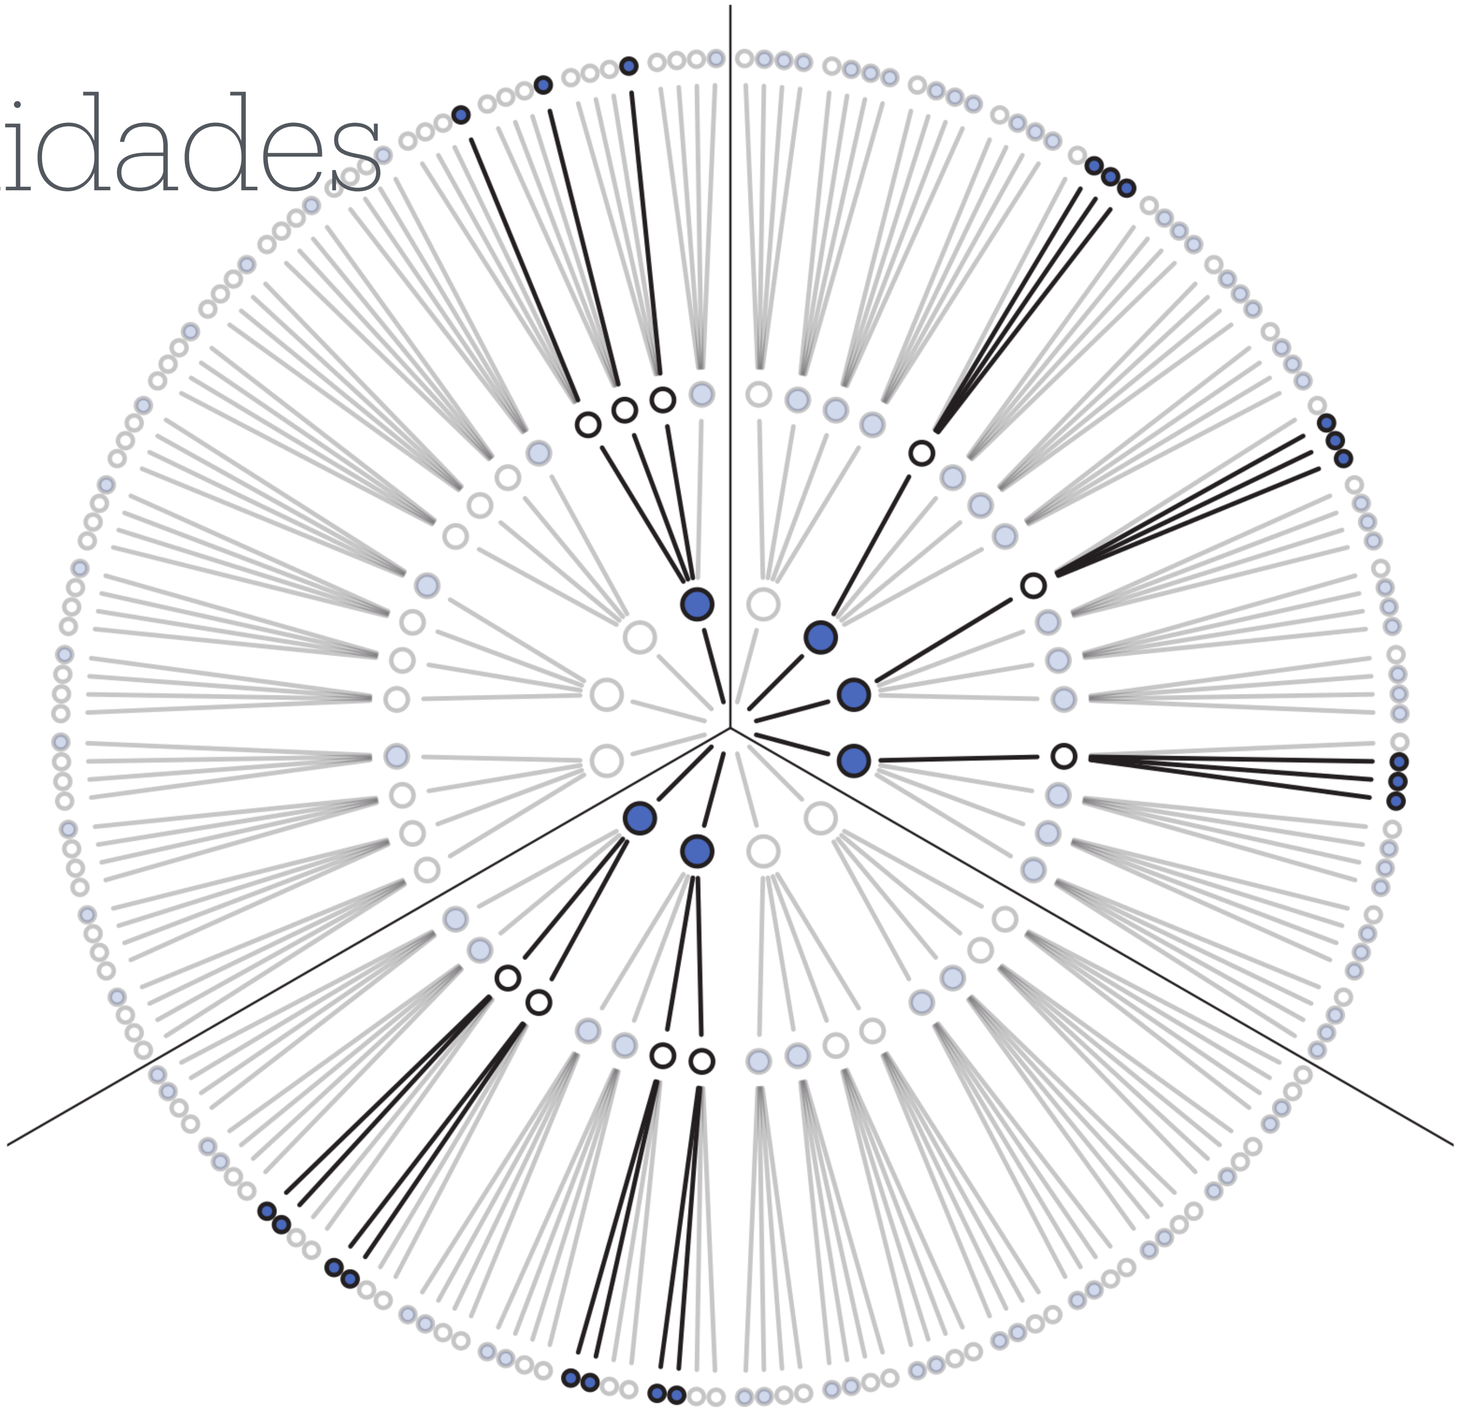
Verossimilhança como contagem

Quantos desses sorteios possíveis são compatíveis com os dados?

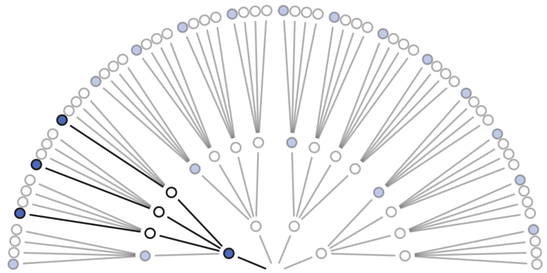


Todas as possibilidades

Conjecture	Ways to produce ●○●
[○○○○]	$0 \times 4 \times 0 = 0$
[●○○○]	$1 \times 3 \times 1 = 3$
[●●○○]	$2 \times 2 \times 2 = 8$
[●●●○]	$3 \times 1 \times 3 = 9$
[●●●●]	$4 \times 0 \times 4 = 0$



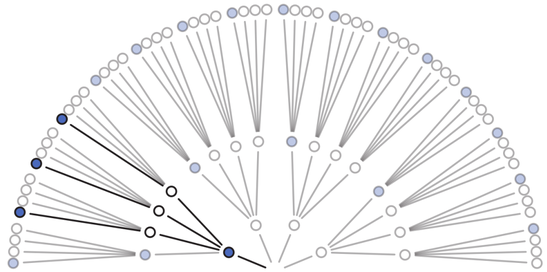
A verossimilhança é só uma contagem normalizada



Conjecture	Ways to produce ●○●
[○○○○]	$0 \times 4 \times 0 = 0$
[●○○○]	$1 \times 3 \times 1 = 3$
[●●○○]	$2 \times 2 \times 2 = 8$
[●●●○]	$3 \times 1 \times 3 = 9$
[●●●●]	$4 \times 0 \times 4 = 0$

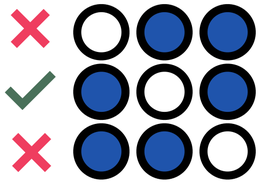
```
> 3/(4^3)
[1] 0.046875
> dbinom(2, 3, 0.25)/3
[1] 0.046875
```

A verossimilhança é só uma contagem normalizada



Conjecture	Ways to produce ●○●
[○○○○]	$0 \times 4 \times 0 = 0$
[●○○○]	$1 \times 3 \times 1 = 3$
[●●○○]	$2 \times 2 \times 2 = 8$
[●●●○]	$3 \times 1 \times 3 = 9$
[●●●●]	$4 \times 0 \times 4 = 0$

```
> 3/(4^3)
[1] 0.046875
> dbinom(2, 3, 0.25)/3
[1] 0.046875
```



A verossimilhança é só uma contagem normalizada

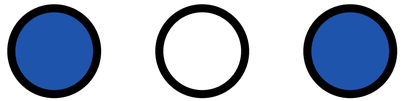
Nós usamos parâmetros para indexar essas conjecturas.

Possible composition	p	Ways to produce data	Plausibility
[○○○○]	0	0	0
[●○○○]	0.25	3	0.15
[●●○○]	0.5	8	0.40
[●●●○]	0.75	9	0.45
[●●●●]	1	0	0

Escalonamos as plausilibidades para os números serem manejáveis

E se sortearmos mais uma bola azul?

Dados anteriores:



Nova observação:



Conjecture	Ways to produce ●	Previous counts	New count
[○○○○]	0	0	$0 \times 0 = 0$
[●○○○]	1	3	$3 \times 1 = 3$
[●●○○]	2	8	$8 \times 2 = 16$
[●●●○]	3	9	$9 \times 3 = 27$
[●●●●]	4	0	$0 \times 4 = 0$

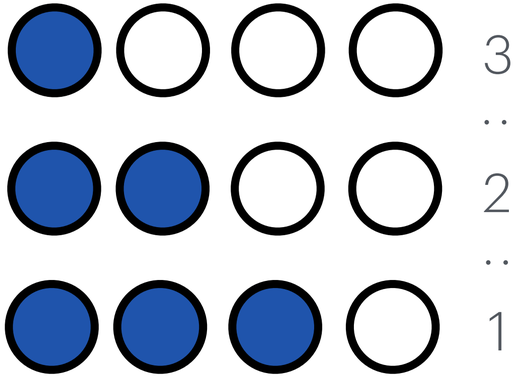
As plausibilidades novas são o produto das contagens de jeitos de produzir os dados sob cada conjectura.

E se tivermos informação de outra fonte?

Nossa urna

Dados: 

Proporções da fábrica de urnas:



Conjecture	Prior count	Factory count	New count
[○○○○]	0	0	$0 \times 0 = 0$
[●○○○]	3	3	$3 \times 3 = 9$
[●●○○]	16	2	$16 \times 2 = 32$
[●●●○]	27	1	$27 \times 1 = 27$
[●●●●]	0	0	$0 \times 0 = 0$

De novo, as plausibilidades novas são o produto das plausibilidades das nossas conjecturas com os dados que vêm da fábrica.

Juntando tudo



$$P(\theta = 0.25 \,|\, [A, B, A]) \propto P([A, B, A] \,|\, \theta = 0.25) \times P(\theta = 0.25)$$

Juntando tudo



$$P(\theta = 0.25 \mid [A, B, A]) \propto P([A, B, A] \mid \theta = 0.25) \times P(\theta = 0.25)$$

Verossimilhança: Quantos jeitos de produzir os dados sob uma dada conjectura.

Juntando tudo



$$P(\theta = 0.25 \mid [A, B, A]) \propto P([A, B, A] \mid \theta = 0.25) \times P(\theta = 0.25)$$

Verossimilhança: Quantos jeitos de produzir os dados sob uma dada conjectura.

A priori, toda a informação sobre a conjectura que não vem dos dados.

Juntando tudo



$$P(\theta = 0.25 \mid [A, B, A]) \propto P([A, B, A] \mid \theta = 0.25) \times P(\theta = 0.25)$$

Probabilidade a posteriori: contém toda a informação contida nos dados e na priori.

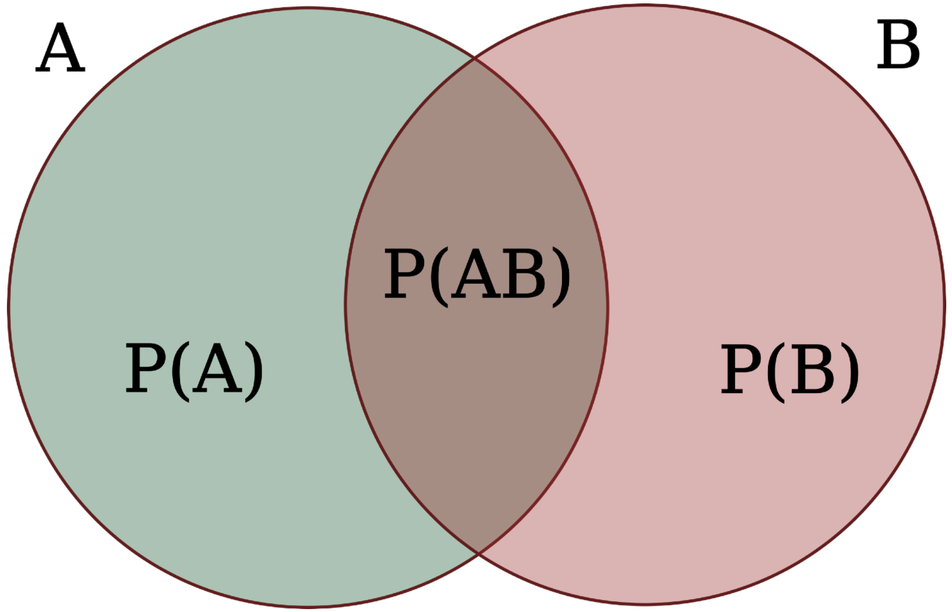
Verossimilhança: Quantos jeitos de produzir os dados sob uma dada conjectura.

A priori, toda a informação sobre a conjectura que não vem dos dados.

Rev Thomas Bayes (1701 – 1761)

Regra do produto ou Teorema de Bayes.

$$P(AB) = P(A \mid B)P(B) = P(B \mid A)P(A)$$





O que é estatística Bayesiana?

ML: Qual o valor do parâmetro que maximiza a probabilidade de gerar o conjunto de dados que observamos?

$$\underset{\theta}{\operatorname{argmax}} \left[P(y \mid \theta) \right]$$

Bayesiana: Qual a distribuição de probabilidade que descreve a nossa crença sobre os parâmetros dados os dados:

$$P(\theta \mid y) \propto P(\theta) P(y \mid \theta)$$

O que é estatística Bayesiana?

ML: Qual o valor do parâmetro que maximiza a probabilidade de gerar o conjunto de dados que observamos?

$$\underset{\theta}{\text{argmax}} \left[P(y \mid \theta) \right]$$

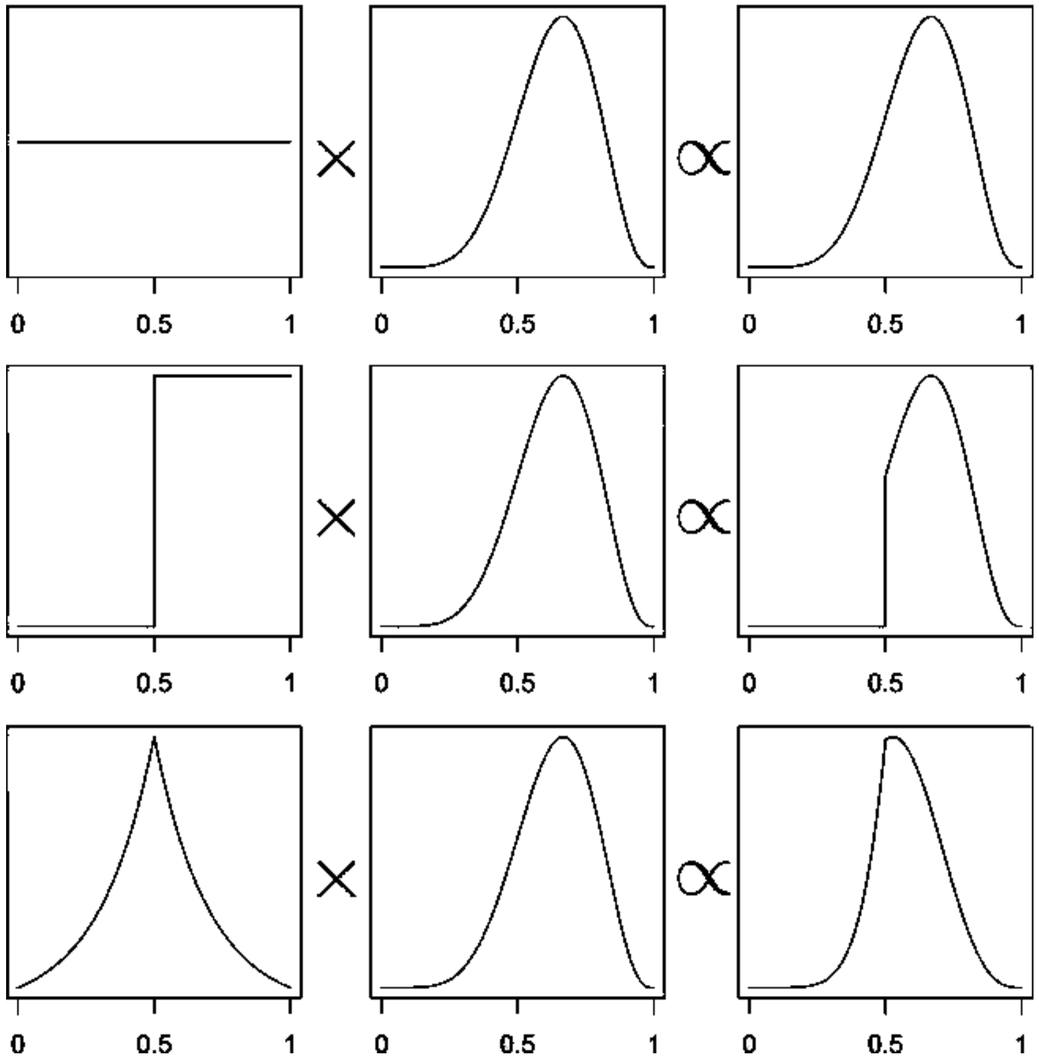
Bayesiana: Qual a distribuição de probabilidade que descreve a nossa crença sobre os parâmetros dados os dados:

$$P(\theta \mid y) \propto P(\theta) P(y \mid \theta)$$

Atenção! Sem maximização!

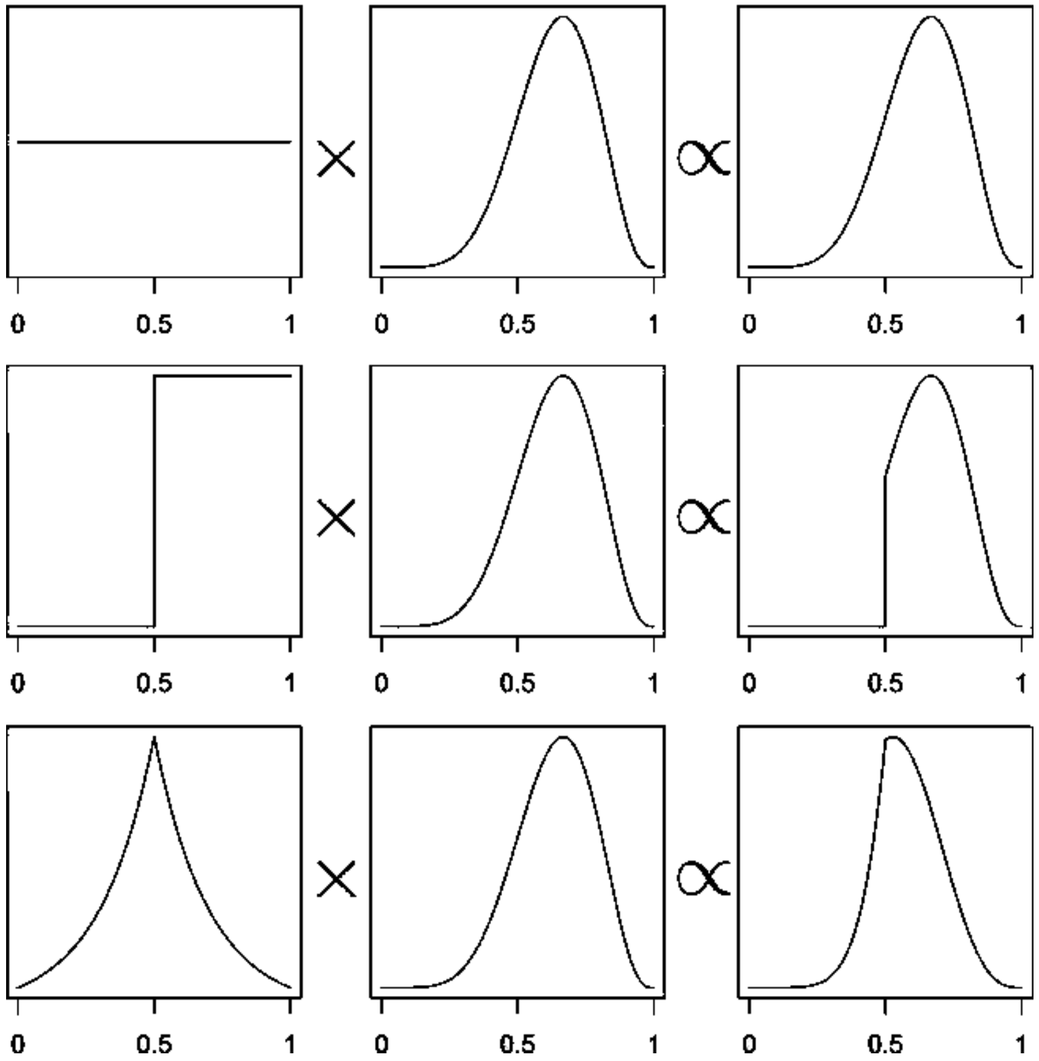
Prior × Likelihood ∝ Posterior

$$P(\theta \mid y) = \frac{P(y \mid \theta) P(\theta)}{P(y)}$$



Prior × Likelihood ∝ Posterior

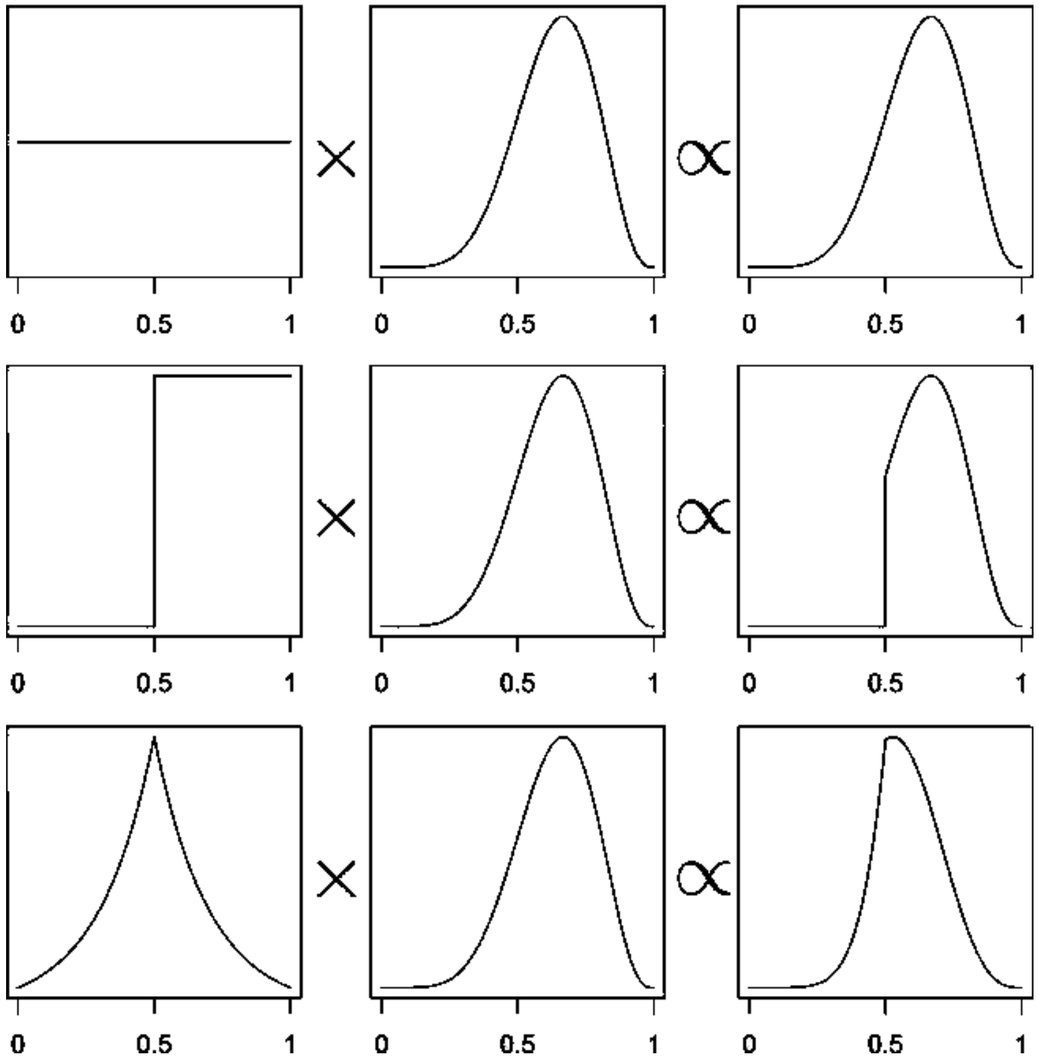
$$P(\theta \mid y) = \frac{P(y \mid \theta)P(\theta)}{P(y)}$$



- $P(\theta \mid y)$ Representa nossa informação sobre os parâmetros usando probabilidade.

Prior × Likelihood ∝ Posterior

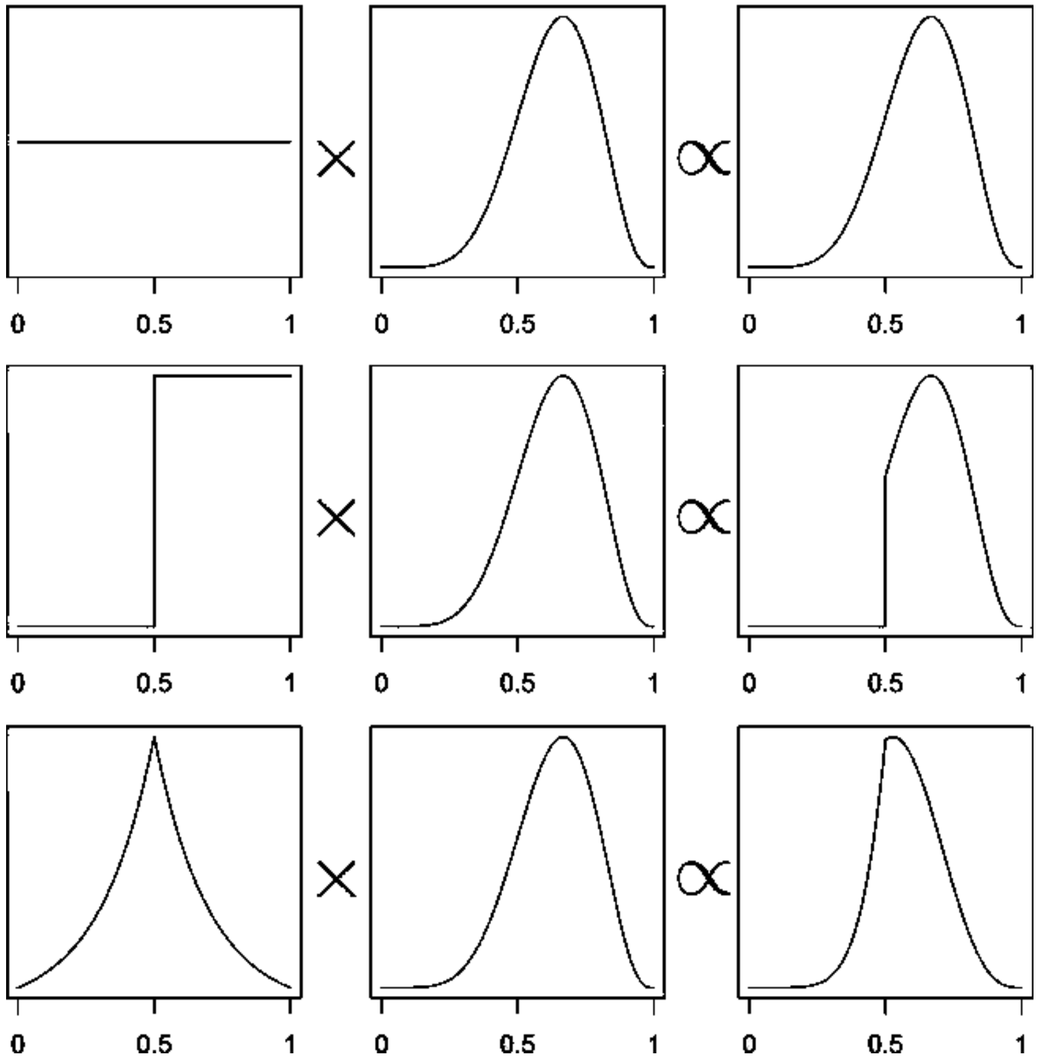
$$P(\theta \mid y) = \frac{P(y \mid \theta)P(\theta)}{P(y)}$$



- $P(\theta \mid y)$ Representa nossa informação sobre os parâmetros usando probabilidade.
  - Contém toda a informação sobre nossa crença.

Prior × Likelihood ∝ Posterior

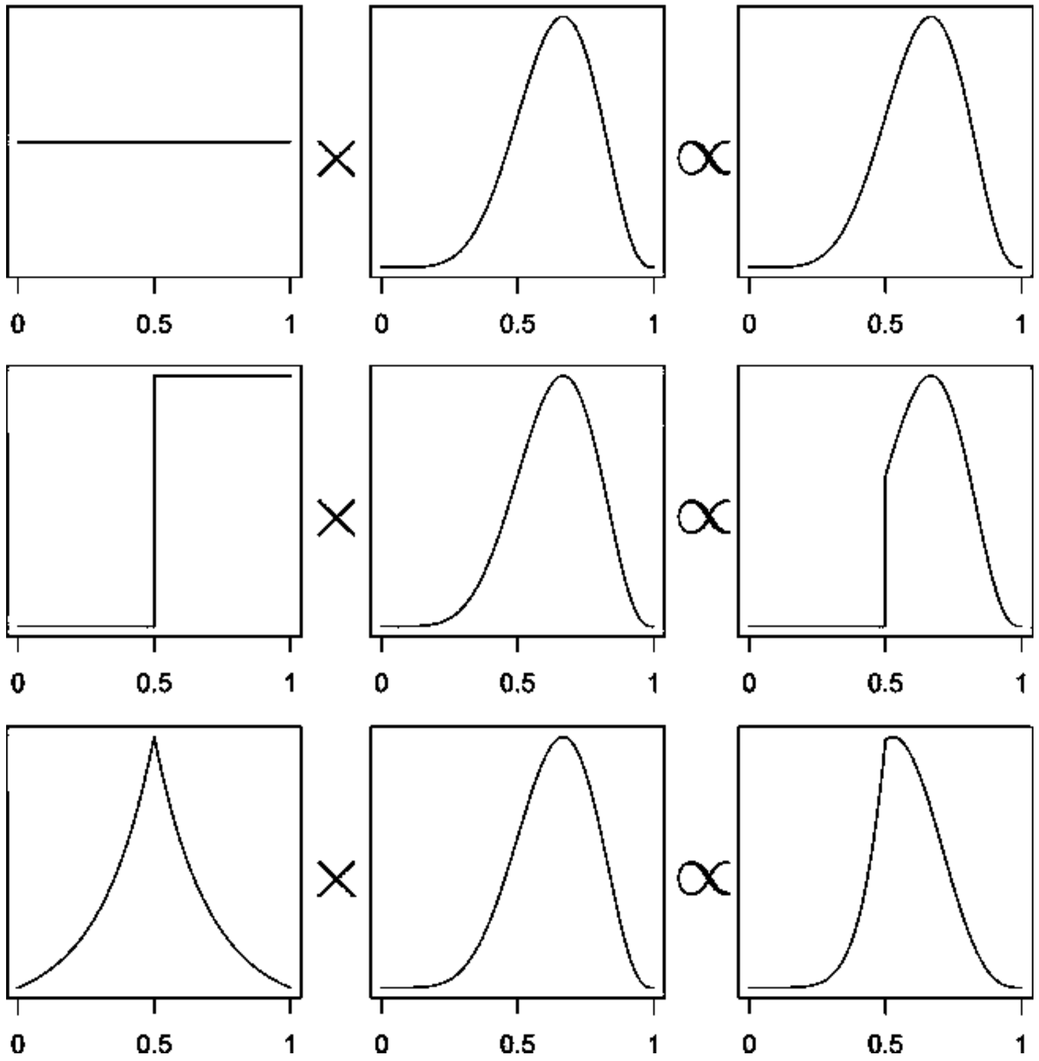
$$P(\theta \mid y) = \frac{P(y \mid \theta)P(\theta)}{P(y)}$$



- $P(\theta \mid y)$ Representa nossa informação sobre os parâmetros usando probabilidade.
  - Contém toda a informação sobre nossa crença.
  - Inclusive nossa incerteza.

Prior × Likelihood ∝ Posterior

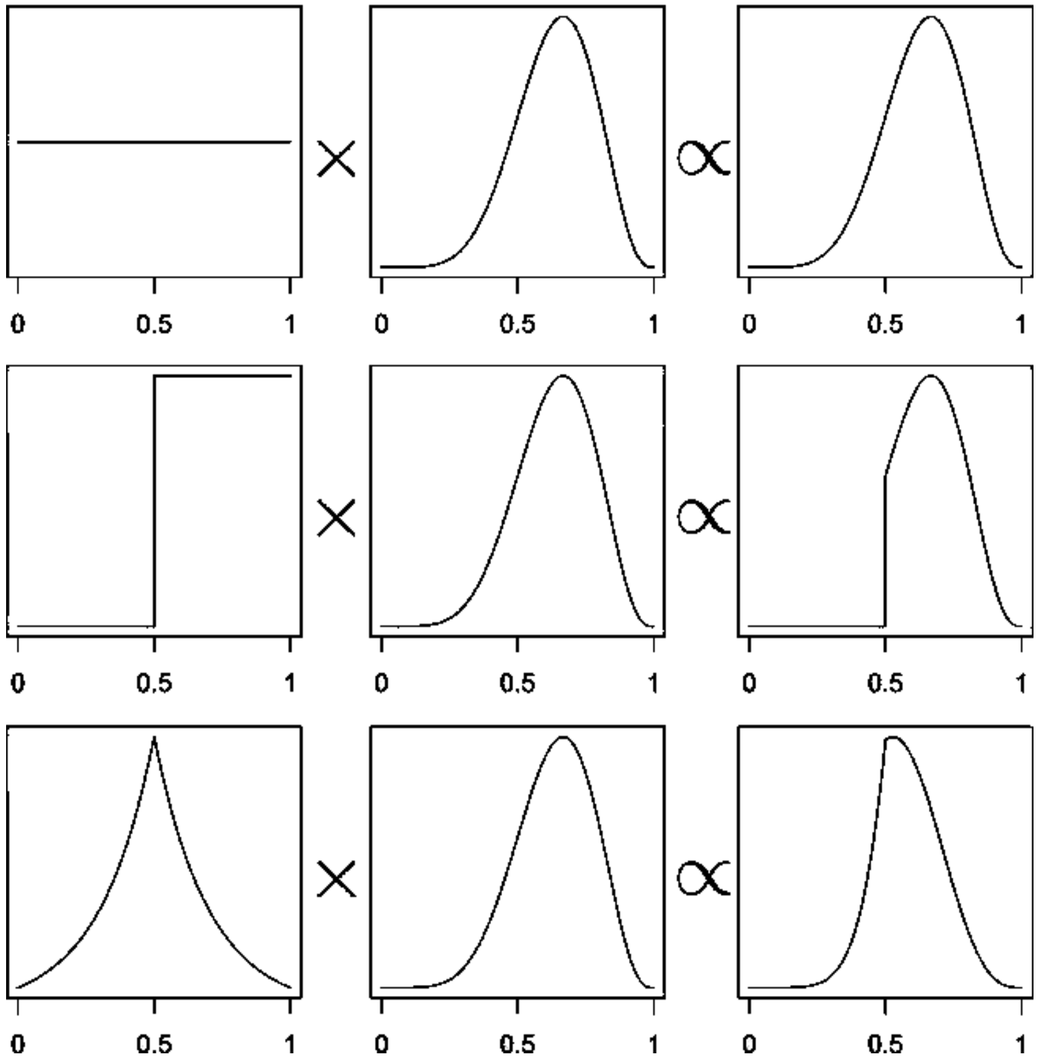
$$P(\theta \mid y) = \frac{P(y \mid \theta)P(\theta)}{P(y)}$$



- $P(\theta \mid y)$ Representa nossa informação sobre os parâmetros usando probabilidade.
  - Contém toda a informação sobre nossa crença.
  - Inclusive nossa incerteza.
- $P(\theta)$, o prior ou a priori, codifica informação prévia:

Prior × Likelihood ∝ Posterior

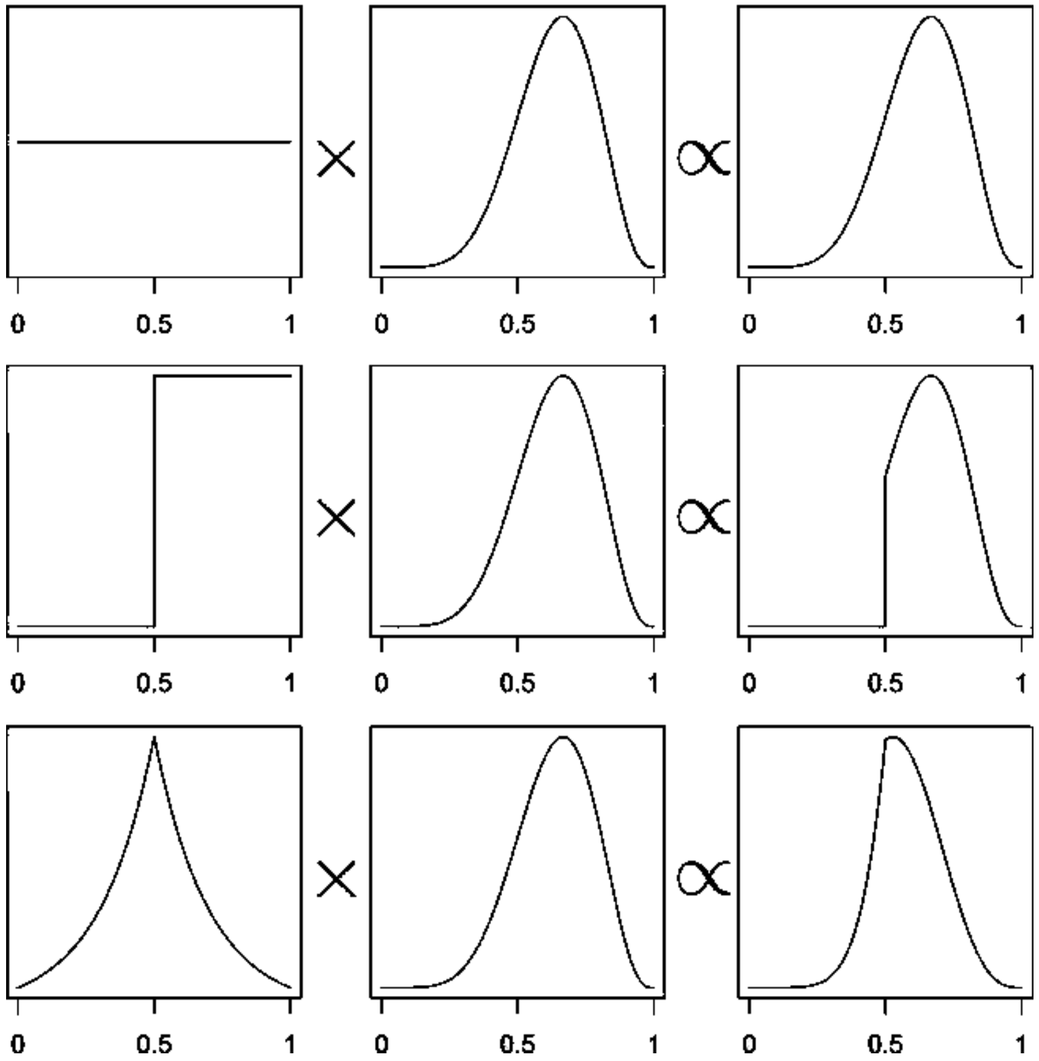
$$P(\theta \mid y) = \frac{P(y \mid \theta)P(\theta)}{P(y)}$$



- $P(\theta \mid y)$ Representa nossa informação sobre os parâmetros usando probabilidade.
  - Contém toda a informação sobre nossa crença.
  - Inclusive nossa incerteza.
- $P(\theta)$, o prior ou a priori, codifica informação prévia:
  - Escala, estrutura de relação, valores possíveis...

Prior × Likelihood ∝ Posterior

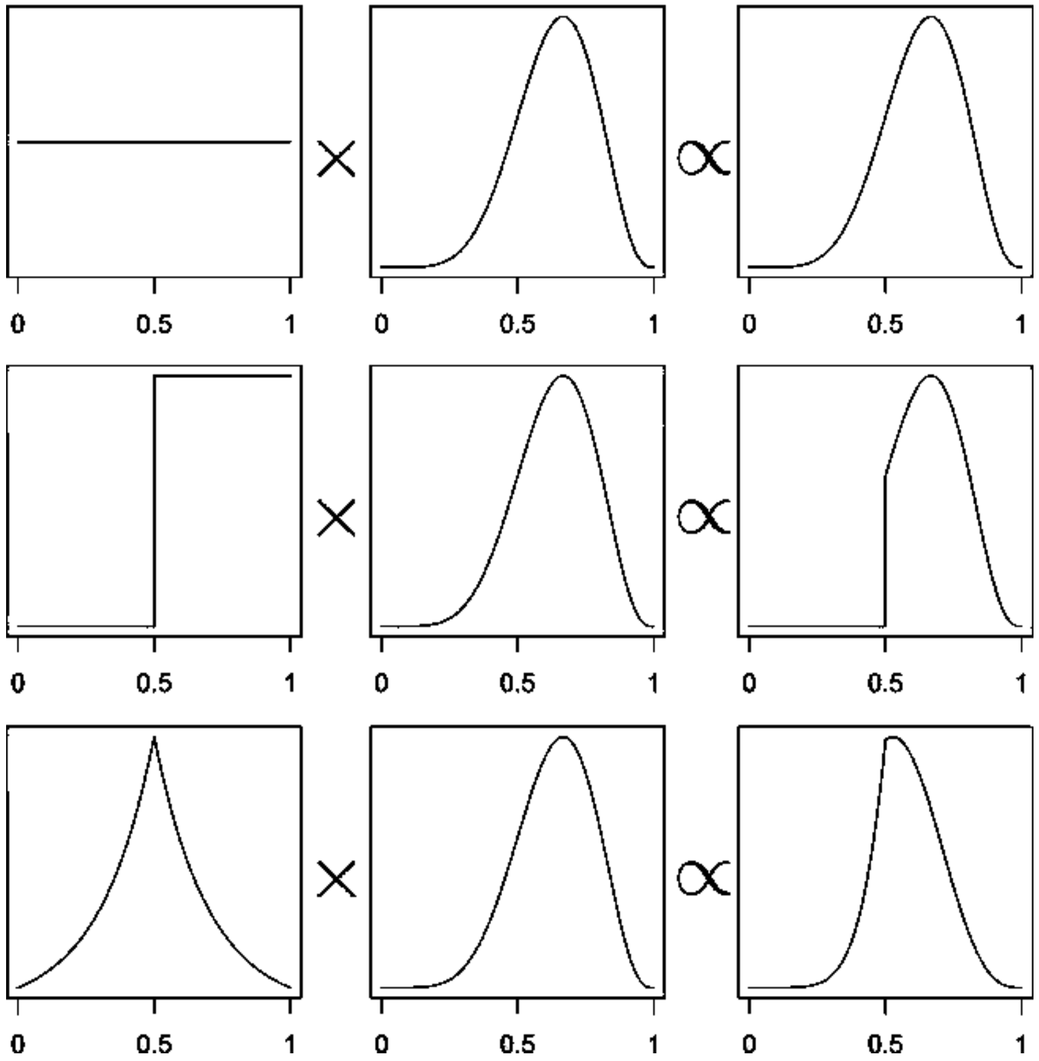
$$P(\theta \mid y) = \frac{P(y \mid \theta)P(\theta)}{P(y)}$$



- $P(\theta \mid y)$ Representa nossa informação sobre os parâmetros usando probabilidade.
  - Contém toda a informação sobre nossa crença.
  - Inclusive nossa incerteza.
- $P(\theta)$, o prior ou a priori, codifica informação prévia:
  - Escala, estrutura de relação, valores possíveis...
- Mas o estimados de ML não é o melhor?!

Prior × Likelihood ∝ Posterior

$$P(\theta \mid y) = \frac{P(y \mid \theta)P(\theta)}{P(y)}$$



- $P(\theta \mid y)$ Representa nossa informação sobre os parâmetros usando probabilidade.
  - Contém toda a informação sobre nossa crença.
  - Inclusive nossa incerteza.
- $P(\theta)$, o prior ou a priori, codifica informação prévia:
  - Escala, estrutura de relação, valores possíveis...
- Mas o estimados de ML não é o melhor?!
  - As vezes... mas não funções dele

$$\rho = f(\hat{\theta})$$

Usando a posteriori

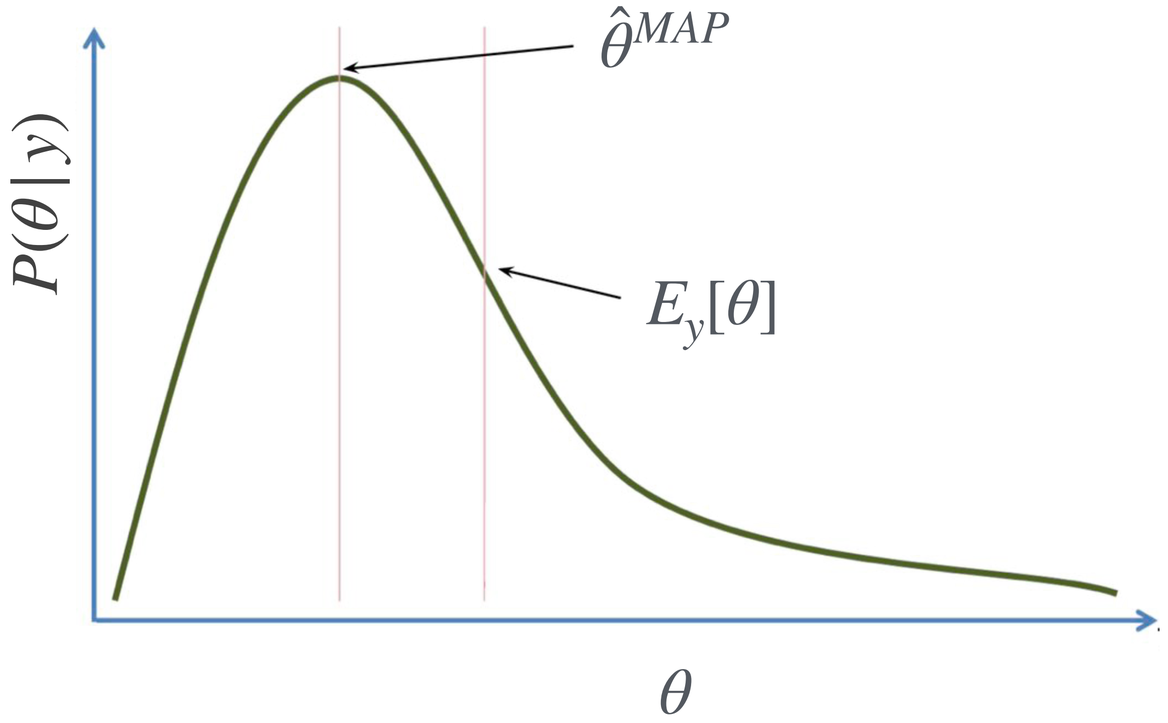
Posterior estimators

- Equivalente Bayesiano da ML é o **M**aximum **A** **P**osteriori (MAP):

$$\hat{\theta}^{MAP} = \underset{\theta \in \Omega}{\operatorname{argmax}} \left[P(\theta \mid y) \right]$$

- A média sob a posteriori é mais comum

$$E_y[\theta] = \sum_{\theta \in \Omega} \theta P(\theta \mid y)$$

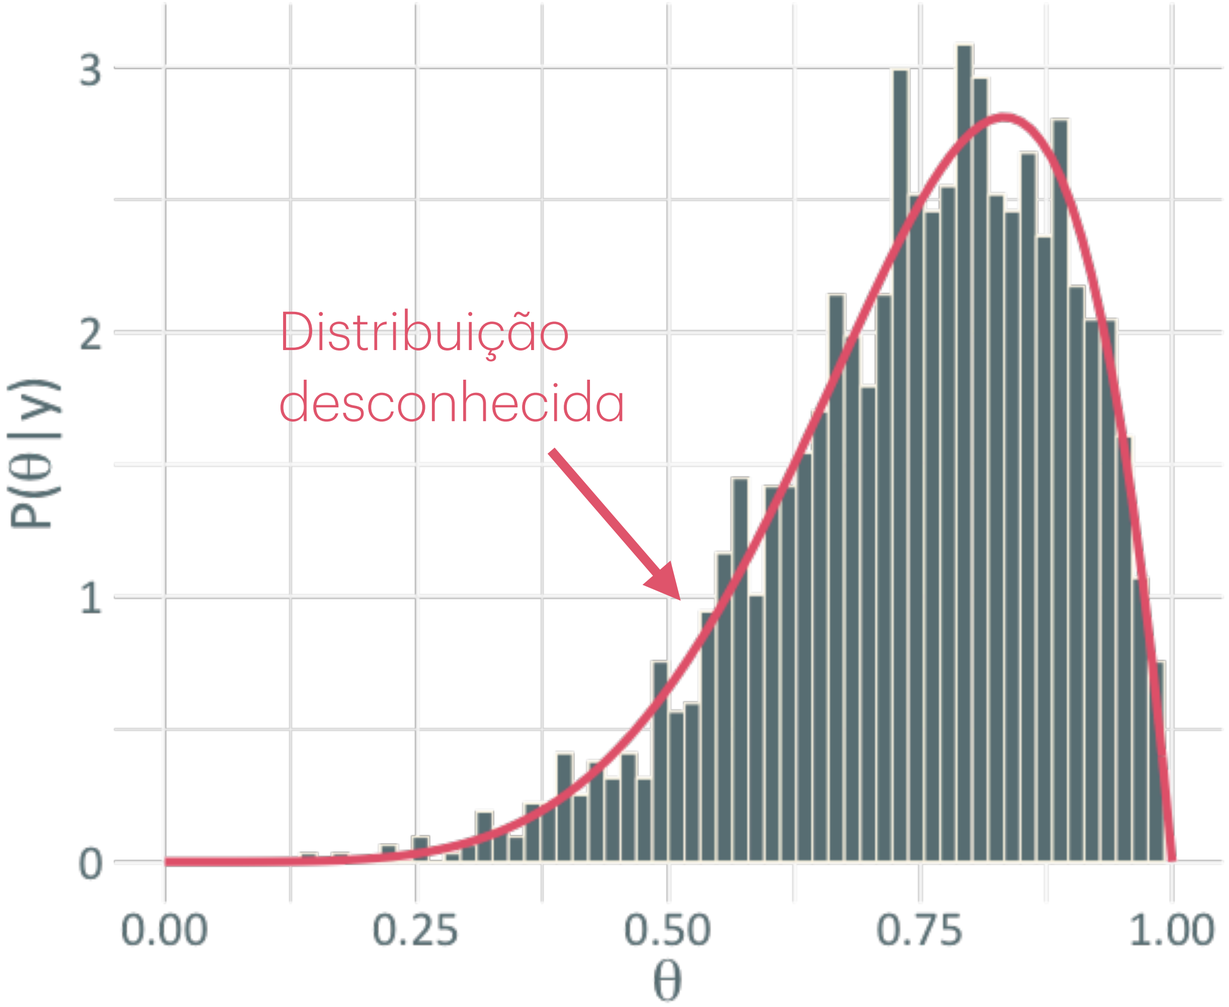


(A mediana da posteriori é usada ocasionalmente)

Aproximações da posteriori

- O número pequeno de modelos, podemos acessar a posteriori diretamente (Pequeno mesmo, nem precisa tentar).
- Para a maioria dos modelos, nós aproximamos a posteriori usando uma amostra.

$$\{\theta_1, \cdots, \theta_N\} \sim P(\theta \,|\, y)$$



Quantidades a partir da posterioriz

- Podemos usar essa amostra para calcular qualquer quantidade

$$\{\theta_1, \cdots, \theta_N\} \sim P(\theta \mid y)$$

Por exemplo, a média da posteriori:

$$\frac{\theta_1 + \theta_2 + \cdots + \theta_N}{N} \approx \sum_{\theta \in \Omega} \theta P(\theta \mid y)$$

Quantidades a partir da posterioriz

- Podemos usar essa amostra para calcular qualquer quantidade

$$\{\theta_1, \cdots, \theta_N\} \sim P(\theta \mid y)$$

Por exemplo, a média da posteriori:

$$\frac{\theta_1 + \theta_2 + \cdots + \theta_N}{N} \approx \sum_{\theta \in \Omega} \theta P(\theta \mid y)$$

Outras quantidades:

- Qualquer função dos parâmetros.
- Um uso comum é comparar diferenças entre médias de grupos.
- Quantis, valores acima de um valor de referência, intervalos de confiança...

Construindo um modelo

Nossa regressão linear velha de guerra

- Dados são medias de um preditor e uma resposta:

$$(x, y) = \{(x_1, y_1), \cdots, (x_n, y_n)\}$$

- Definimos a verossimilhança:

$$\left.\begin{aligned} y_i &\sim Normal(\mu_i, \sigma) \\ \mu_i &= \alpha + \beta x_i \end{aligned}\right\} P(y \mid \theta)$$

Construindo um modelo

Nossa regressão linear velha de guerra

- Dados são medias de um preditor e uma resposta:

$$(x, y) = \{(x_1, y_1), \cdots, (x_n, y_n)\}$$

- Definimos a verossimilhança:

$$\left.\begin{aligned} y_i &\sim Normal(\mu_i, \sigma) \\ \mu_i &= \alpha + \beta x_i \end{aligned}\right\} P(y \mid \theta)$$

- E as a priori para os 3 parâmetros

$$\alpha \sim P(\alpha)$$
$$\beta \sim P(\beta)$$
$$\sigma \sim P(\sigma)$$

Construindo um modelo

Nossa regressão linear velha de guerra

- Dados são medias de um preditor e uma resposta:

$$(x, y) = \{(x_1, y_1), \cdots, (x_n, y_n)\}$$

- Definimos a verossimilhança:

$$\left.\begin{aligned} y_i &\sim Normal(\mu_i, \sigma) \\ \mu_i &= \alpha + \beta x_i \end{aligned}\right\} P(y \mid \theta)$$

- E as a priori para os 3 parâmetros

$$\left.\begin{aligned} \alpha &\sim P(\alpha) \\ \beta &\sim P(\beta) \\ \sigma &\sim P(\sigma) \end{aligned}\right\} P(\theta)$$

Como escolher os priors?!

$$\alpha \sim P(\alpha)$$
$$\beta \sim P(\beta)$$
$$\sigma \sim P(\sigma)$$

Como escolher os priors?!

$$\alpha \sim P(\alpha)$$
$$\beta \sim P(\beta)$$
$$\sigma \sim P(\sigma)$$

- Escolhas agnósticas:

Como escolher os priors?!

$$\alpha \sim P(\alpha)$$
$$\beta \sim P(\beta)$$
$$\sigma \sim P(\sigma)$$

- Escolhas agnósticas:
  - Laplace Principio da Indiferença

Como escolher os priors?!

$$\alpha \sim P(\alpha)$$
$$\beta \sim P(\beta)$$
$$\sigma \sim P(\sigma)$$

- Escolhas agnósticas:
  - Laplace Principio da Indiferença
  - Priors “não informativos”

Como escolher os priors?!

$$\alpha \sim P(\alpha)$$
$$\beta \sim P(\beta)$$
$$\sigma \sim P(\sigma)$$

- Escolhas agnósticas:
  - Laplace Principio da Indiferença
  - Priors “não informativos”
- Priors de máxima entropia

Como escolher os priors?!

$$\alpha \sim P(\alpha)$$
$$\beta \sim P(\beta)$$
$$\sigma \sim P(\sigma)$$

- Escolhas agnósticas:
  - Laplace Principio da Indiferença
  - Priors “não informativos”
- Priors de máxima entropia
  - São distribuições que carregam a menor quantidade possível de informação dada alguma restrição

Como escolher os priors?!

$$\alpha \sim P(\alpha)$$
$$\beta \sim P(\beta)$$
$$\sigma \sim P(\sigma)$$

- Escolhas agnósticas:
  - Laplace Principio da Indiferença
  - Priors “não informativos”
- Priors de máxima entropia
  - São distribuições que carregam a menor quantidade possível de informação dada alguma restrição
- Jeffreys priors

Como escolher os priors?!

$$\alpha \sim P(\alpha)$$
$$\beta \sim P(\beta)$$
$$\sigma \sim P(\sigma)$$

- Escolhas agnósticas:
  - Laplace Principio da Indiferença
  - Priors “não informativos”
- Priors de máxima entropia
  - São distribuições que carregam a menor quantidade possível de informação dada alguma restrição
- Jeffreys priors
  - São invariantes sob mudanças de variável

Como escolher os priors?!

$$\alpha \sim P(\alpha)$$
$$\beta \sim P(\beta)$$
$$\sigma \sim P(\sigma)$$

- Escolhas agnósticas:
  - Laplace Principio da Indiferença
  - Priors “não informativos”
- Priors de máxima entropia
  - São distribuições que carregam a menor quantidade possível de informação dada alguma restrição
- Jeffreys priors
  - São invariantes sob mudanças de variável
- Restrições totais

Como escolher os priors?!

$$\alpha \sim P(\alpha)$$
$$\beta \sim P(\beta)$$
$$\sigma \sim P(\sigma)$$

- Escolhas agnósticas:
  - Laplace Principio da Indiferença
  - Priors “não informativos”
- Priors de máxima entropia
  - São distribuições que carregam a menor quantidade possível de informação dada alguma restrição
- Jeffreys priors
  - São invariantes sob mudanças de variável
- Restrições totais
  - Ex: Variância é sempre positiva

Como escolher os priors?!

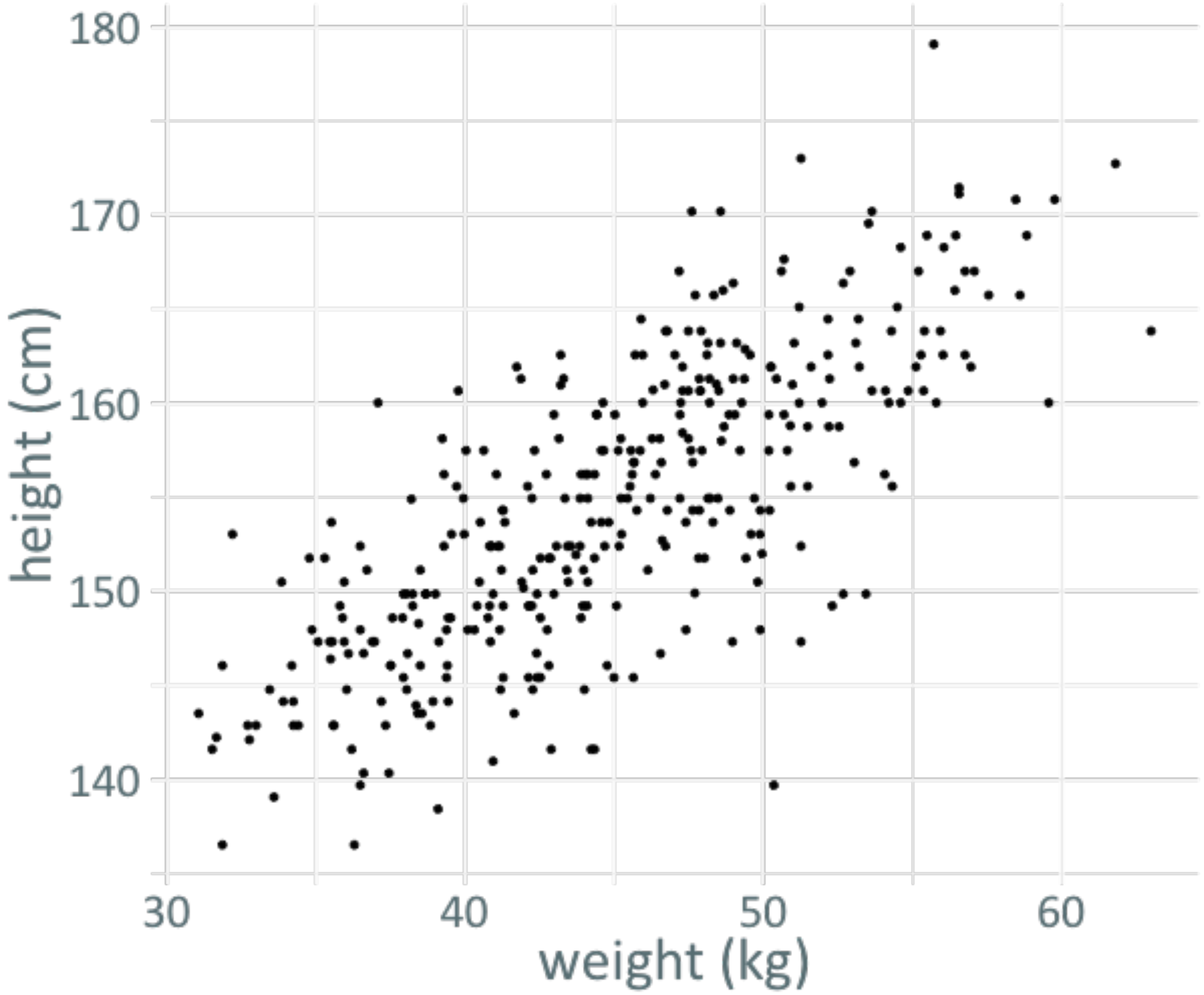
$$\alpha \sim P(\alpha)$$
$$\beta \sim P(\beta)$$
$$\sigma \sim P(\sigma)$$

- Escolhas agnósticas:
  - Laplace Principio da Indiferença
  - Priors “não informativos”
- Priors de máxima entropia
  - São distribuições que carregam a menor quantidade possível de informação dada alguma restrição
- Jeffreys priors
  - São invariantes sob mudanças de variável
- Restrições totais
  - Ex: Variância é sempre positiva

Boas escolhas:

- Use seu conhecimento sobre o sistema de estudo!
- Conhecimento da escala do sistema.
- Desenho experimental frequentemente induz priors (modelos hierárquicos)
- Usem simulações para entender as consequências das escolhas

Priors podem codificar escala do sistema

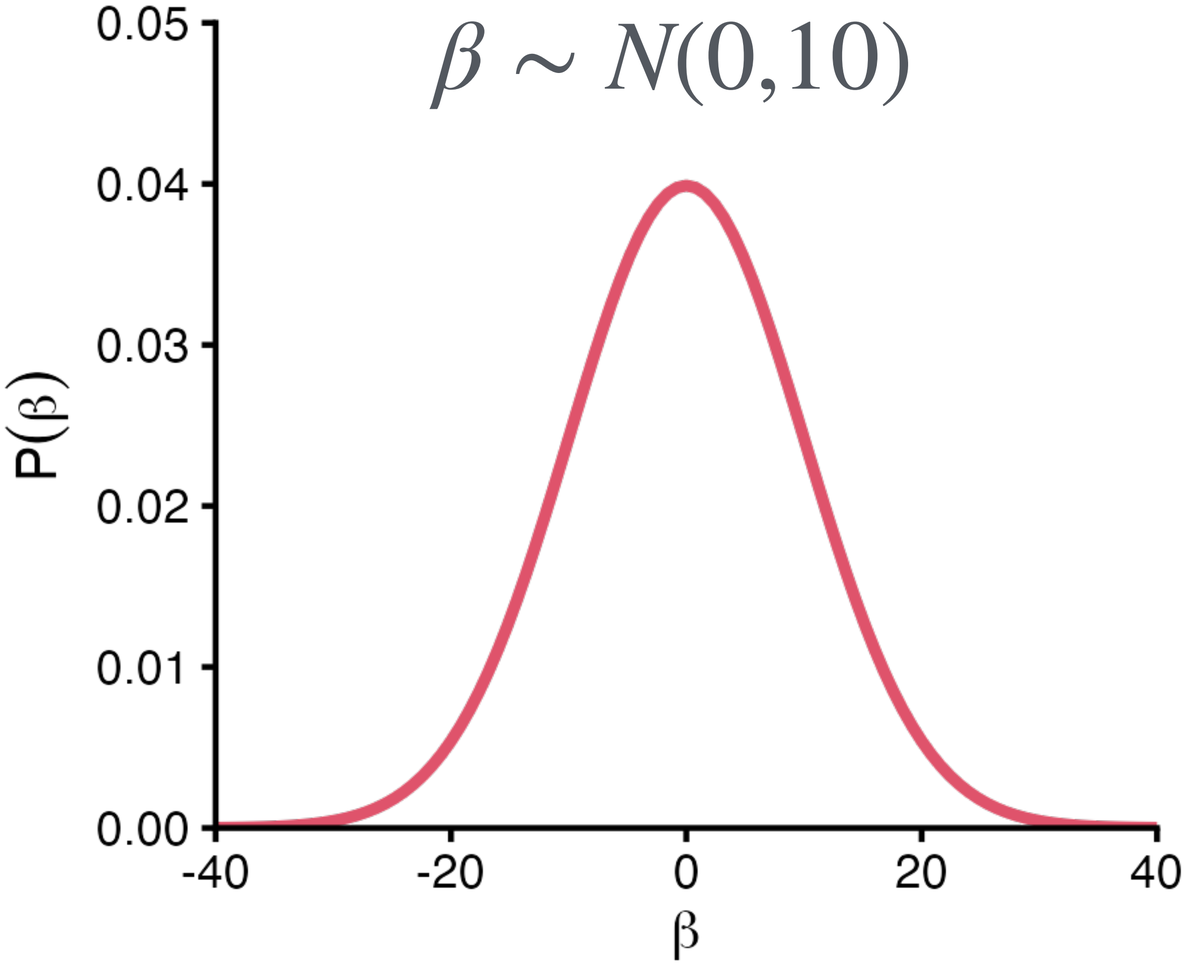


Adapted from Statistical Rethinking

Priors Largo vs Estreito

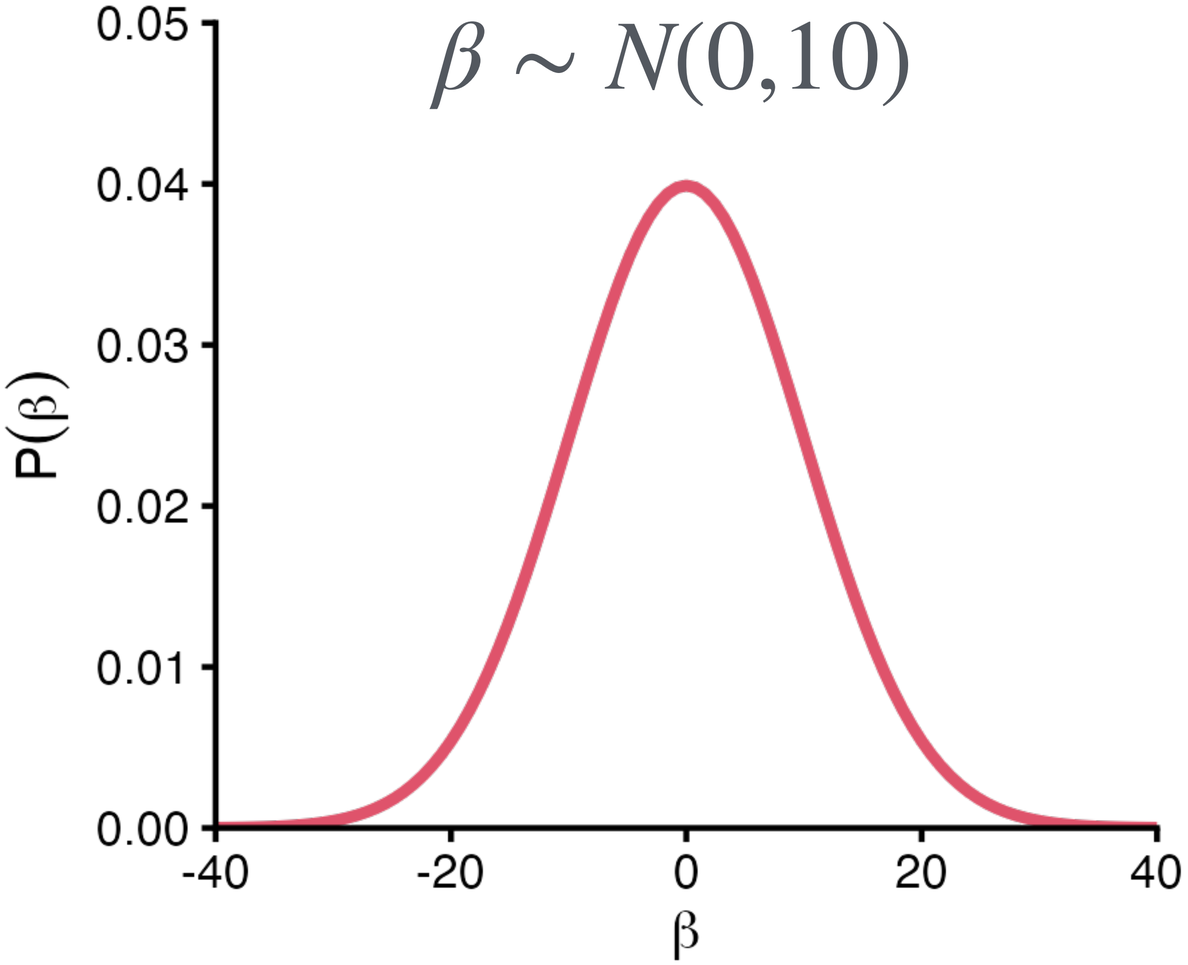
$$\beta \sim N(0,10)$$

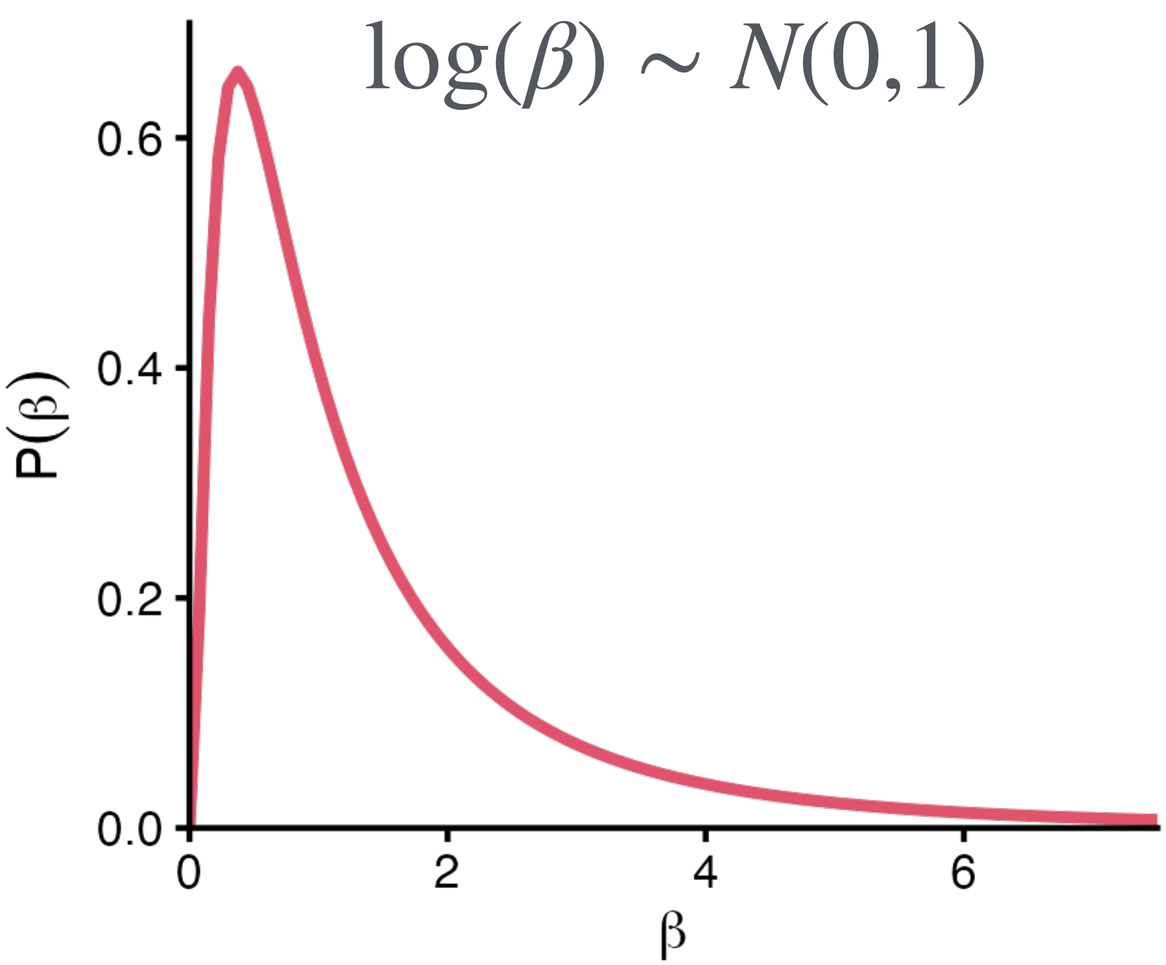
$$\log(\beta) \sim N(0,1)$$



Esse é um exemplo de prior não-informativo

Priors Largo vs Estreito



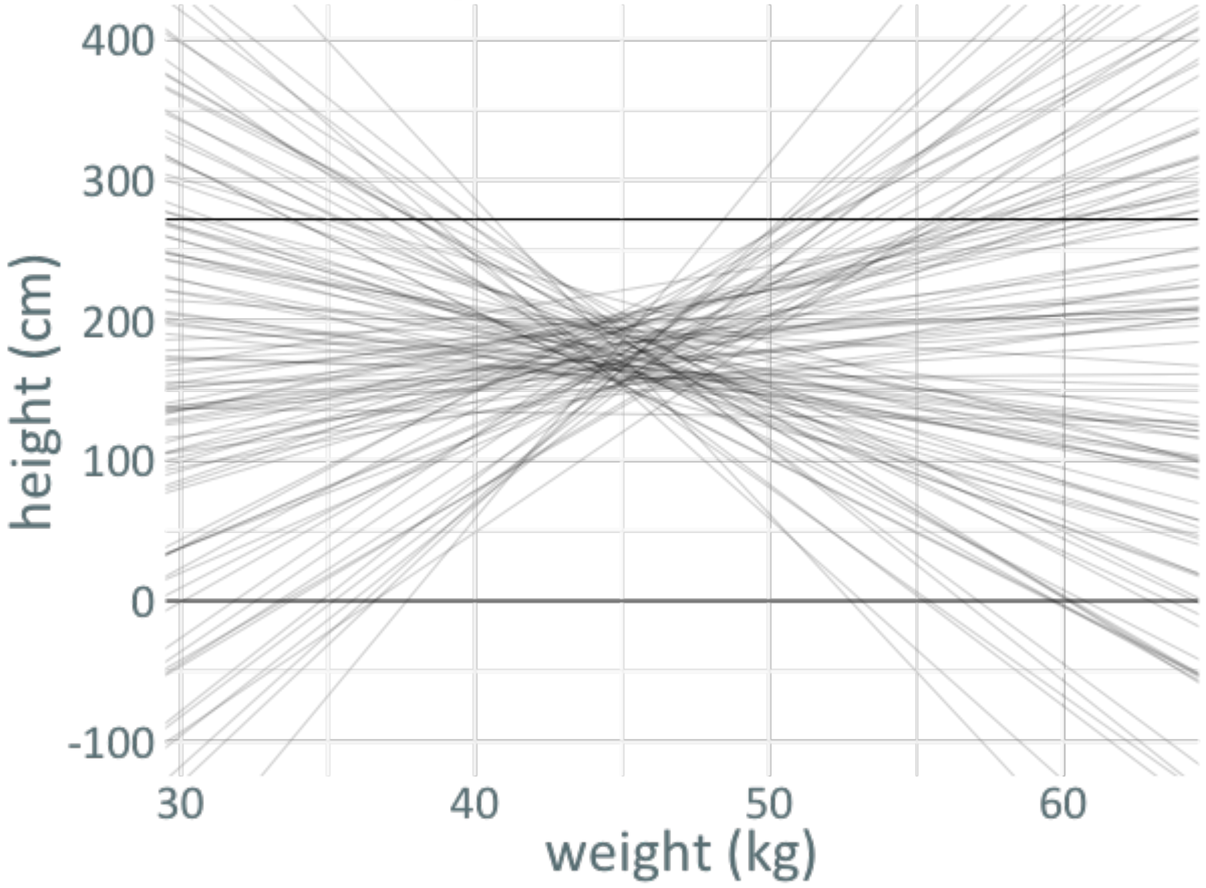


Esse é um exemplo de prior não-informativo

Esse prior é informativo, mas de um jeito bom!

Priors Largo vs Estreito

$$\beta \sim N(0,10)$$

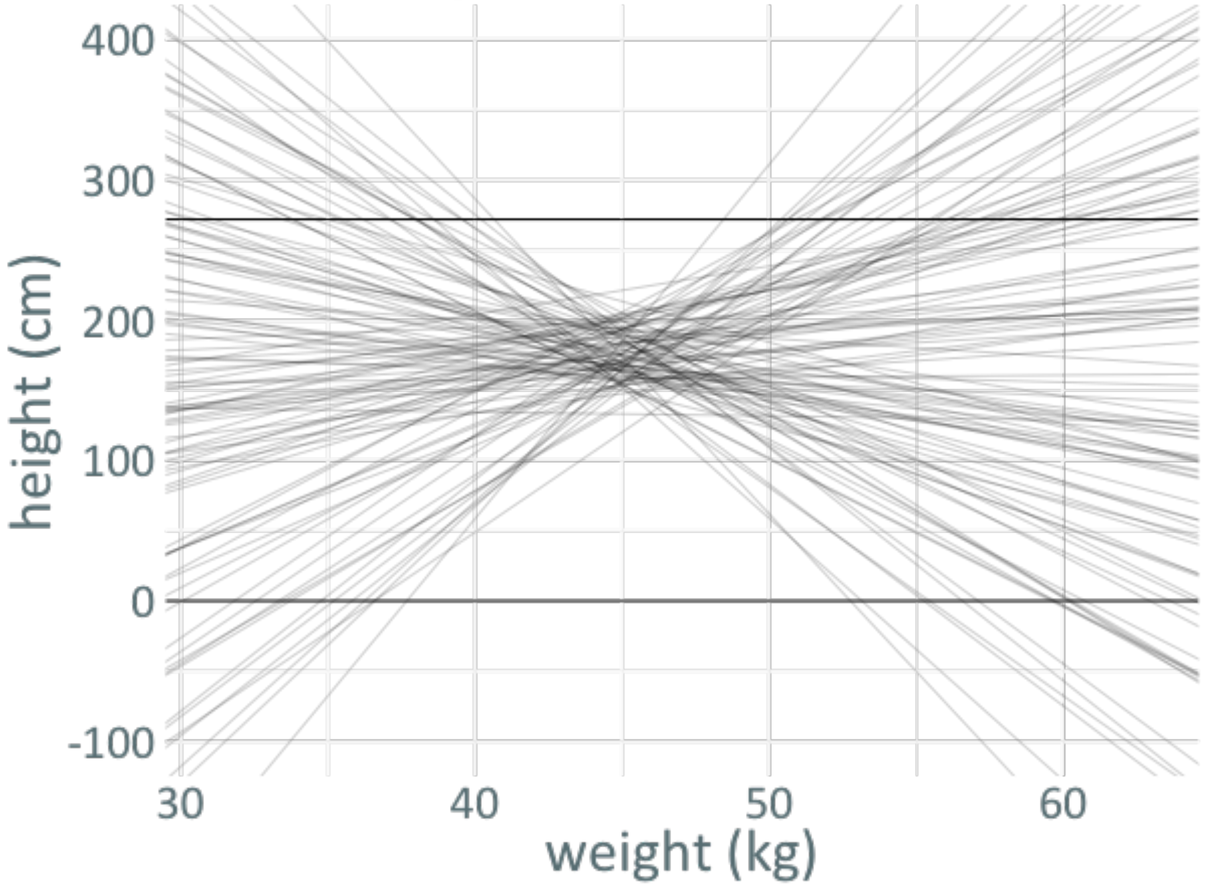


$$\log(\beta) \sim N(0,1)$$

Esse é um exemplo de prior não-informativo

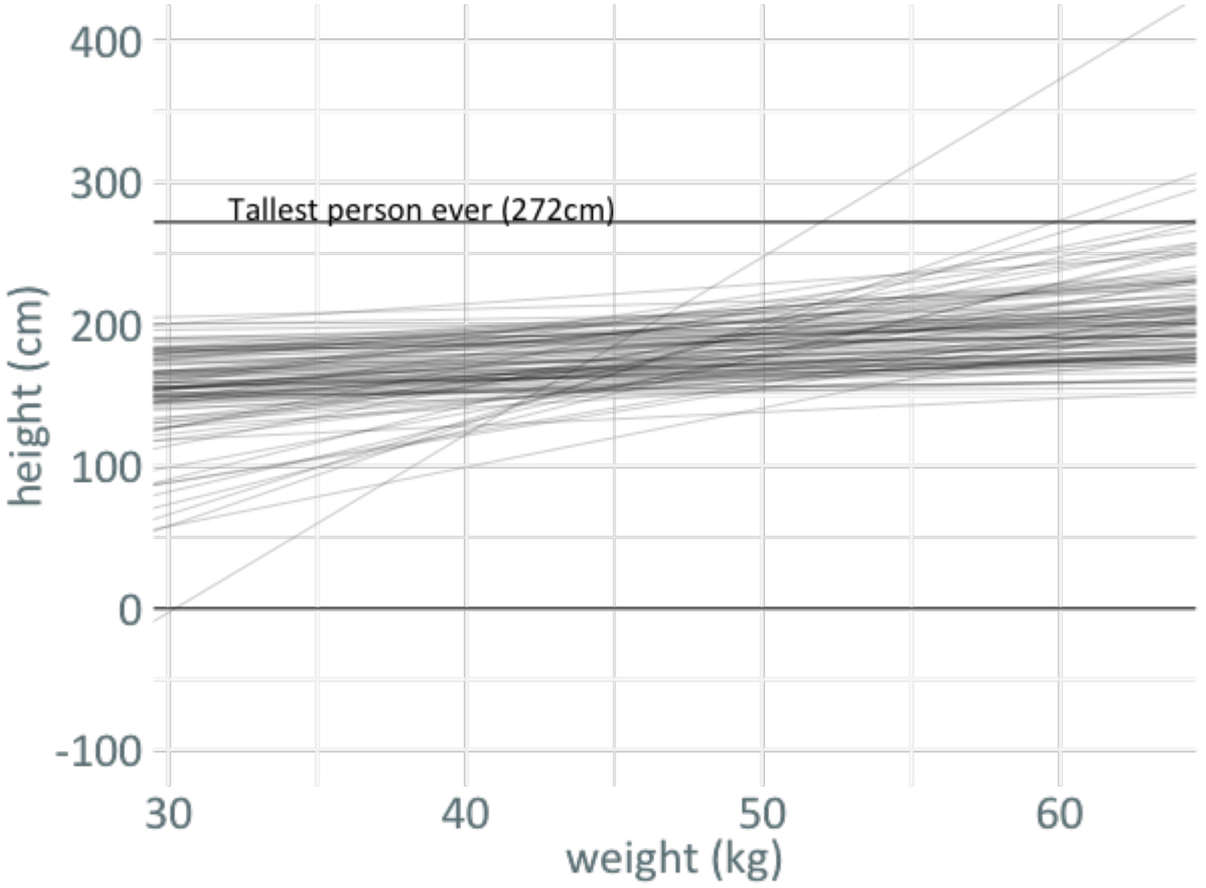
Priors Largo vs Estreito

$$\beta \sim N(0,10)$$



Esse é um exemplo de prior não-informativo

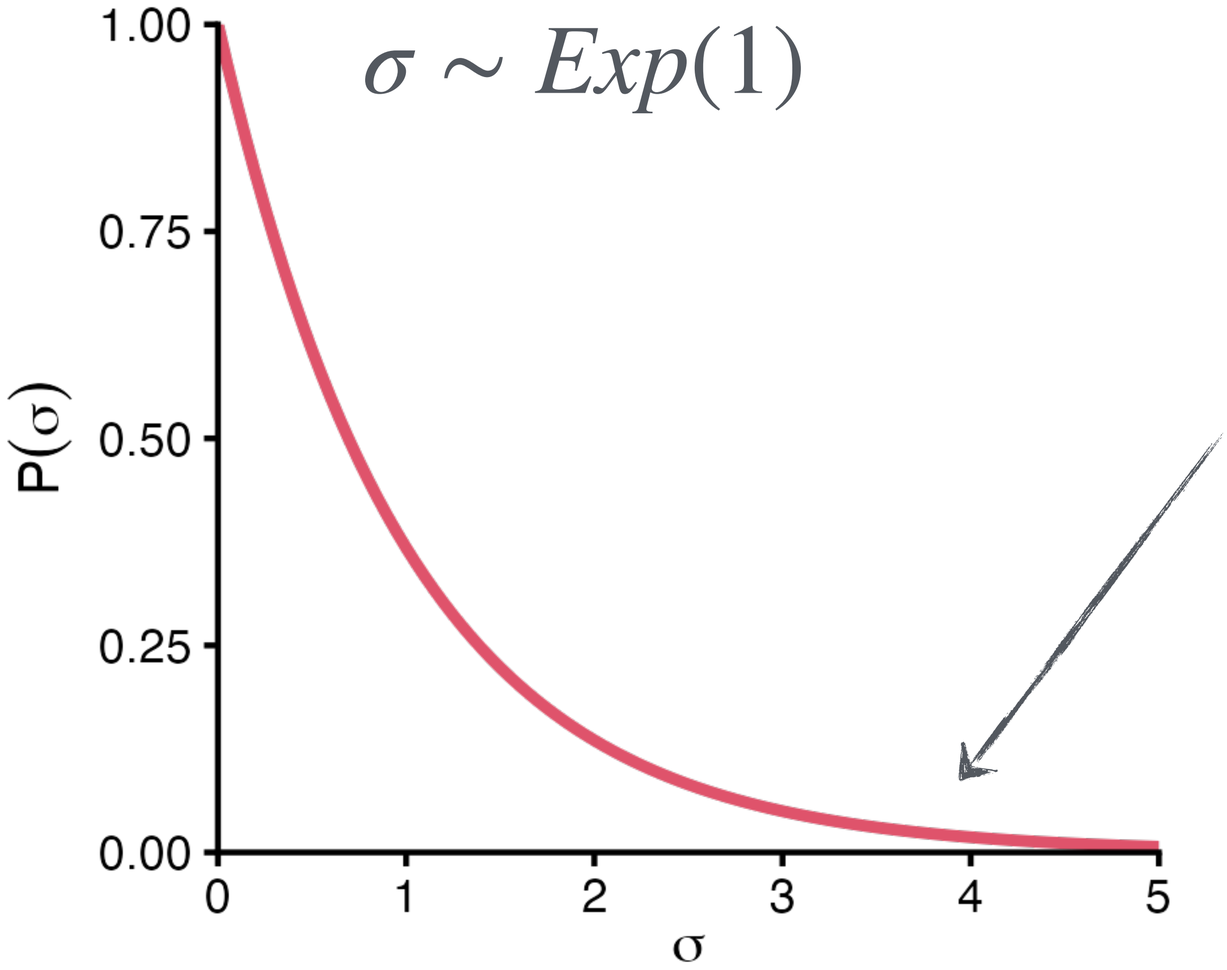
$$\log(\beta) \sim N(0,1)$$



Esse prior é informativo, mas de um jeito bom!

Prior para a variância

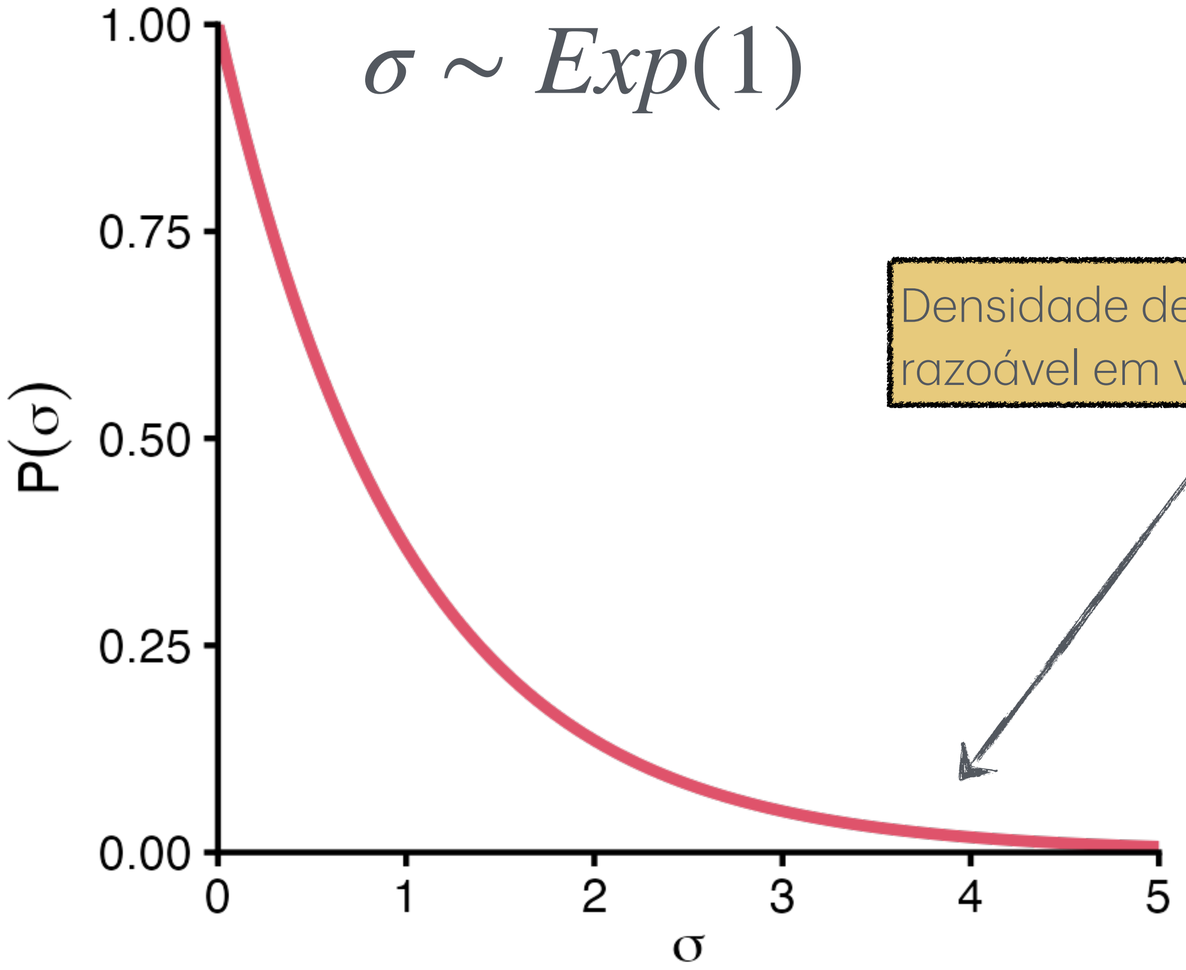
Distribuição exponencial, sempre positiva



Prior para a variância

Distribuição exponencial, sempre positiva

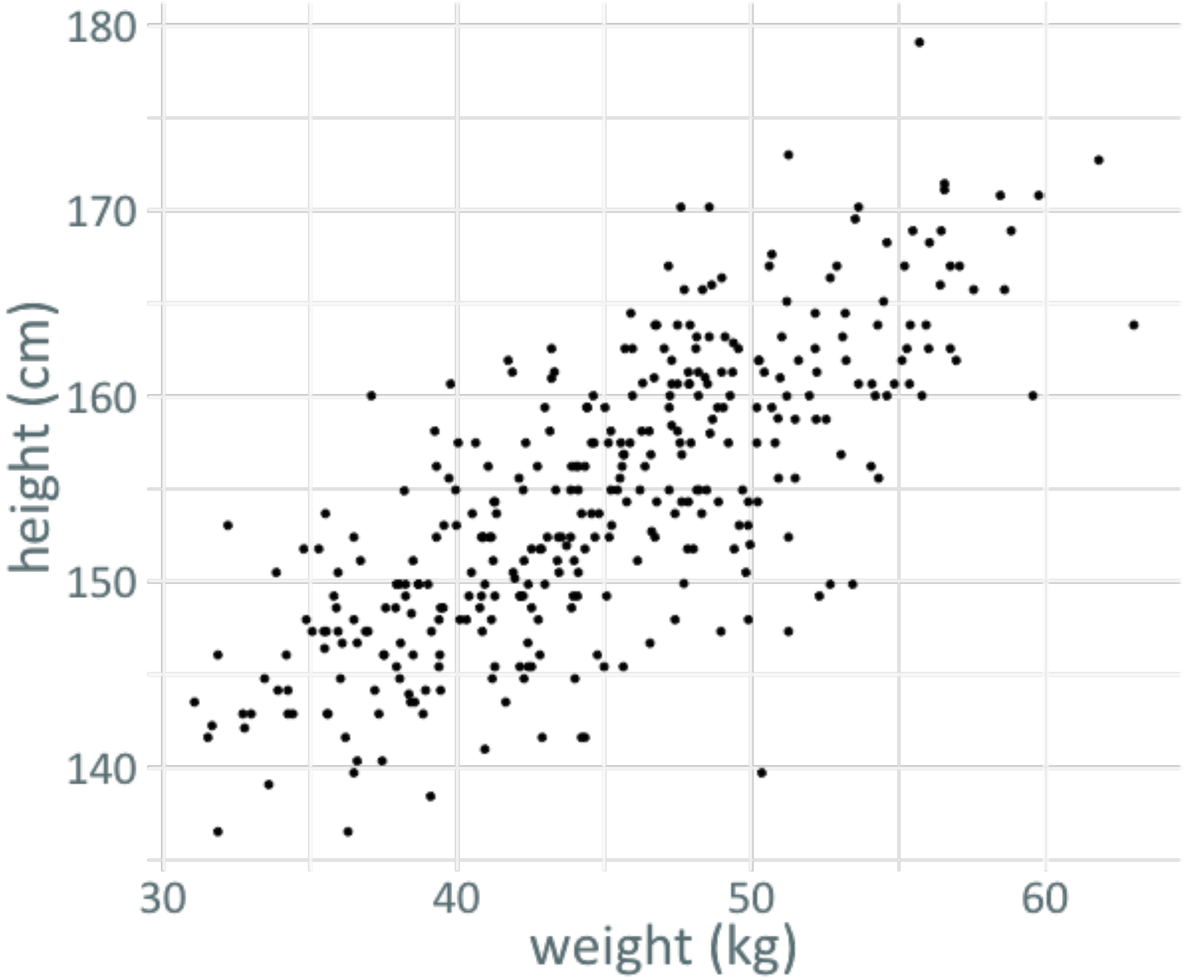
$$\sigma \sim Exp(1)$$



Densidade de probabilidade razoável em valores plausíveis

Nosso modelo completo

$$y_i \sim Normal(\mu_i, \sigma)$$
$$\mu_i = \alpha + \beta x_i$$
$$\alpha \sim Normal(0, 20)$$
$$\beta \sim lognormal(0, 1)$$
$$\sigma \sim Exponential(1)$$

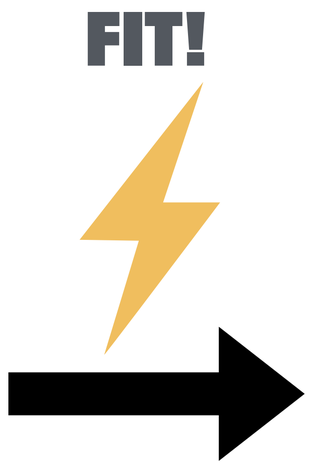


Amostras da posteriori

$$
\begin{aligned}
y_i &\sim Normal(\mu_i, \sigma) \\
\mu_i &= \alpha + \beta x_i \\
\alpha &\sim Normal(0, 20) \\
\beta &\sim lognormal(0, 1) \\
\sigma &\sim Exponential(1)
\end{aligned}
$$

Amostras da posteriori

$$y_i \sim Normal(\mu_i, \sigma)$$
$$\mu_i = \alpha + \beta x_i$$
$$\alpha \sim Normal(0, 20)$$
$$\beta \sim lognormal(0, 1)$$
$$\sigma \sim Exponential(1)$$




```
> samples
# A tibble: 2,000 × 3
             a          b     sigma
   <dbl[1d]> <dbl[1d]> <dbl[1d]>
 1      115.     0.889       4.78
 2      109.     1.02        5.30
 3      112.     0.928       5.07
 4      111.     0.949       5.30
 5      111.     0.955       5.04
 6      115.     0.872       5.19
 7      109.     1.01        5.13
 8      117.     0.844       5.00
 9      115.     0.882       4.94
10      112.     0.939       4.95
# … with 1,990 more rows
```

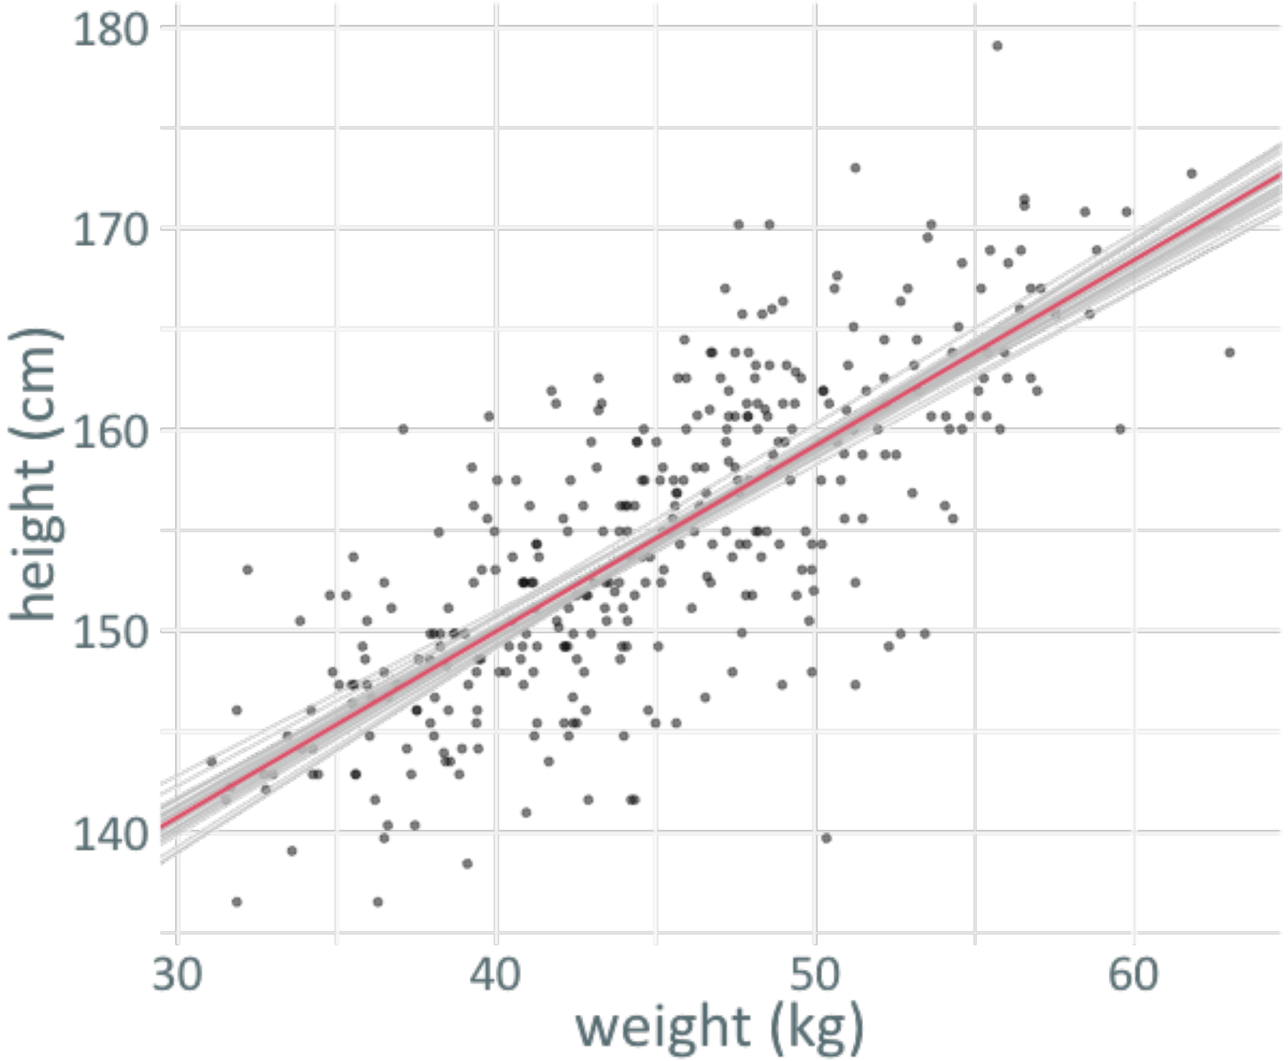
Estimadores

Médias da posteriori

$$E_y[\theta] =$$

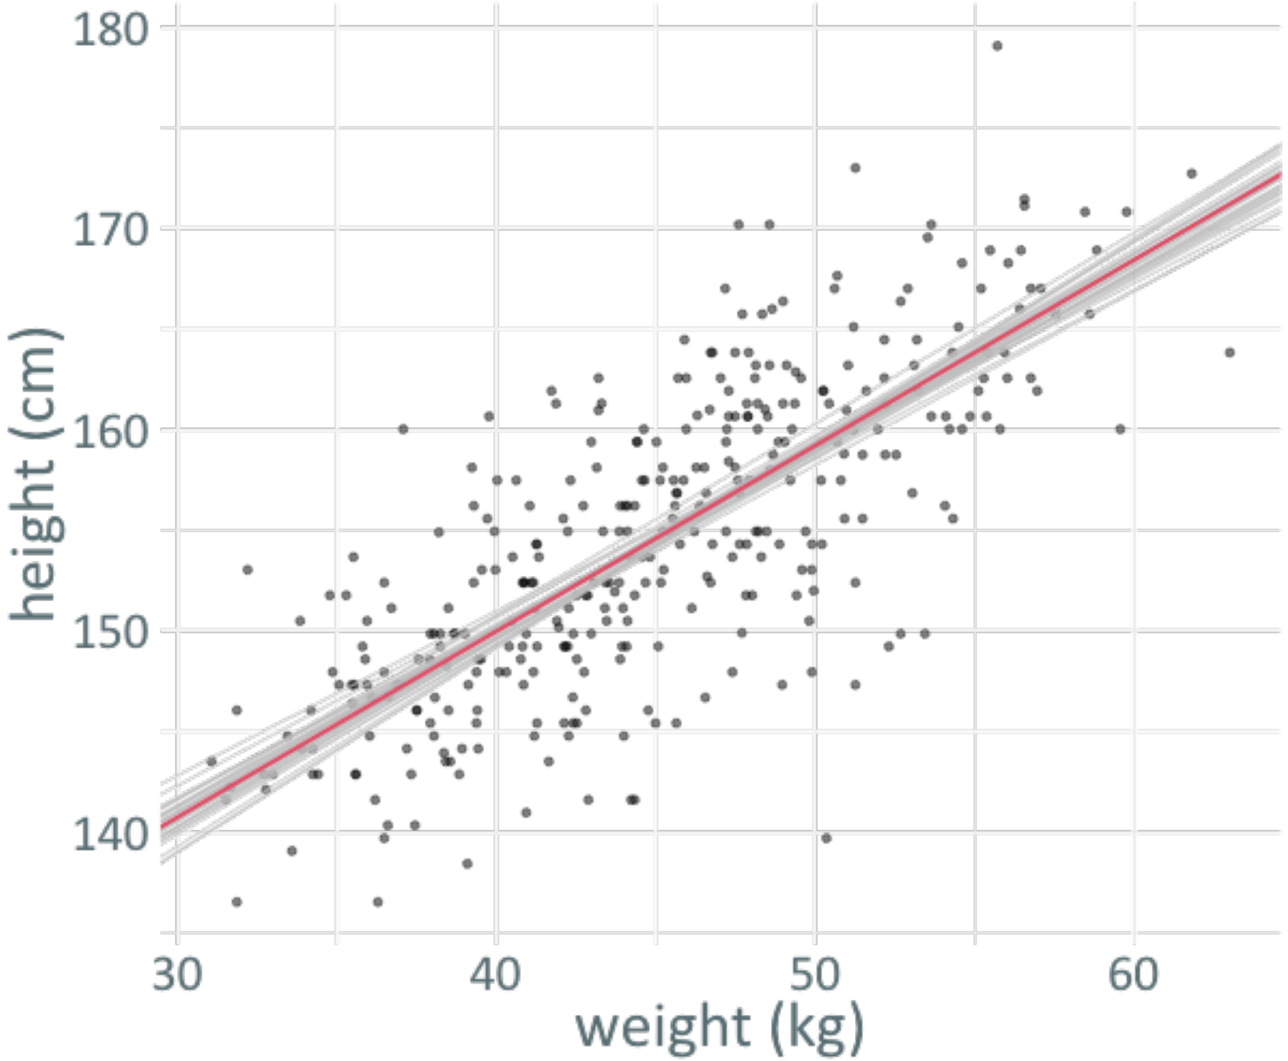
```
> colMeans(samples)
          a           b       sigma
112.9296580   0.9253803   5.0453651
```

Model fit




```
> colMeans(samples)
          a           b       sigma
112.9296580   0.9253803   5.0453651
```

Model fit



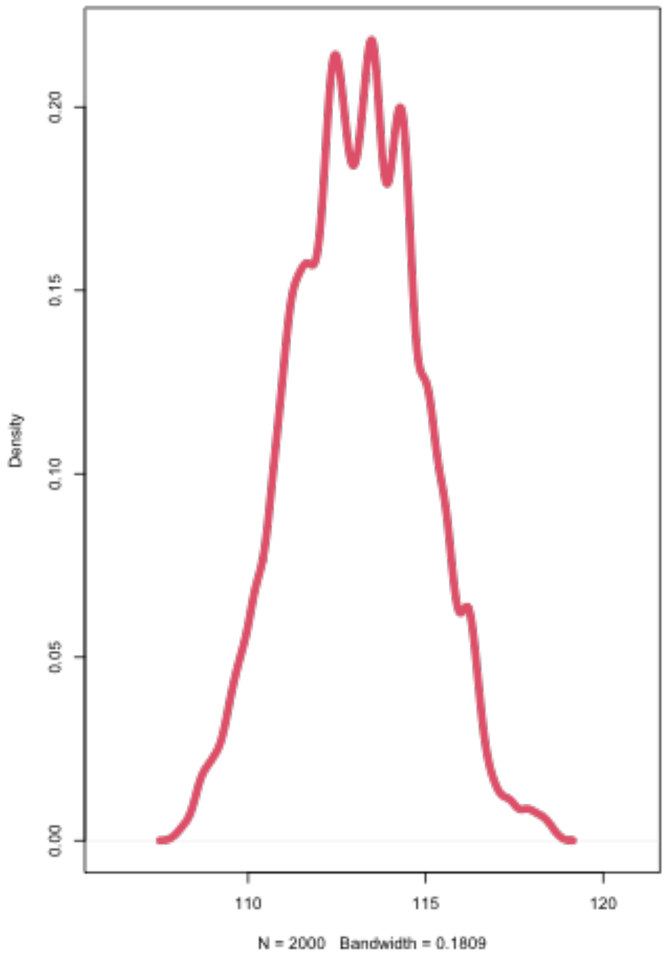

```
> colMeans(samples)
          a           b       sigma
112.9296580   0.9253803   5.0453651
```

```
> samples
# A tibble: 2,000 × 3
          a         b     sigma
  <dbl[1d]> <dbl[1d]> <dbl[1d]>
1      115.     0.889      4.78
2      109.     1.02       5.30
3      112.     0.928      5.07
4      111.     0.949      5.30
5      111.     0.955      5.04
6      115.     0.872      5.19
7      109.     1.01       5.13
8      117.     0.844      5.00
9      115.     0.882      4.94
10     112.     0.939      4.95
# … with 1,990 more rows
```

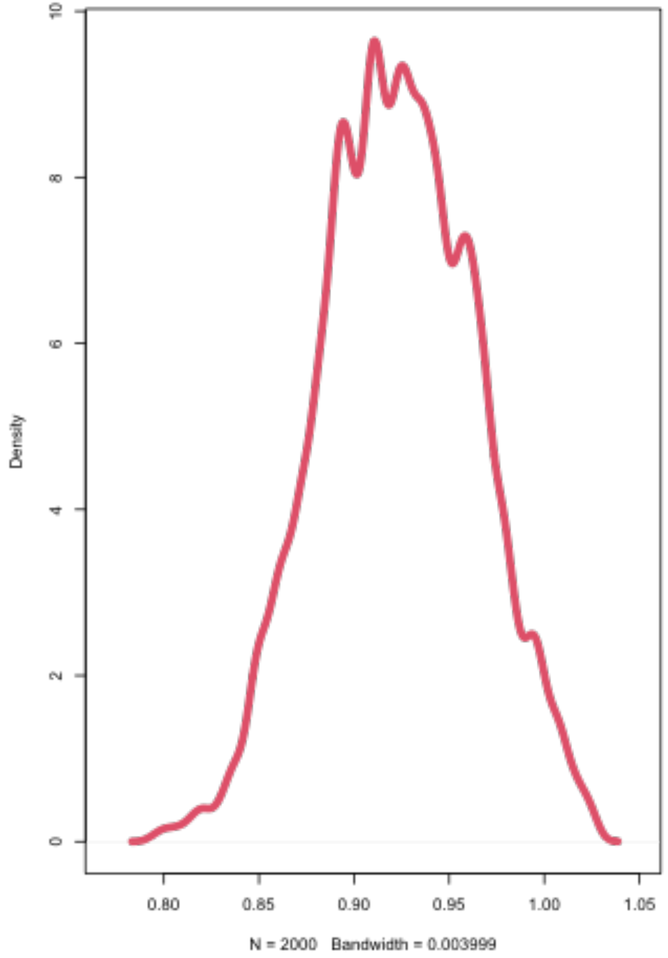
Distribuição posteriori estimada

Parecem normais?

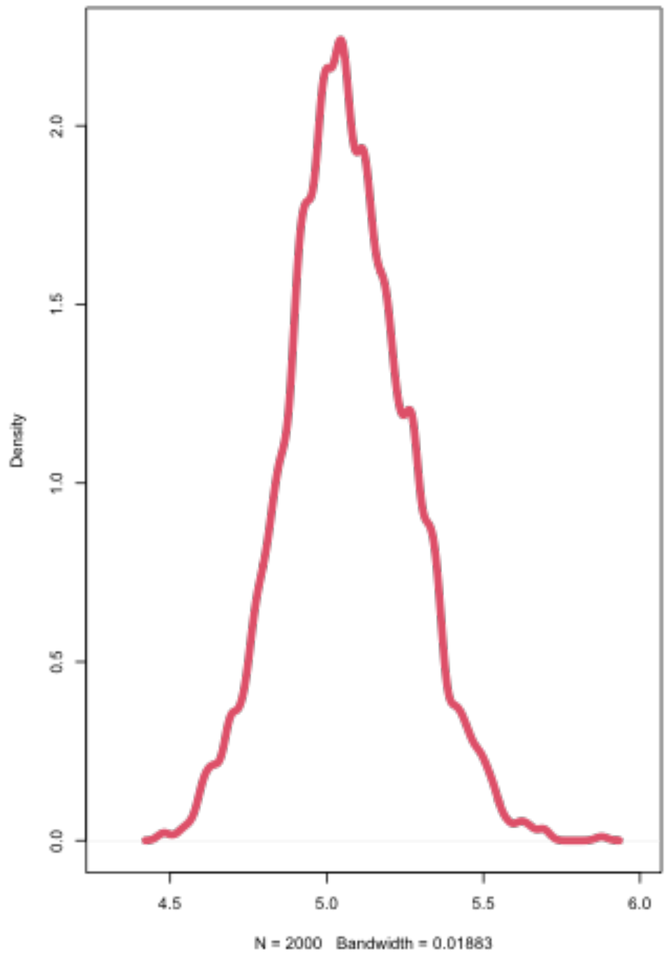
a



b



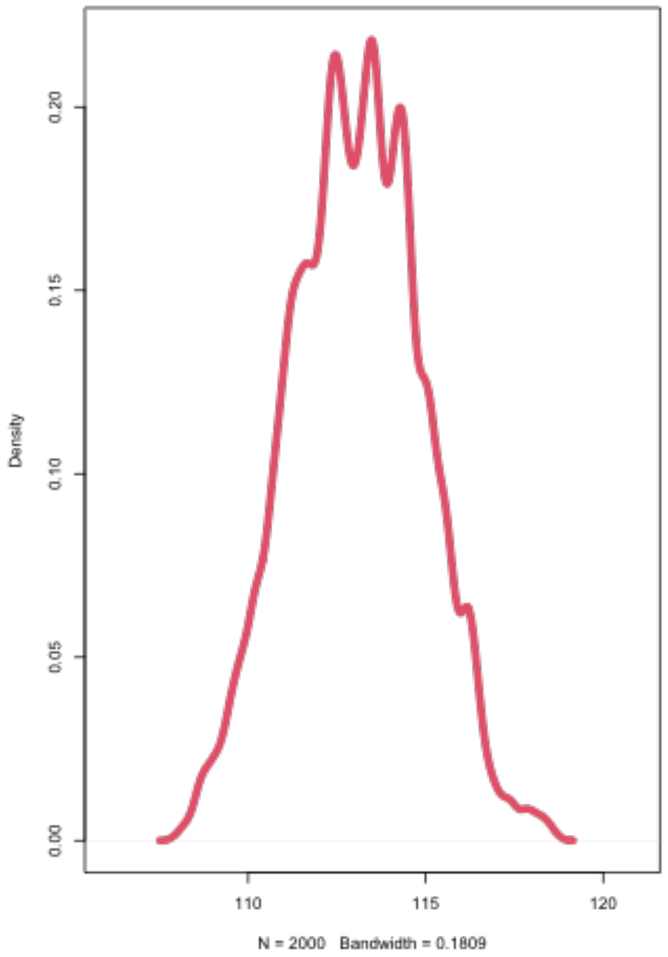
sigma



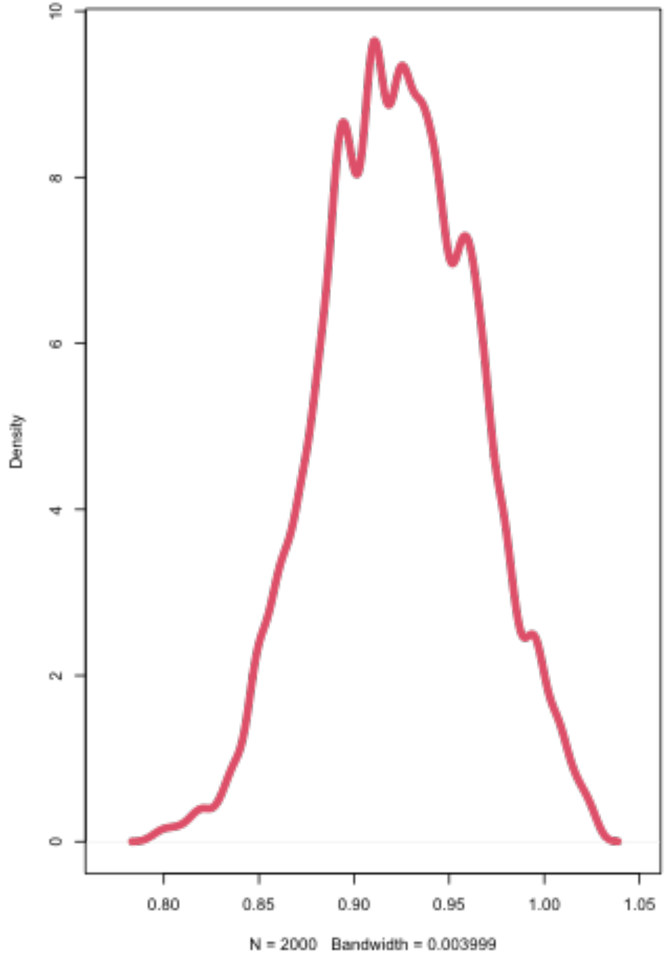
Distribuição posteriori estimada

Parecem normais?

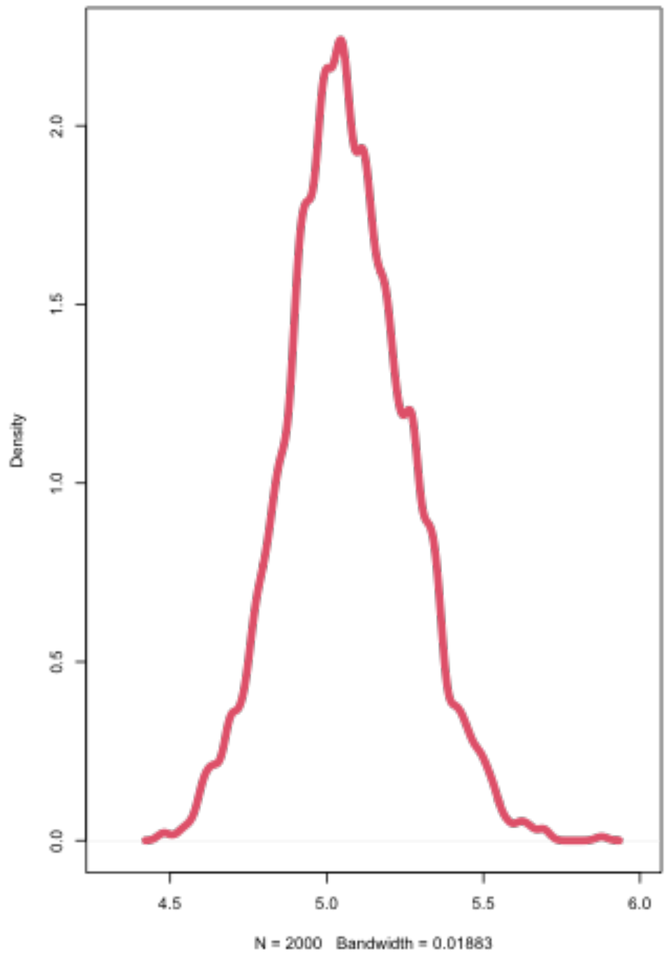
a



b



sigma




```
> samples
# A tibble: 2,000 × 3
       a     b sigma
   <dbl> <dbl> <dbl>
 1  115.  0.889  4.78
 2  109.  1.02   5.30
 3  112.  0.928  5.07
 4  111.  0.949  5.30
 5  111.  0.955  5.04
 6  115.  0.872  5.19
 7  109.  1.01   5.13
 8  117.  0.844  5.00
 9  115.  0.882  4.94
10  112.  0.939  4.95
# … with 1,990 more rows
```