Modelos lineares generalizados

Disciplina BIE5781 – IB – USP

PI

26 de outubro de 2026

Objetivos da aula

- Generalizar o conceito de modelos lineares para outras distribuições de probabilidades;
- Exemplificar essa generalização com modelos Poisson e binomial;
- Mostrar os comandos básicos no R para ajustar e avaliar esses modelos;
- Mostrar que alguns deles pertencem à classe dos modelos lineares generalizados (GLMs);

Onde estamos

Até agora vimos modelos Gaussianos lineares. Ou seja que têm em sua função de verossimilhança:

$$Y \sim \text{Normal}(\mu = a_0 + a_1 X_1,\, \sigma = b_0)$$

$$Y \sim \text{Normal}\left(\mu = a_0 + a_1 X_1 + a_2 X_2,\, \sigma = e^{b_0 + b_1 X_1}\right)$$

$$\dots$$

Para onde vamos

Hoje veremos modelos com verossimilhanças não Gaussianas com preditoras, como:

- Modelos binomiais:

$$Y \sim \text{Bin}(N = n,\, p = g(X_i))$$

- Modelos Poisson:

$$Y \sim \text{Pois}(\lambda = g(X_i))$$

Ou seja

Uma expressão geral modelos estatísticos

$$Y \sim f(Y \mid \Theta = g(X_i))$$
$$\theta_j \sim h_j(\theta_j)$$

Em palavras

- Y é uma variável aleatória, cujos valores têm probabilidades definidas pela função de densidade $f(Y)$, cujos parâmetros Θ são uma função qualquer g de outras medidas (preditoras) X_i.
- Cada um dos parâmetros do conjunto Θ tem uma distribuição a priori $h_j(\theta_j)$

Distribuições de probabilidade discretas

Distribuição Bernoulli

- *Bernoulli* é a distribuição de probabilidades mais simples dentre as variáveis discretas.
- Mais que uma distribuição, é interessante vê-la como um ensaio com resultado estocástico.
- A partir desse ensaio aleatório, podem-se conceituar diversas distribuições de probabilidades de variáveis discretas.

Variável binária

- Dois resultados possíveis:
  - *fracasso* ($X = 0$): o evento não ocorre;
  - *sucesso* ($X = 1$): o evento ocorre.
- Parâmetro: a probabilidade de sucesso (p).

Distribuição Bernoulli: apresentação formal

Função de densidade

$$f(x) = p^x(1-p)^{1-x}, \qquad x = 0, 1$$

Resultados

- Fracasso: $f(0) = P(X = 0) = 1 - p$
- Sucesso: $f(1) = P(X = 1) = p$

Momentos

- Esperança: $E[X] = p$
- Variância: $\mathbf{Var}[X] = p\,(1-p)$

Distribuição binomial

Situação

- Uma série de n *ensaios Bernoulli independentes*
- Parâmetro tamanho da série: n
- Parâmetro probabilidade de sucesso *constante*: p
- Distribuição de máxima entropia para variáveis que são contagens até um valor máximo possível.

Variável

- $X =$ o número de sucessos nos n ensaios
- Espaço amostral: $x = 0, 1, 2, \ldots, n$

Exemplos: nº de caras em 10 lançamentos de moeda; nº de fêmeas em ninhadas de 5 filhotes; nº de cobaias mortas em bioensaio (dose-resposta).

Gráfico: distribuição binomial

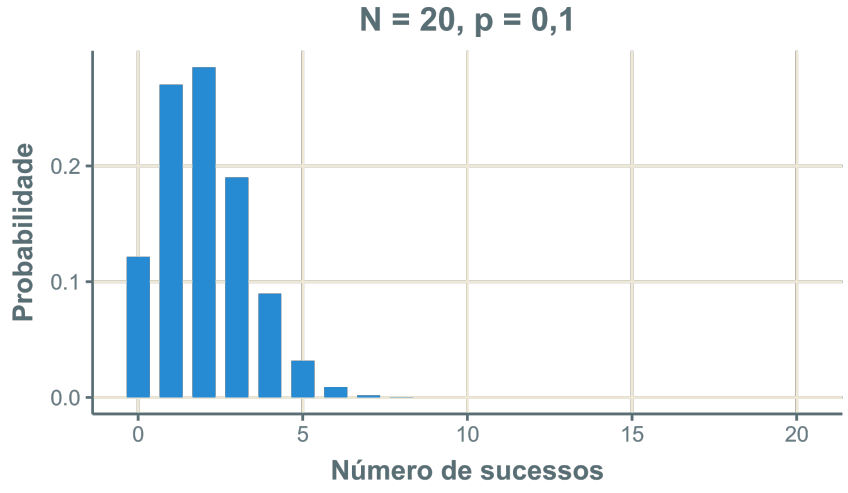


Gráfico: distribuição binomial

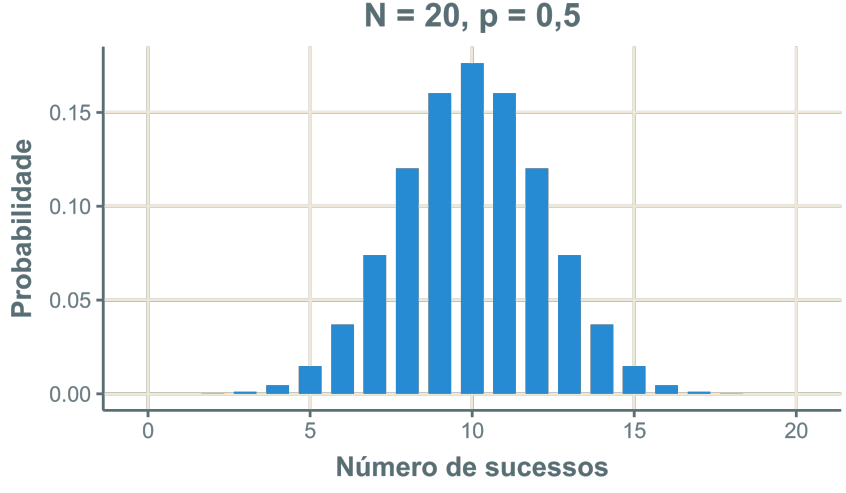
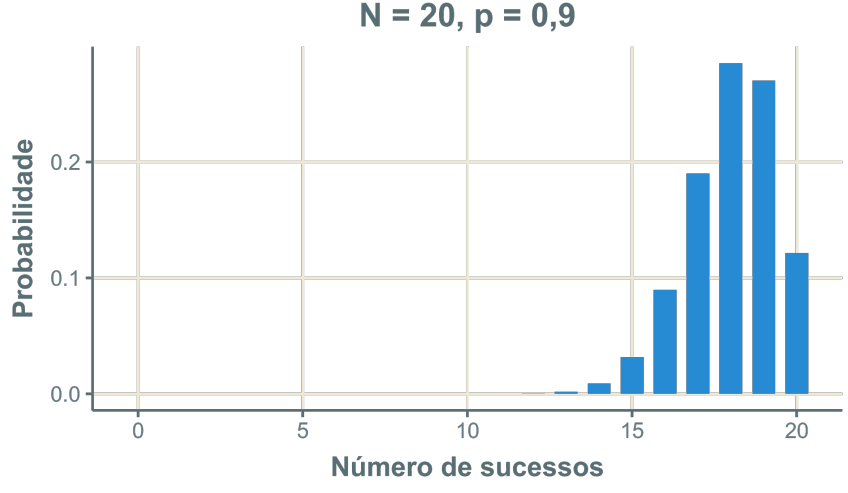


Gráfico: distribuição binomial



Distribuição binomial: apresentação formal

Função de densidade

$$f(x) = \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x}, \qquad x = 0, 1, 2, \ldots, n$$

Parâmetros

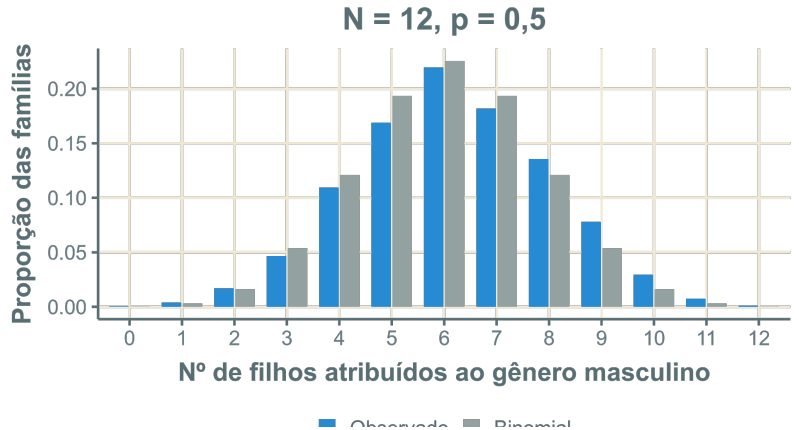
- n: Tamanho da amostra (número de ensaios);
- p: Probabilidade de sucesso em cada ensaio.

Momentos

- Esperança: $E[X] = n\,p$
- Variância: $\mathrm{Var}[X] = n\,p\,(1-p)\,]$

Exemplo de distribuição binomial

6.115 famílias de 12 filhos na Saxônia: nº de filhos atribuídos ao gênero masculino ao nascer (Geissler 1889, *apud* Lindsey (2004)):



Distribuição Poisson

Situação

- Contagem de eventos independentes.
- A contagem é *por unidade* de tempo e/ou espaço.
- Os eventos ocorrem a uma taxa constante por unidade (λ).
- Distribuição de máxima entropia para contagens sem limite máximo pré-definido

Variável

- $X =$ o número de eventos em cada unidade.
- Espaço amostral: $x = 0, 1, 2, \ldots$

Exemplos: nº de árvores por parcela; nº de capturas por unidade de tempo; número de casos por 100 mil habitantes.

Gráfico: distribuição Poisson

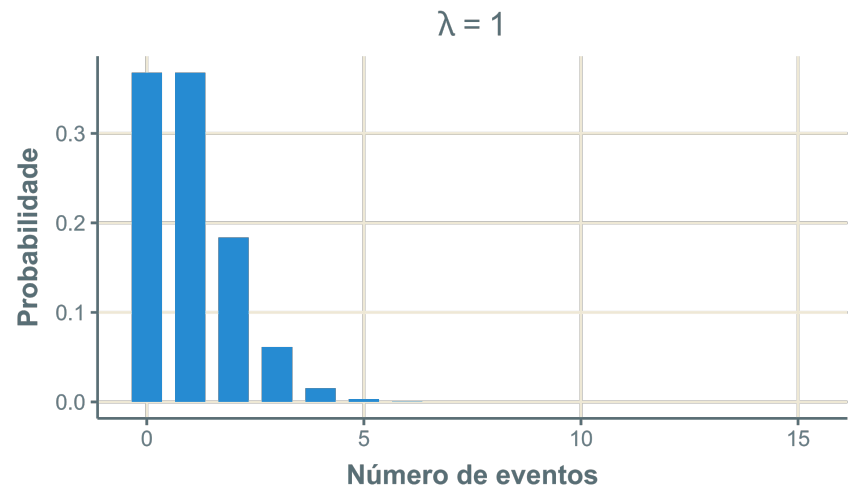


Gráfico: distribuição Poisson

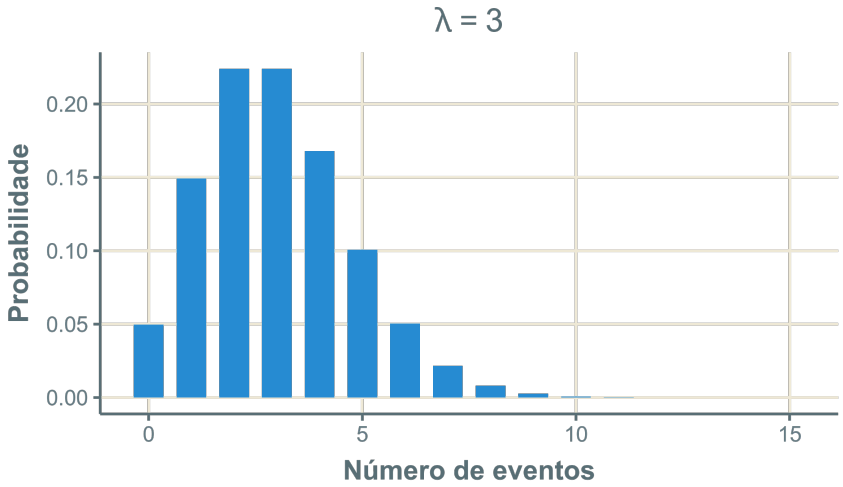
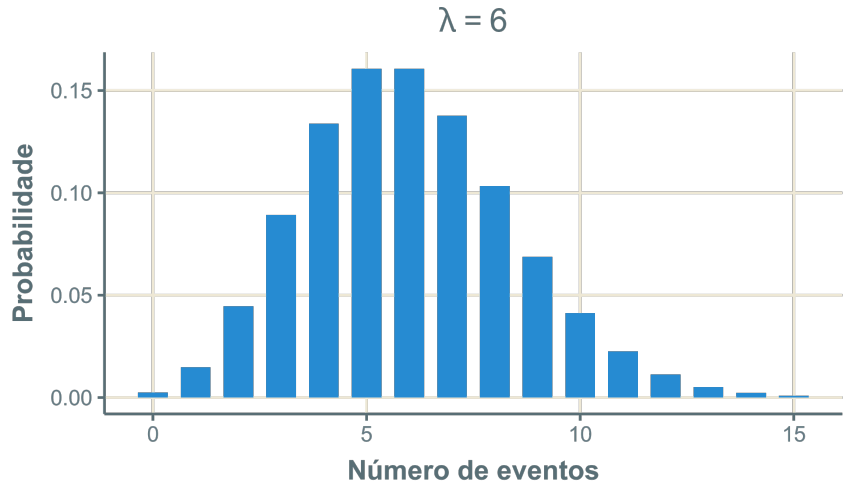


Gráfico: distribuição Poisson



Distribuição Poisson: apresentação formal

Função de densidade

$$f(x) = \frac{\lambda^x \, e^{-\lambda}}{x!}, \qquad x = 0, 1, 2, \ldots$$

Parâmetro

λ: taxa de ocorrência por unidade de observação

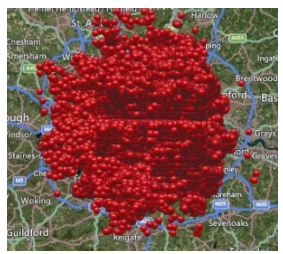
Momentos

- Esperança: $E[X] = \lambda$
- Variância: $\mathbf{Var}[X] = \lambda$
- Parâmetro λ = esperança = variância

Exemplo de distribuição Poisson

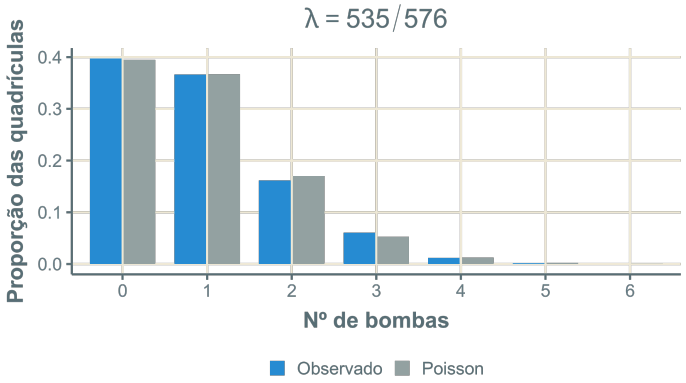
Distribuição de bombas V1 lançadas em Londres na II Guerra:

$$\lambda = \frac{535 \text{ bombas}}{576 \text{ quadriculas}} \simeq 0{,}929/\text{quadricula}$$



Exemplo de distribuição Poisson

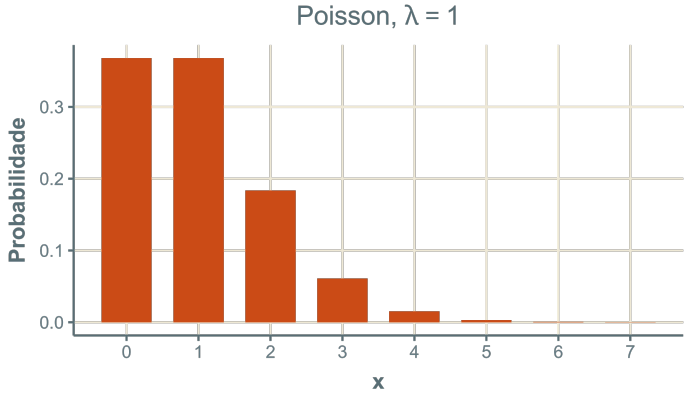
Distribuição dos locais de impacto de bombas V1 lançadas em 1944 no sul de Londres:



Clarke 1946

Caso limite

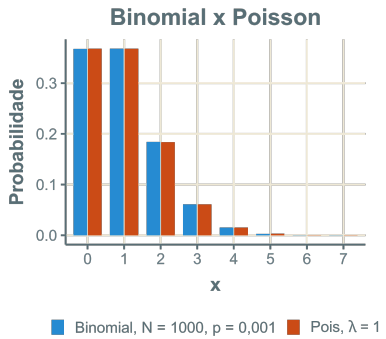
A Poisson é um caso limite da distribuição binomial.



Caso limite

A Poisson é um caso limite da distribuição binomial:

- quando o tamanho da amostra tende a infinito ($n \to \infty$),
- a probabilidade de sucesso tende a zero ($p \to 0$),
- mas o valor esperado permanece constante: $np = \lambda$.



Distribuições de probabilidade no R

Binomial

- `dbinom(x, size, prob, log = FALSE)`
- `pbinom(q, size, prob, lower.tail = TRUE, log.p = FALSE)`
- `qbinom(p, size, prob, lower.tail = TRUE, log.p = FALSE)`
- `rbinom(n, size, prob)`

Poisson

- `dpois(x, lambda, log = FALSE)`
- `ppois(q, lambda, lower.tail = TRUE, log.p = FALSE)`
- `qpois(p, lambda, lower.tail = TRUE, log.p = FALSE)`
- `rpois(n, lambda)`

... e funções equivalentes para outras distribuições (`?Distributions`).

Modelos com distribuição binomial

Modelos binomiais

- Descrevem o número de ocorrências de uma variável binária em um certo número de tentativas, em função de variáveis preditoras contínuas ou discretas.

Úteis principalmente quando temos:

- Respostas binárias (regressão logística!)
- Proporções

Exemplos de respostas binomiais:

- Presença de alguma espécie em manchas, fragmentos, sítios;
- Ocorrência de morte, doença ou qualquer outro evento por indivíduo;
- Proporção de frutos parasitados.

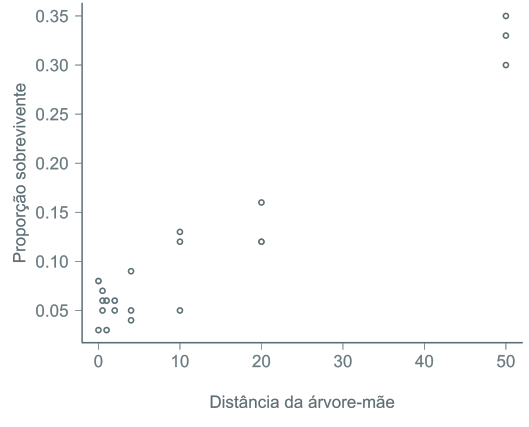
Modelos binomiais: um exemplo

Sobrevivência de sementes colocadas a diferentes distâncias da árvore-mãe

- 8 distâncias, 3 réplicas de 100 sementes
- Resposta: número de sobreviventes após 60 dias

	distancia	nsobrev
1	0.0	8
2	0.0	8
3	0.0	3
4	0.5	7
5	0.5	6
6	0.5	5
19	20.0	12
20	20.0	12
21	20.0	16
22	50.0	33
23	50.0	35
24	50.0	30

Modelos binomiais: um exemplo



Modelo binomial: função logística

- A verossimilhança de nosso modelo é:

$$Y \sim \text{Bin}(N = 100, p = g(\text{distancia}))$$

- Que função usar para o efeito da distância sobre p?
- Uma função sigmoide limitada entre zero e um, como:

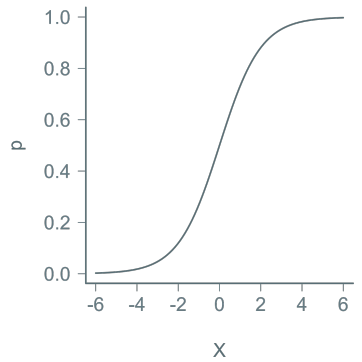
$$p = \frac{e^{a_0 + a_1 \text{dist}}}{1 + e^{a_0 + a_1 \text{dist}}}$$

- O que implica que:

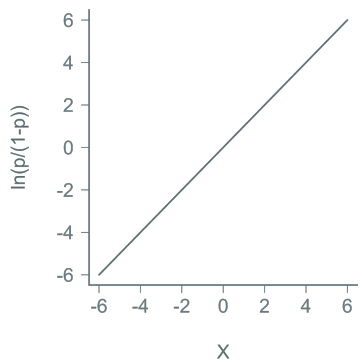
$$\ln\left(\frac{p}{1-p}\right) = a_0 + a_1 \text{dist}$$

Modelo binomial: funções logística e *logito*

$$p = \frac{e^{a+bX}}{1 + e^{a+bX}}$$



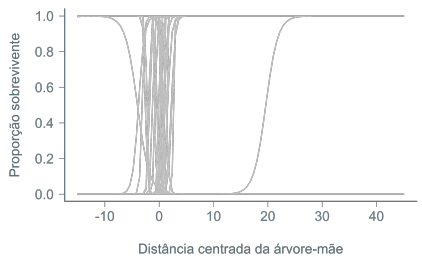
$$Y = \ln\left(\frac{p}{1-p}\right)$$



Modelo binomial: ajuste Bayesiano no R

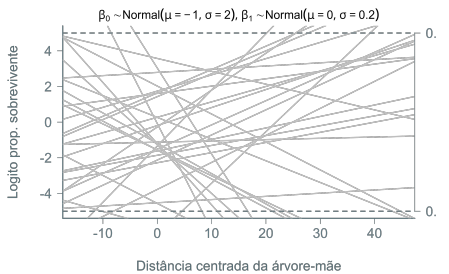
Distribuições *a priori*

- Para modelos lineares, já vimos que distribuições *a priori* achatadas podem expressar expectativas irrealistas ou mesmo impossíveis de aocntecer.
- Para preditores não lineares, distribuições *a priori* muito achatadas de parâmetros não resultam tipos de curva de resposta bem distribuídas. Ao contrário, podem expressar uma premissa de maior probabilidade de uma forma específica de resposta.
- Ao lado: 30 curvas logísticas geradas com 30 valores dos dois parâmetros sorteados de uma normal com $\mu = 0$ e $\sigma = 10$



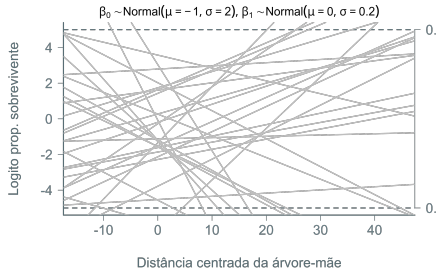
Modelo binomial: ajuste Bayesiano no R

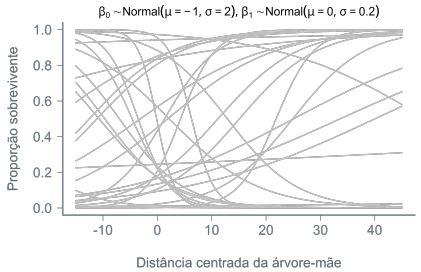
Distribuições *a priori*



Modelo binomial: ajuste Bayesiano no R

Distribuições *a priori*





Modelo binomial: ajuste Bayesiano no R

Especificação do modelo

$$Y_i \sim \text{Binomial}(N, p_i)$$

$$\ln\left(\frac{p_i}{1-p_i}\right) = \beta_0 + \beta_1 \text{Dist}_i$$

$$N = 100$$

$$\beta_0 \sim \text{Normal}(\mu = -1, \sigma = 2)$$

$$\beta_1 \sim \text{Normal}(\mu = 0, \sigma = 0{,}2)$$

```
> mbin1.f <- alist(
+     nsobrev ~ dbinom(100 , p),
+     logit(p) <- b0 + b1*distc,
+     b0 ~ dnorm(-1, 2),
+     b1 ~ dnorm(0, 0.2)
+     )
>
> mbin1 <- ulam(mbin1.f,
+               data = pred.seed,
+               chains = 4,
+               cores = 4)
```


Modelo binomial: ajuste Bayesiano no R

Coeficientes e seus intervalos

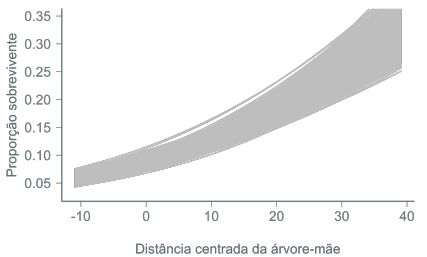
```
 > precis(mbin1)

          mean          sd        5.5%       94.5%     rhat ess_bulk
b0 -2.33241252 0.076416318 -2.45667947 -2.21183519 1.004075 503.5336
b1  0.04158737 0.003319859  0.03612441  0.04681036 1.002019 779.4852
```


Modelo binomial: ajuste Bayesiano no R

Posterior do preditor

```
> mbin1.post <- extract.samples(mbin1)
> plot(I(nsobrev/100) ~ distc, data=pred.s
+      xlab="Distância centrada da árvore-
+      ylab="Proporção sobrevivente", type
> for(i in 1:length(mbin1.post$b0))
+     with(mbin1.post,
+          curve(exp(b0[i] + b1[i]*x) /
+                (1 + exp(b0[i] + b1[i]*x)
+                    add=TRUE, col="grey")
```



Modelo binomial: ajuste Bayesiano no R

Posterior dos previstos

Crie uma tabela com os valores dos preditores para fazer previsões e passe à função `sim()`:

```
> grade <- data.frame(distc=unique(pred.seed$distc))
> mbin1.sim <- sim(mbin1, data = grade, n = 1000)
```

Objeto resultante: matriz de amostras de valores previstos (linhas) para cada valor do preditor (colunas):

```
> head(mbin1.sim, 3)

     [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8]
[1,]    7    5   10   11    5   10   16   39
[2,]    6    8    3    8    7    6    8   28
[3,]    5    4    8    6    9    8   15   40

> dim(mbin1.sim)

[1] 1000    8
```


Modelo binomial: ajuste Bayesiano no R

Posterior dos previstos

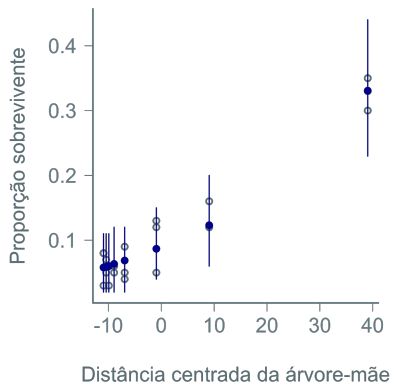
Com estas amostras, você pode calcular médias e intervalos de incerteza para cada valor previsto:

```
     distc   media     inf  sup
1 -10.9375 0.05795 0.02000 0.11
2 -10.4375 0.05885 0.02000 0.11
3  -9.9375 0.06004 0.02000 0.11
4  -8.9375 0.06342 0.02000 0.12
5  -6.9375 0.06867 0.02000 0.12
6  -0.9375 0.08677 0.04000 0.15
7   9.0625 0.12315 0.06000 0.20
8  39.0625 0.33069 0.22975 0.44
```


Modelo binomial: ajuste Bayesiano no R

Posterior dos previstos

```
> plot(I(nsobrev/100) ~ distc, data=pred.s
+      xlab="Distância centrada da árvore-
+      ylab="Proporção sobrevivente",
+      ylim = c(min(mbin1.pred$inf),
+               max(mbin1.pred$sup)))
> points(media ~ distc, data = mbin1.pred,
+        col="darkblue", pch = 19)
> with(mbin1.pred,
+      segments(x0 = distc, x1 = distc,
+          y0 = inf, y1 = sup, lwd=1.5,
+          col = "darkblue"))
```



Modelos Poisson

Modelos Poisson

- Descrevem contagens de eventos independentes em função de variáveis preditoras contínuas ou discretas.
- Úteis principalmente quando temos:
  - contagens com médias baixas;
  - contagens com variância igual à média.
- Exemplos de respostas Poisson:
  - Número de capturas, avistamentos, registros por unidade de tempo ou espaço;
  - Taxas de ocorrência de eventos (*e.g.* fotos/hora, células/área, casos/pacientes).

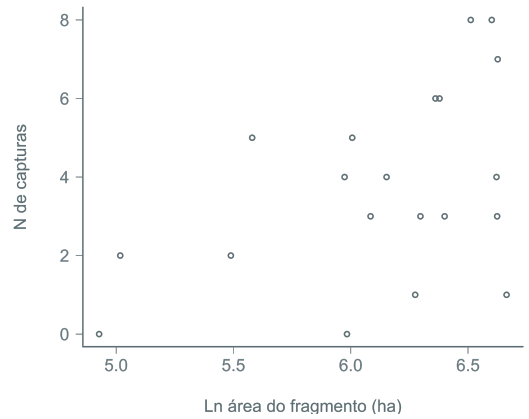
Modelos Poisson: um exemplo

Amostragem de aves em fragmentos de floresta

- Capturas de *Pyriglena leucoptera* em redes de neblina
- 20 fragmentos de diferentes tamanhos, 500 horas/rede
- Resposta: número de capturas
- Preditora: ln da área do fragmento em ha (a partir de agora, simplesmente "área"):

	area	larea	ncap
1	736	6.601230	8
2	753	6.624065	3
3	265	5.579730	5
4	673	6.511745	8
5	531	6.274762	1
6	439	6.084499	3
15	397	5.983936	0
16	755	6.626718	7
17	784	6.664409	1
18	138	4.927254	0
19	406	6.006353	5
20	470	6.152733	4

Modelo Poisson: gráfico



Modelos Poisson

- A verossimilhança de nosso modelo é:

$$Y_i \sim \text{Poisson}(\lambda_i = g(\ln \text{area}_i))$$

- Que função usar para o efeito do logaritmo da área sobre λ?
- Uma função monotônica positiva, como a exponencial:

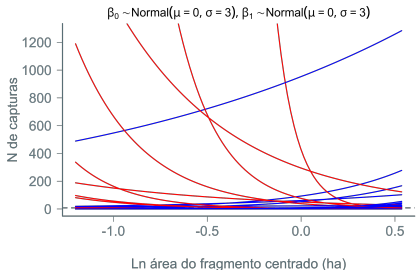
$$\lambda_i = e^{\beta_0 + \beta_1 \ln \text{area}_i}$$

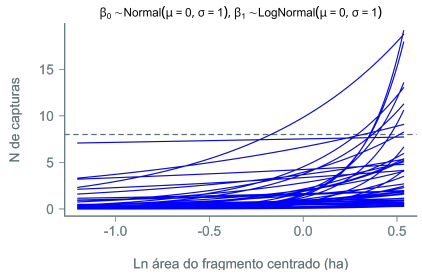
- O que implica que:

$$\ln(\lambda_i) = \beta_0 + \beta_1 \ln \text{area}_i$$

Modelo Poisson: ajuste Bayesiano no R

Distribuições *a priori*





Modelo Poisson: ajuste Bayesiano no R

Especificação do modelo

$$
\begin{aligned}
Y_i &\sim \text{Poisson}(\lambda) \\
\ln \lambda &= \beta_0 + \beta_1 \ln \text{area}_i \\
\beta_0 &\sim \text{Normal}(\mu = 0, \sigma = 1) \\
\beta_1 &\sim \text{LogNormal}(\mu = 0, \sigma = 1)
\end{aligned}
$$

```
> mpois1.f <- alist(
+     ncap ~ dpois(lambda),
+     log(lambda) <- b0 + b1*lareac,
+     b0 ~ dnorm(0, 1),
+     b1 ~ dlnorm(0, 1)
+     )
>
> mpois1 <- ulam(mpois1.f,
+                data = aves,
+                chains = 4,
+                cores = 4)
```


Modelo Poisson: ajuste Bayesiano no R

Coeficientes e seus intervalos

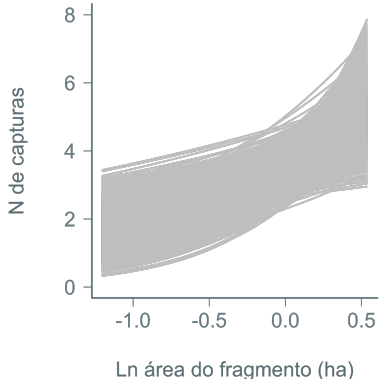
```
 > precis(mpois1)

        mean        sd      5.5%    94.5%     rhat ess_bulk
b0 1.2354508 0.1199512 1.0306648 1.418205 1.006483 973.8309
b1 0.7112874 0.2674147 0.3095376 1.161840 1.008183 757.4853
```


Modelo Poisson: ajuste Bayesiano no R

Posterior do preditor

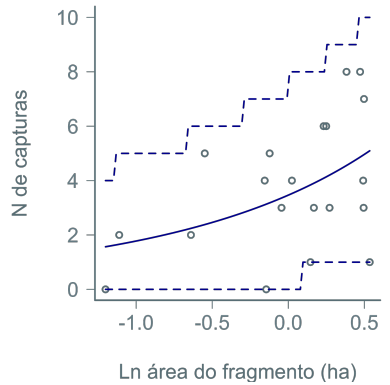
```
> grade <- data.frame(
+     lareac = seq(min(aves$lareac),
+                  max(aves$lareac),
+                  length=100))
> mpois1.lp <- link(mpois1, data = grade)
> plot(ncap~lareac, data=aves,
+      xlab="Ln área do fragmento (ha)",
+      ylab="N de capturas", type="n")
> for(i in 1:nrow(mpois1.lp))
+     lines(grade$lareac, mpois1.lp[i,],
+           col="grey")
```



Modelo Poisson: ajuste Bayesiano no R

Posterior dos previstos

```
> ## Posterior dos previstos
> mpois1.lpm <- apply(mpois1.lp,2,mean)
> ## quantis de cada Poisson
> inf <- qpois(0.025, lambda= mpois1.lpm)
> sup <- qpois(0.975, lambda= mpois1.lpm)
> ## IC e média
> mpois1.pred <- data.frame(
+     lareac=grade$lareac,
+     media = mpois1.lpm,
+     inf   = inf,
+     sup   = sup)
```



GLMs: exemplo Poisson

Função `glm` no R

```
> aves.glm1 <- glm(ncap ~ lareac, data = aves,
+                  family=poisson)
> coef(aves.glm1)

(Intercept)      lareac
  1.2643537   0.7190406

> coef(mpois1)

       b0        b1
1.2354508 0.7112874
```


Modelos lineares generalizados (GLMs)

- Generalizam a lógica da regressão linear Gaussiana para algumas outras distribuições;
- Preservam várias propriedades dos modelos lineares Gaussianos;
- Abrangem vários modelos sob um conjunto único de soluções analíticas e de propriedades matemáticas;
- Ou seja, uma teoria unificada;
- Definiram a sintaxe de modelos do R e de várias outras linguagens computacionais.

Modelos lineares generalizados (GLMs)

J. R. Statist. Soc. A,
(1972), **135**, *Part* 3, p. 370

Generalized Linear Models

By J. A. Nelder and R. W. M. Wedderburn

Rothamsted Experimental Station, Harpenden, Herts

Summary

The technique of iterative weighted linear regression can be used to obtain maximum likelihood estimates of the parameters with observations distributed according to some exponential family and systematic effects that can be made linear by a suitable transformation. A generalization of the analysis of variance is given for these models using log-likelihoods. These generalized linear models are illustrated by examples relating to four distributions; the Normal, Binomial (probit analysis, etc.), Poisson (contingency tables) and gamma (variance components).

The implications of the approach in designing statistics courses are discussed.

A família exponencial de distribuições

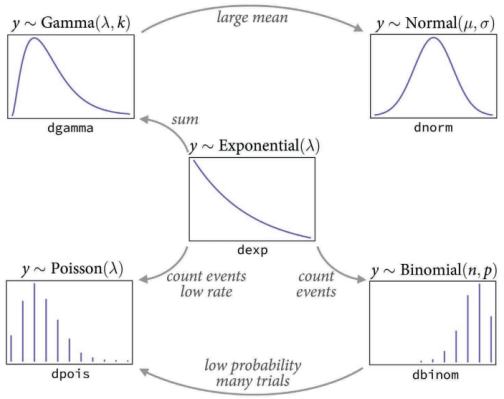


Figura 10.6 de McElreath (2016)

A função de ligação

- Os GLMs têm esse nome porque generalizam a ideia de estabelecer uma relação do valor esperado com uma combinação linear de covariáveis:

$$\eta(E[Y]) = \beta_0 + \beta_1 X_1 + \ldots + \beta_i X_i = \sum_0^i \beta_i X_i$$

- A função η estabelece essa relação. Ela é chamada de função de ligação.
- Na teoria de GLMs, há uma generalização dos métodos de mínimos quadrados para ajuste de modelos não-gaussianos e com funções de ligação.

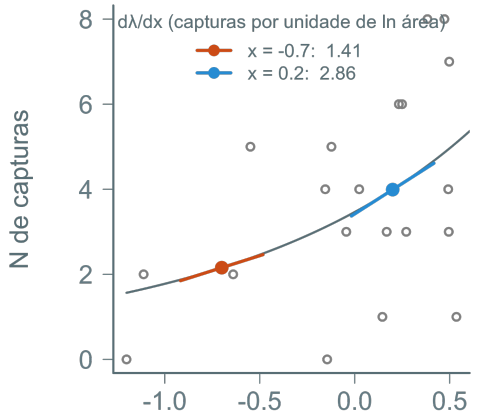
Consequências da função de ligação: coeficientes difíceis de interpretar

	Média	2,5%	97,5%
β_0	1,235	0,992	1,462
β_1	0,711	0,239	1,269

O efeito da área sobre o número esperado de capturas é a derivada:

$$\frac{d\lambda}{dx} = \beta_1 e^{\beta_0 + \beta_1 x} = \beta_1 \lambda(x)$$

O efeito de x depende do próprio valor de x: é como se x interagisse consigo mesmo.

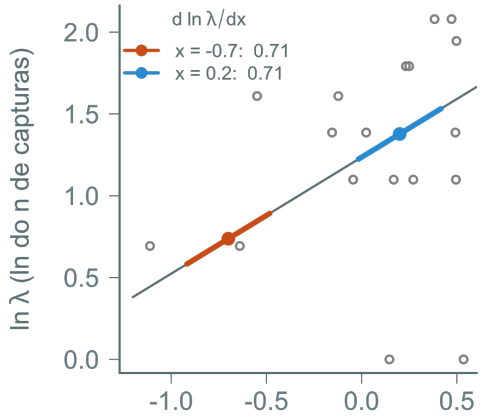


Na escala da função de ligação, o efeito é constante

$$\ln \lambda = \beta_0 + \beta_1 x$$

$$\frac{d \ln \lambda}{dx} = \beta_1$$

- Na escala do preditor linear, o efeito de x é o mesmo em qualquer ponto: $\beta_1 \approx 0.71$.
- As tangentes nos dois pontos coincidem com a própria reta.
- Na escala da resposta (número de capturas), o efeito depende de onde estamos na curva.



Função de ligação log: efeito relativo é constante

Dividindo a derivada pelo valor esperado:

$$\frac{1}{\lambda}\frac{d\lambda}{dx} = \frac{d\ln\lambda}{dx} = \beta_1$$

- O efeito **absoluto** de x (em número de capturas) depende de x.
- O efeito **relativo** é constante: cada unidade a mais de x multiplica o número esperado de capturas por e^{β_1}, em qualquer ponto da curva.
- Por isso, nos modelos Poisson com ligação log, interpretamos e^{β_1} como um efeito multiplicativo.

x	λ(x)	λ(x+1)	Diferença	Razão
-0,7	2,16	4,29	2,13	2,11
0,2	3,99	8,47	4,47	2,11

A diferença muda entre os dois pontos, mas a razão é a mesma, e igual a $e^{\beta_1} \approx 2.11$.

O que é constante depende da função de ligação

Para qualquer função de ligação g, o efeito é constante na escala da ligação:

$$g(\mu(x+1)) - g(\mu(x)) = \beta_1$$

O que esse efeito constante representa na escala da resposta depende de g:

Ligação	Constante a cada unidade de x	Interpretação de β_1
Identidade: μ	diferença: $\mu(x+1) - \mu(x)$	efeito aditivo
Log: $\ln\mu$	razão: $\mu(x+1)/\mu(x)$	e^{β_1}: efeito multiplicativo
Logito: $\ln\frac{p}{1-p}$	razão das chances: $\frac{p(x+1)/[1-p(x+1)]}{p(x)/[1-p(x)]}$	e^{β_1}: razão de chances

Com funções de ligação não lineares, a forma mais segura de interpretar os efeitos é calcular os previstos na escala da resposta e compará-los.

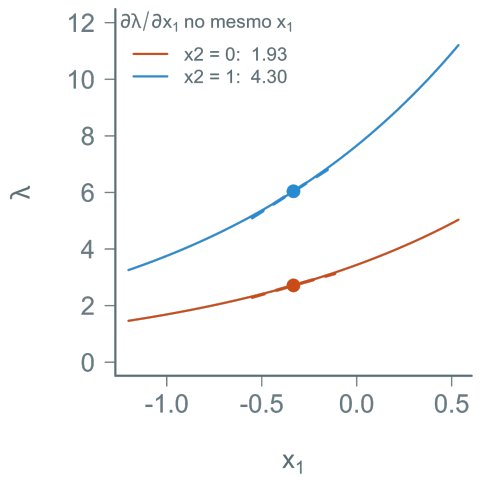
Com duas preditoras: interação embutida

$$\ln\lambda = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

Não há nenhum termo de interação no preditor linear. Mas:

$$\frac{\partial\lambda}{\partial x_1} = \beta_1\, e^{\beta_0+\beta_1 x_1+\beta_2 x_2} = \beta_1\,\lambda(x_1, x_2)$$

- O efeito absoluto de x_1 depende também do valor de x_2.
- Com função de ligação não linear, as preditoras **interagem** na escala da resposta, mesmo sem termos de interação no modelo (McElreath 2016).



Mensagens para levar para casa

- Modelos generalizados lineares estendem a lógica de modelos lineares Gaussianos para outras distribuições de resposta.
- Para respostas que são contagens até um máximo, a distribuição de máxima entropia é a binomial.
- A Poisson é um caso particular da binomial, usado para contagens sem um máximo conhecido.
- Os glms clássicos inluem outras distribuição da chamada família exponencial. Mas na abordagem Bayesiana você pode criar modelos com qualquer distribuição.
- A necessidade de escolher uma função de ligação para o preditor linear em glms requer cuidados adicionais na especificação, estimativa e interpretação desses modelos.

Para saber mais

- McElreath, R. (2016). Statistical rethinking: A Bayesian course with examples in R and Stan (Vol. 122). Boca Raton, FL: CRC press. caps 10 a 12.
- Bolker, B.M. 2008. Ecological Models and Data in R. Princeton: Princeton University Press, caps. 6 e 9.
- Dobson, A.J. 1990. An Introduction to Generalized Linear Models. London: Chapman and Hall.