# Comparação de modelos

## Disciplina BIE5781 – IB – USP

### PI (Paulo Inácio Prado)

### 23 de outubro de 2026

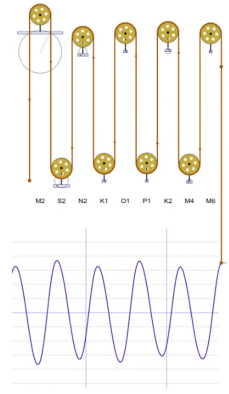
# MUITO IMPORTANTE

Toda esta aula é sobre comparar modelos quanto ao seu **poder preditivo** ou seja

> A capacidade do modelo de aproximar o processo probabilístico que gera os dados

Não estamos comparando modelos quanto à sua capacidade de revelar relações de causa e efeito.

Exemplo de modelo mecânico e determinístico: a máquina de Kelvin (1872) prevê as marés muito bem, sem representar o mecanismo físico que produz as marés.



Simulação: National Oceanography Centre / Tide and Time



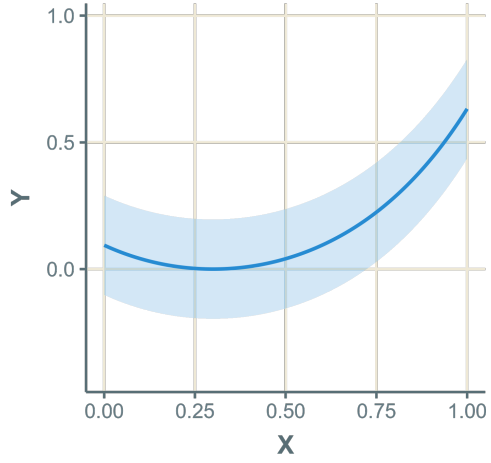
## Um processo gerador

$$Y \sim \text{Normal}(\mu, \sigma)$$

$$\mu = e^{(X-0{,}3)^2} - 1$$

$$\sigma = 0{,}1$$

A linha mostra o valor esperado $\mu$, e a faixa, o intervalo que contém 95% dos valores de $Y$ para cada valor de $X$.





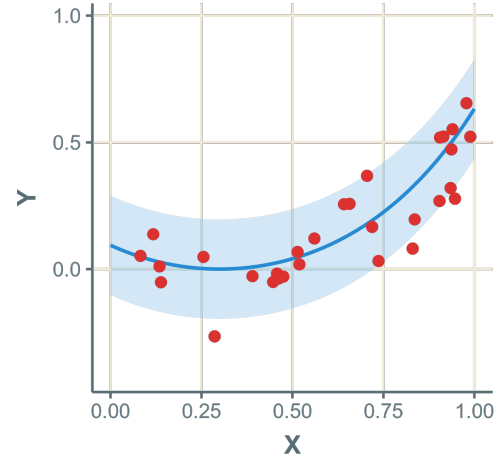

## Dados gerados por este processo

$$Y \sim \text{Normal}(\mu, \sigma)$$

$$\mu = e^{(X-0{,}3)^2} - 1$$

$$\sigma = 0{,}1$$

Uma amostra de 30 observações sorteadas deste processo.



# Modelos que vamos ajustar: polinômios

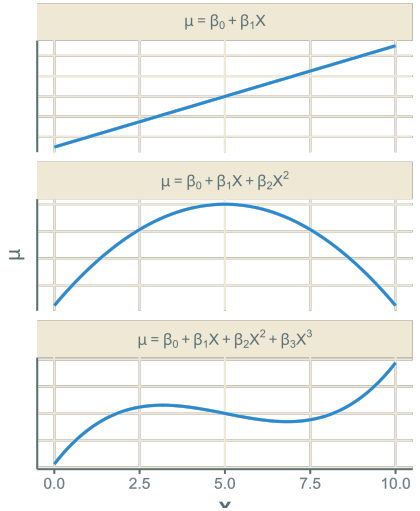
**Expressão geral** de um polinômio de grau $p$:

$$\mu = \beta_0 + \sum_{j=1}^{p} \beta_j X^j$$

**Exemplos**

- Grau 1 (reta): $\mu = \beta_0 + \beta_1 X$
- Grau 2: $\mu = \beta_0 + \beta_1 X + \beta_2 X^2$
- Grau 3: $\mu = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3$

Todos são **preditores lineares**: as potências de $X$ são novas variáveis preditoras.






# Modelos que vamos ajustar: especificação

$$y_i \sim \text{Normal}(\mu_i,\ \sigma)$$

$$\mu_i = \beta_0 + \sum_{j=1}^{p} \beta_j\, x_i^j$$

$$\beta_0 \sim \text{Normal}(0,\ 1)$$

$$\beta_j \sim \text{Normal}(0,\ 10)$$

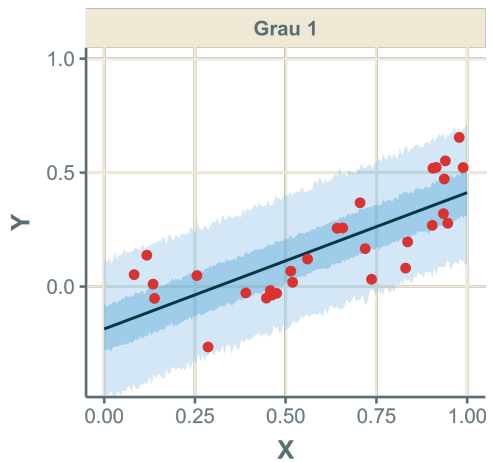
$$\sigma \sim \text{Exponencial}(1)$$

- $x_i$ e $y_i$: valores de $X$ e $Y$ padronizados (escore z).
- $p$: grau do polinômio. Vamos ajustar modelos de graus 1, 2, 4 e 6.
- Distribuições a priori **pouco informativas** para os coeficientes $\beta_j$: permitem valores muito grandes.
- Ajuste com a função `quap()` do pacote *rethinking*.



# Subajuste (*underfitting*)

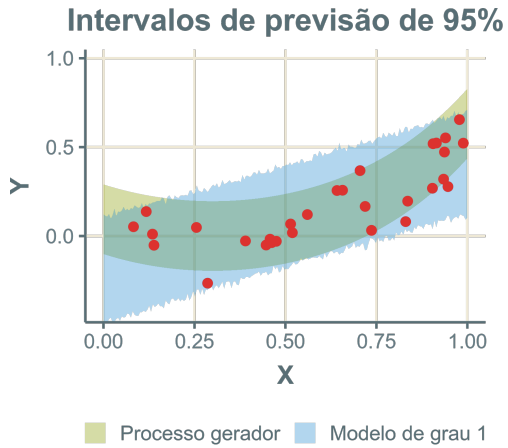
> "Failure to identify features in the data-generating process that are strongly replicable."
>
> Burnham & Anderson (2002)






# Subajuste (*underfitting*)

> "Failure to identify features in the data-generating process that are strongly replicable."
>
> Burnham & Anderson (2002)



# Log-verossimilhança e distância ao processo gerador

- Um modelo que aproxima bem o processo gerador atribui aos dados probabilidades próximas das que o processo gerador atribui.
- Akaike mostrou que a log-verossimilhança de um modelo expressa a informação sobre o processo gerador contida no modelo.
- Mostrou também que a diferença de log-verossimilhança entre dois modelos estima a diferença na informação perdida por cada um deles ao descrever o processo.
- Assim, essa diferença é um critério para encontrar o modelo com maior poder preditivo.



Hirotugu Akaike (1927–2009)



# Diferenças entre log-verossimilhanças

**Densidade preditiva pontual em escala log** (*log pointwise predictive density*):

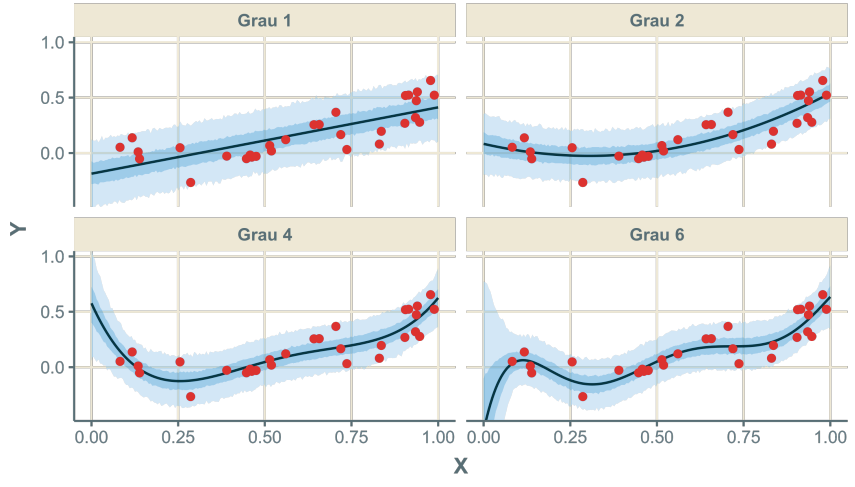
$$\text{lppd}(y, \Theta) = \sum_{i=1}^{n} \log \frac{1}{S} \sum_{s=1}^{S} p(y_i \mid \Theta_s)$$

- $y_i$: cada observação.
- $\Theta_s$: cada uma das $S$ amostras da distribuição posterior dos parâmetros.
- Para cada observação, a média da verossimilhança sobre a posterior; depois, a soma dos logaritmos dessas médias.

| Modelo | lppd |
|---|---|
| Grau 1 | -28,57 |
| Grau 2 | -22,10 |
| Grau 4 | -19,72 |
| Grau 6 | -18,20 |



# Ajuste dos modelos aos dados

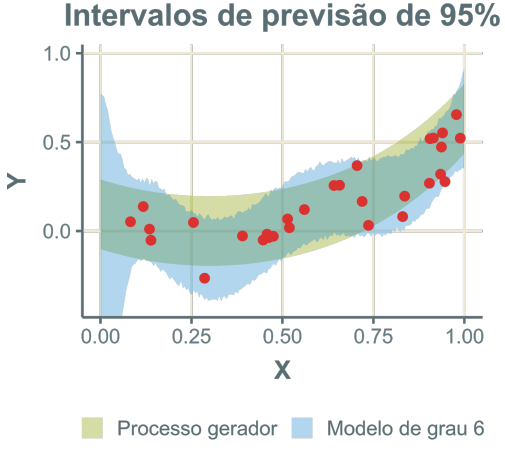





# Sobreajuste (*overfitting*)

> "To make inferences about unique features of the data at hand, as if they applied to all (or most all) samples (hence the population)."
>
> Burnham & Anderson (2002)

Fazer inferências sobre características únicas dos dados disponíveis, como se valessem para todas (ou quase todas) as amostras, ou seja, para a população.



# O critério de informação de Akaike (AIC)

- Akaike descobriu que a log-verossimilhança calculada com os mesmos dados usados para ajustar o modelo superestima a informação sobre o processo que gera os dados.
- Esse viés é proporcional ao número de parâmetros do modelo ( $k$ ).
- Com isso, propôs um estimador não enviesado para grandes amostras:

$$\text{AIC} = -2 \sum_i \log p(y_i \mid \hat{\theta}) + \underbrace{2k}_{\text{correção do viés}}$$



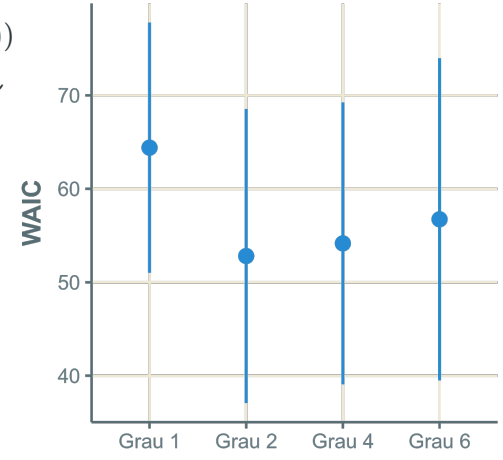
Hirotugu Akaike (1927–2009)



# Critério Bayesiano: WAIC

$$\text{WAIC}(y, \Theta) = -2(\text{lppd} - \underbrace{\sum_i \text{var}_\theta \log p(y_i \mid \theta)}_{\text{penalização}})$$

- A penalização é a soma das variâncias dos logaritimos das probabilidades de cada observação .
- Assim como o AIC, o WAIC expressa perda de informação ao usar o modelo para aproximar o processo gerador dos dados.
- Portanto, menores valores de WAIC indicam maior poder preditivo.






# Comparando modelos com a função `compare()`

```
> compare(m1, m2, m4, m6)

       WAIC       SE     dWAIC      dSE     pWAIC      weight
m2 52.70442 7.849294  0.000000       NA  4.282476 0.666123342
m4 54.59396 7.755510  1.889543 5.995369  7.611386 0.258967730
m6 57.12155 8.846350  4.417125 8.650173 10.385326 0.073179295
m1 64.61155 6.699011 11.907131 7.007359  3.727444 0.001729634
```

- WAIC, SE: WAIC e seu erro padrão.
- dWAIC: diferença para o modelo de menor WAIC.
- dSE: erro padrão dessa diferença.
- pWAIC: penalização; weight: peso de Akaike.

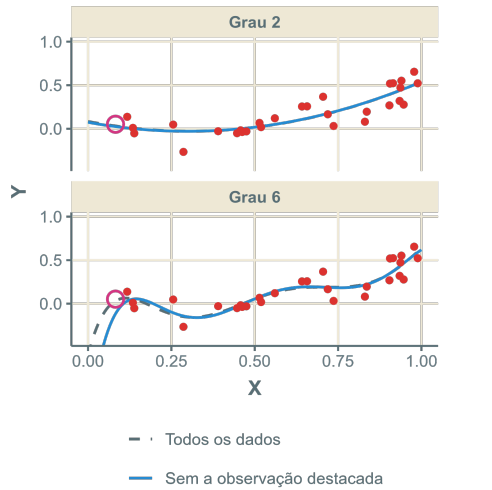
Para comparar dois modelos, verifique se o intervalo **diferença de WAIC ± 2 erros padrão** inclui o zero. Se incluir, os modelos não diferem quanto ao poder preditivo.

Erros padrão das diferenças entre todos os pares: `compare(m1, m2, m4, m6)@dSE`



# Validação cruzada

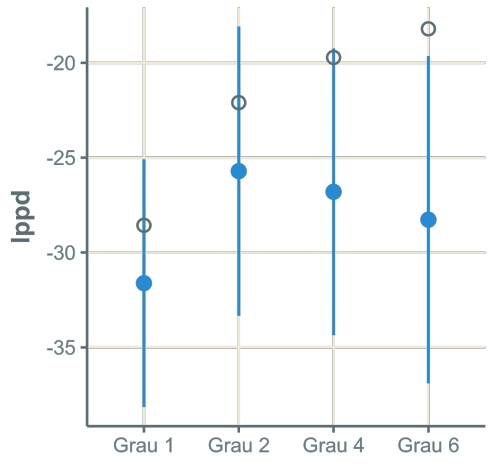
- O poder preditivo de um modelo é medido pela sua capacidade de prever **dados novos**, que não foram usados no ajuste.
- **Validação cruzada**: dividimos os dados em uma parte para **ajuste** (treino) e outra para **teste**. Ajustamos o modelo à primeira e calculamos a log-verossimilhança da segunda.
- **Deixando um de fora** (*leave-one-out*, LOO): cada observação é deixada de fora uma vez, e o modelo é ajustado às $n - 1$ restantes.
- Com $n = 30$ observações, são 30 ajustes de cada modelo.



# lppd por validação cruzada

$$\text{lppd}_{\text{CV}} = \sum_{i=1}^{n} \log \frac{1}{S} \sum_{s=1}^{S} p(y_i \mid \Theta_{-i,s})$$

- $\Theta_{-i,s}$: amostra $s$ da posterior do modelo ajustado **sem** a observação $i$.
- Cada observação é prevista por um ajuste que não a usou: a lppd resultante estima o poder preditivo para dados novos.
- Sem penalização: a lppd calculada com os dados do ajuste (círculos vazios) sempre aumenta com o grau; a lppd por validação cruzada, não.






# PSIS: validação cruzada sem reajustar o modelo

- A LOO exige $n$ ajustes de cada modelo. O **PSIS** (*Pareto-smoothed importance sampling*) aproxima a LOO usando apenas a posterior do ajuste com todos os dados.
- Para cada observação $i$, cada amostra da posterior recebe um **peso** proporcional a $1/p(y_i \mid \Theta_s)$: amostras em que $y_i$ é pouco provável representam melhor a posterior sem $y_i$.
- Os maiores pesos são suavizados com uma distribuição de Pareto. O parâmetro $k$ dessa distribuição é um **diagnóstico**: $k > 0{,}5$ indica observações muito influentes, e uma aproximação pouco confiável.
- Em `compare()`, use `func = PSIS` para comparar pelo PSIS.

```
> PSIS(m2)

Some Pareto k values are high (>0.5). Set pointw

      PSIS      lppd  penalty  std_err
1 54.14054 -27.07027 4.965544 8.363436
```

| Modelo | lppd (PSIS) | lppd (LOO) | k máximo |
|---|---|---|---|
| Grau 1 | -32,56 | -31,62 | 0,83 |
| Grau 2 | -27,39 | -25,71 | 1,15 |
| Grau 4 | -28,89 | -26,80 | 1,11 |
| Grau 6 | -31,83 | -28,27 | 1,20 |



# Mensagens para levar para casa

- Modelos estatísticos são aproximações dos processos probabilísticos que geram os dados.
- O poder preditivo de um modelo é sua capacidade de aproximar o processo gerador.
- Se avaliamos o poder preditivo com os mesmos dados usados para ajustar o modelo, o modelo mais complexo sempre terá melhor desempenho.
- Para evitar este risco de *overfitting* temos que estimar o poder do modelo prever observações fora da amostra.
- Podemos obter estas estimativas com critérios de informação (WAIC), e validação cruzada (incluindo sua aproximação PSIS).



# Referências


- Burnham, K.P. & Anderson, D.R. (2002). *Model Selection and Multimodel Inference: A Practical Information-Theoretic Approach*. 2ª ed. Springer.
- McElreath, R. (2020). *Statistical Rethinking: A Bayesian Course with Examples in R and Stan*. 2ª ed. CRC Press.
- Vehtari, A., Gelman, A. & Gabry, J. (2017). Practical Bayesian model evaluation using leave-one-out cross-validation and WAIC. *Statistics and Computing*, 27, 1413–1432.